Pré-processamento de Dados e Engenharia de Características

Prof. Milton Roman de Brito

Fatec Votorantim Benedicto Pagliato
Centro Paula Souza

Objetivo

Ao final da aula, vocês devem ser capazes de:

- Compreender a importância do pré-processamento em projetos de Aprendizado de Máquina
- Identificar problemas comuns em dados reais
- Aplicar técnicas básicas de limpeza e preparação de dados
- Entender o conceito e o papel da Engenharia de Características

Conteúdo da Aula

- Pré-processamento de dados e o Pipeline de ML
- Limpeza de Dados
- Dados Faltantes (missing values) e Outliers
- Transformação de Características
- Conexão com Projetos Reais
- Encerramento

Por que Pré-processar Dados?

- Dados reais são imperfeitos

- Presença de
  - Valores faltantes
  - Outliers
  - Escalas diferentes
  - Dados inconsistentes

- Impacto direto na qualidade do modelo

O Pipeline de um Projeto de ML (Visão Geral)

- Entendimento do Problema
- Coleta de Dados
- Pré-processamento e Engenharia de Características
- Treinamento do Modelo
- Avaliação, Ajustes e Iteração

Limpeza de Dados

Principais atividades

- Remoção de duplicatas
- Correção de inconsistências
- Padronização de formatos (datas, textos, categorias)

Exemplo → nomes de cidades, datas em formatos diferentes

Exemplos de Limpeza de Dados

Base de Clientes (CRM / Vendas)

Problemas Comuns

- Mesmo cliente cadastrado mais de uma vez
- Nomes escritos de formas diferentes
- Telefones e datas em formatos variados

Atividades de Limpeza

- ***Remoção de Duplicatas*** → Identificar registros repetidos pelo CPF ou e-mail
- ***Correção de Inconsistências*** → Ajustar nomes divergentes ("João da Silva" vs "J. Silva")
- ***Padronização de Formatos***
  - Telefones no padrão (DD) 9XXXX-XXXX
  - Datas no formato YYYY-MM-DD

Exemplos de Limpeza de Dados

Dados de Pesquisa ou Formulários (Marketing / UX)

Problemas Comuns

- Respostas duplicadas
- Valores inválidos
- Respostas textuais variadas para a mesma opção

Atividades de Limpeza

- ***Remoção de Duplicatas*** → Eliminar respostas repetidas do mesmo usuário
- ***Correção de Inconsistências*** → Ajustar idades fora do intervalo esperado (ex.: 5 ou 150 anos)
- ***Padronização de Formatos***
  - "Masculino", "M", "masc" → "Masculino"
  - Datas de resposta em formato único

Dúvidas e consolidação do Conteúdo

- Quais tipos de problemas de inconsistências de dados vocês já observaram?
- Há algum outro tipo de problemas em dados que vocês conseguem perceber que ainda não falamos?
- Que tipo de problemas, as inconsistências podem provocar nos modelos treinados?

Dados Faltantes (Missing Values)

O que são dados faltantes?

Possíveis causas

- Erro de coleta
- Informação não aplicável
- Falha de preenchimento

Estratégias para Dados Faltantes

Remoção de registros

Preenchimento (imputação)
- Média / mediana
- Moda
- Valor constante

Considerações importantes
- Quantidade de dados faltantes
- Impacto no modelo

Exemplos de Dados Faltantes

Campo "*Renda Mensal*" não preenchido no cadastro (Financeiro)

Avaliação de Impactos no Modelo/Negócio

- Relevância da redução do volume de dados se optar pela Remoção de Registros
- Evita decisões baseadas em suposições arriscadas se optar pelo Preenchimento
- A relevância do dado para o resultado do modelo

Remoção de registros

- **Quando usar?**
  - Poucos registros estão incompletos
  - A renda é essencial para o modelo (ex.: concessão de crédito)

Preenchimento (Imputação)

- **Quando usar?**
  - A maioria dos clientes não informou renda
  - O negócio não pode perder tantos registros
- **Estratégia**
  - Média ou mediana da renda por faixa etária ou profissão

Exemplos de Dados Faltantes

Campo "*Idade*" ausente em parte da base (CRM / Marketing)

Avaliação de Impactos no Modelo/Negócio

- Relevância da redução do volume de dados se optar pela Remoção de Registros
- Impacto da idade e segmentação etária em campanhas

Remoção de registros

- **Quando usar?**
  - Idade é uma variável secundária
  - Há muitas outras features relevantes

Preenchimento (Imputação)

- **Quando usar?**
  - Segmentação etária é importante para campanhas direcionadas
- **Estratégia**
  - Mediana da idade
  - Idade média por segmento (ex.: tipo de produto comprado)

Exemplos de Dados Faltantes

Cliente comprou, mas não avaliou o produto (e-commerce)

Avaliação de Impactos no Modelo/Negócio

- Relevância da redução do volume de dados se optar pela Remoção de Registros
- O objetivo é treinar um sistema de recomendação
- Análise agregada de satisfação

Remoção de registros

- **Quando usar**
  - Avaliações não são obrigatórias
  - O modelo pode trabalhar apenas com quem avaliou

Preenchimento (Imputação)

- **Quando usar**
  - Sistemas de recomendação
  - Análises agregadas de satisfação
- **Estratégia**
  - Valor neutro (ex.: 3 estrelas)
  - Média das avaliações do produto

Outliers

O que são Outliers?

Exemplos

- Salários muito acima da média
- Idades irreais

Podem representar

- Erros
- Casos raros, porém válidos

Tratamento de Outliers

- **Remoção**
- **Limitação (clipping)**
- **Transformações**

Decisão depende do contexto do problema ⚠

Exemplo de Tratamento de Outliers

Cadastro de clientes (CRM) - Idade registrada como 200 anos

- **Estratégia adotada – Remoção**
  - Eliminar registros com valores impossíveis ou claramente errados
- **Justificativa de Negócio**
  - Não representam clientes reais
  - Provavelmente erro de digitação ou falha de sistema
- **Impacto**
  - Base menor, porém mais confiável
  - Evita distorção em médias e modelos preditivos

Exemplo de Tratamento de Outliers

Análise de salários ou renda - Renda mensal muito acima do padrão (ex.: R$ 1.000.000)

- **Estratégia adotada – Limitação (Clipping)**
  - Definir limites máximos e mínimos (percentis 1% e 99%)
  - Valores fora do intervalo são “cortados” para o limite
- **Justificativa de Negócio**
  - Valores extremos existem, mas não devem dominar o modelo
  - Preserva o registro, reduzindo influência exagerada
- **Impacto**
  - Mantém volume de dados
  - Reduz sensibilidade de algoritmos como Regressão Linear

Exemplo de Tratamento de Outliers

Vendas diárias (E-commerce) -Poucos dias com vendas extremamente altas (Black Friday)

- **Estratégia adotada – Transformações (veremos melhor adiante)**
  - Aplicar logaritmo, raiz quadrada ou outra técnica de redução de assimetria
- **Justificativa de Negócio**
  - Outliers são reais e relevantes
  - Transformação reduz assimetria sem perder informação
- **Impacto**
  - Distribuição mais próxima da normal
  - Melhor desempenho de modelos estatísticos

Dúvidas e consolidação do Conteúdo

- Conseguem identificar situações de Dados Ausentes ou Outliers em projetos que vocês já atuaram?

- Conseguem perceber outras formas de trabalhar os dados para resolver este tipo de problema?

Engenharia de Características

Processo de criar, transformar ou selecionar variáveis

Objetivo → melhorar o desempenho do modelo

"Bons atributos muitas vezes valem mais que modelos complexos"

Tipos de Engenharia de Características

- **Criação de novas características**
- **Transformação de características existentes**
- **Seleção de características relevantes**

Exemplos de Criação de Características

- **Data** → dia da semana, mês, ano, período (ano/mês)
- **Texto** → contagem de palavras
- **Dados numéricos** → razão, soma, diferença

Exemplo → Criar uma característica "Idade" a partir da "Data de nascimento"

Transformação de Características

- **Escalonamento** → Ajustar os valores para uma mesma faixa numérica, facilitando a comparação entre elas.
- **Normalização** → Transforma os dados para um intervalo fixo, geralmente entre 0 e 1.
- **Padronização** → Transforma os dados para terem média 0 e desvio padrão 1, mantendo a distribuição relativa.

Motivo → Muitos algoritmos são sensíveis à escala dos dados

Seleção de Características

Nem todas as variáveis ajudam o Modelo

- **Tem o objetivo de reduzir**
  - **Ruído** → Variações aleatórias ou erros nos dados que não representam o padrão real do problema
  - **Overfitting** (sobreajuste) → Situação em que o modelo aprende excessivamente os dados de treino, perdendo capacidade de generalização
  - **Custo computacional** → Quantidade de recursos computacionais (tempo de processamento e memória) necessários para treinar ou executar um modelo

Erros Comuns em Pré-processamento

- **Vazamento de dados (data leakage)**
  - Calcular a média para padronização usando dados de treino e teste juntos antes da separação
- **Tratamento inadequado de dados ausentes**
  - Substituir valores por zero sem avaliar o significado do dado
- **Remoção indevida de dados**
  - Excluir muitas linhas com valores faltantes e acabar perdendo informações importantes do problema.
- **Ignorar o impacto das Transformações**
  - Aplicar normalização sem necessidade em um modelo baseado em árvores
  - Criar muitas variáveis irrelevantes, tornando o treinamento mais lento sem ganho real

Dúvidas e consolidação do Conteúdo

- Conseguem identificar situações de Dados Ausentes ou Outliers em projetos que vocês já atuaram?

- Conseguem perceber outras formas de trabalhar os dados para resolver este tipo de problema?

Conexão com Projetos Reais

- Pré-processamento é a parte mais demorada do projeto
- Atividade altamente iterativa
- Forte dependência do domínio do problema

Encerramento

- Foco de Hoje → **A importância de preparar e organizar os dados para o aprendizado de máquina**
- Ainda seguimos sem código, mas logo vai mudar
- Próxima aula → ***Regressão Linear***