# Regressão Linear

Prof. Milton Roman de Brito



Fatec Votorantim Benedicto Pagliato
Centro Paula Souza

# Objetivo

**Ao final da aula, vocês devem ser capazes de:**

- Compreender a formulação matemática da Regressão Linear
- Entender o conceito de função de custo (MSE)
- Explicar como funciona o Gradiente Descendente
- Aplicar Regressão Polinomial e compreender a importância da Regularização
- Interpretar as métricas MSE e RMSE

# Conteúdo da Aula

- Intuição da Regressão
- Formulação Matemática do Modelo
- Função de Custo (MSE)
- Minimização do Erro
  - Equação Normal
  - Gradiente Descendente
- Métricas de Avaliação

# O Problema de Regressão

**O que é Regressão?**

- Se eu quiser prever algo como “o nível de satisfação das pessoas” com base em sua renda, que tipo de problema é esse?

- Exemplos do mundo real
  - Preço de imóveis
  - Consumo de energia
  - Receita de vendas

- O que significa "ajustar um modelo" aos dados?

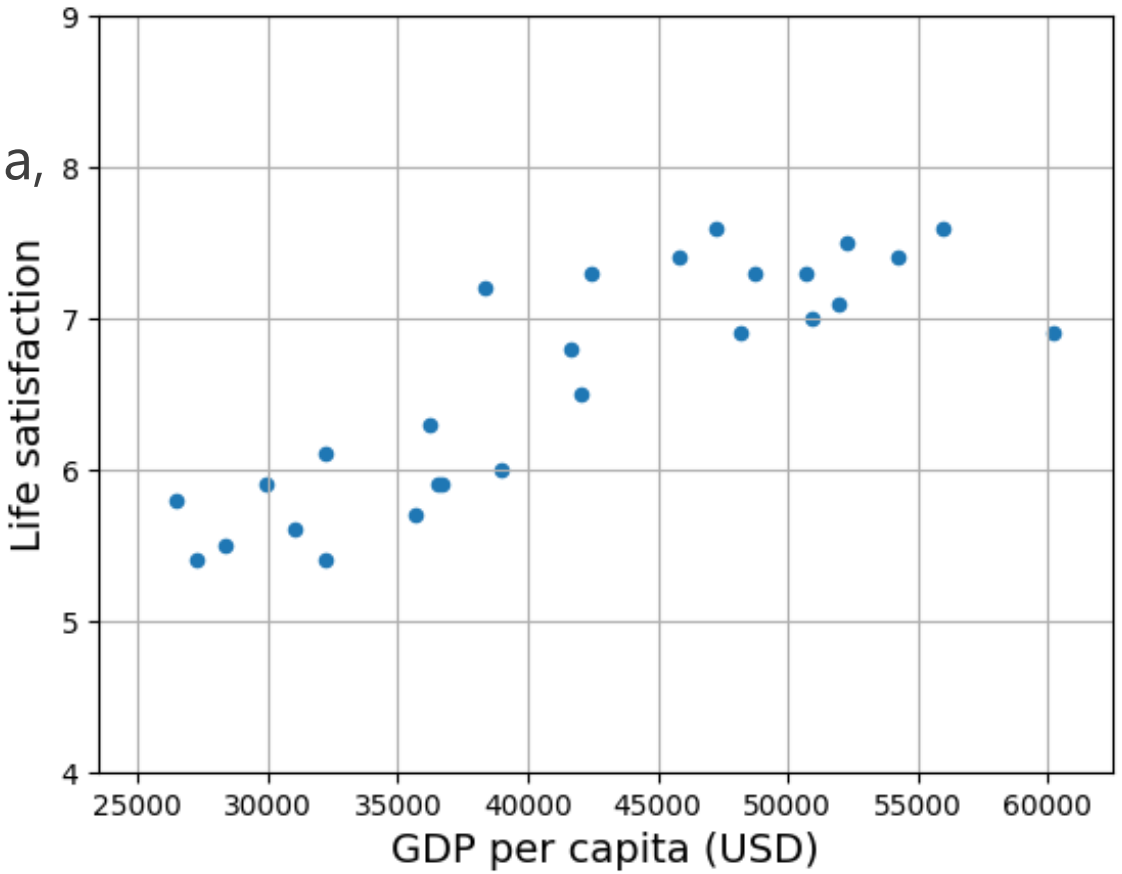

# Ideia Intuitiva

**Queremos encontrar a melhor reta que representa os dados**

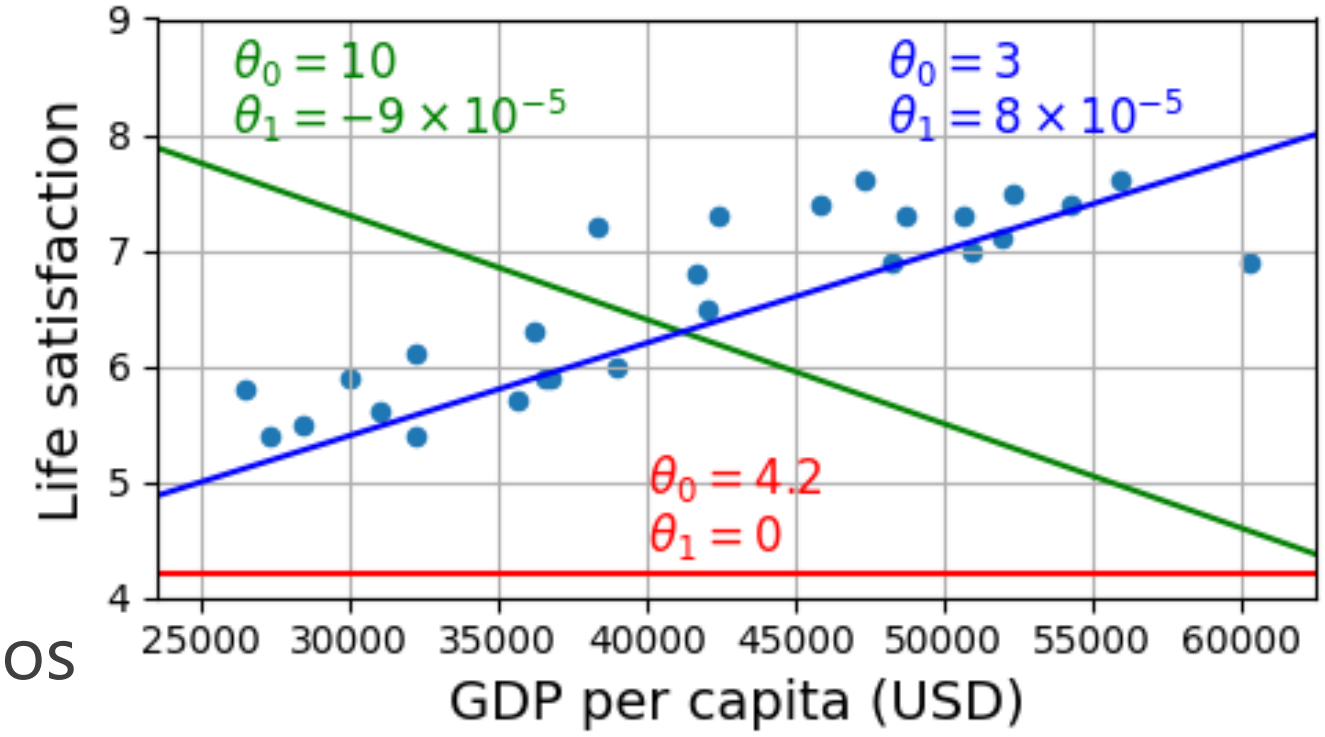


Equação básica

$$\hat{y} = \theta_0 + \theta_1 x$$

- $\theta_0$ → intercepto → viés(bias)
- $\theta_1$ → inclinação → pesos (weigths)

**Conceito-chave** → modelo linear nos parâmetros

# Formulação Geral (Múltiplas Variáveis)

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \ldots + \theta_n x_n$$

- O que representam $\hat{\mathbf{y}}$, $\mathbf{x}$ e $\boldsymbol{\theta}$?

Forma vetorial → $\hat{\mathbf{y}} = \mathbf{X}\boldsymbol{\theta}$

- Todos os dados viram uma matriz X
- Todos os parâmetros viram um vetor θ

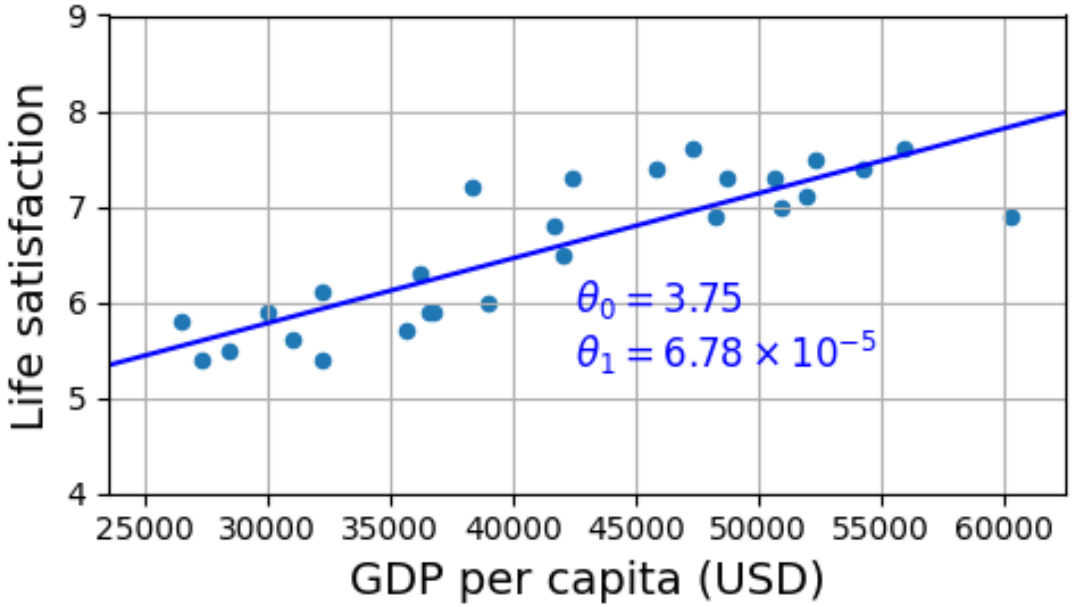


- Por que essa forma é importante computacionalmente?
  - Vetorização | Paralelismo |Escalabilidade

- **O que significa "Treinar" e "Avaliar" o Modelo?**

# Como Medimos o erro?

- **O que é o "Erro" na Regressão Linear?**

- Erro individual
  - **erro = ŷ - y**

- Problema → somar erros cancela sinais
- Precisamos de uma função de custo global

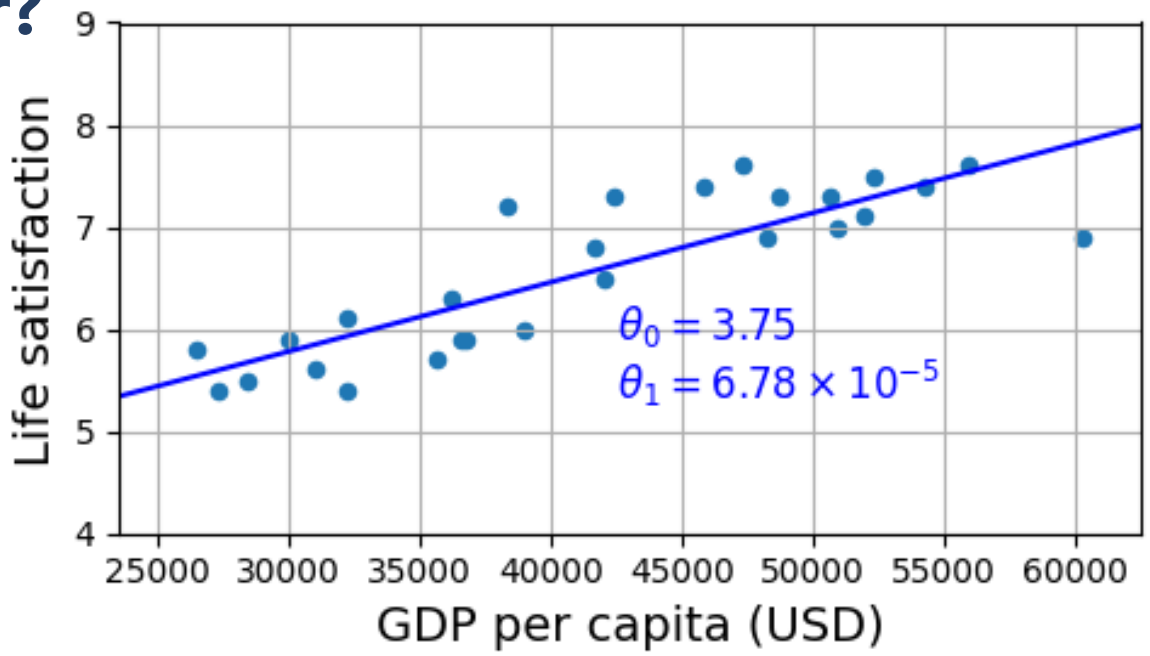

# Mean Squared Error (MSE)

$$MSE = (1/m)\ \Sigma\ (\hat{y}^{(i)} - y^{(i)})^2$$

- Penaliza erros grandes
- Sempre positivo
- Diferenciável

**Por que elevamos ao quadrado?**

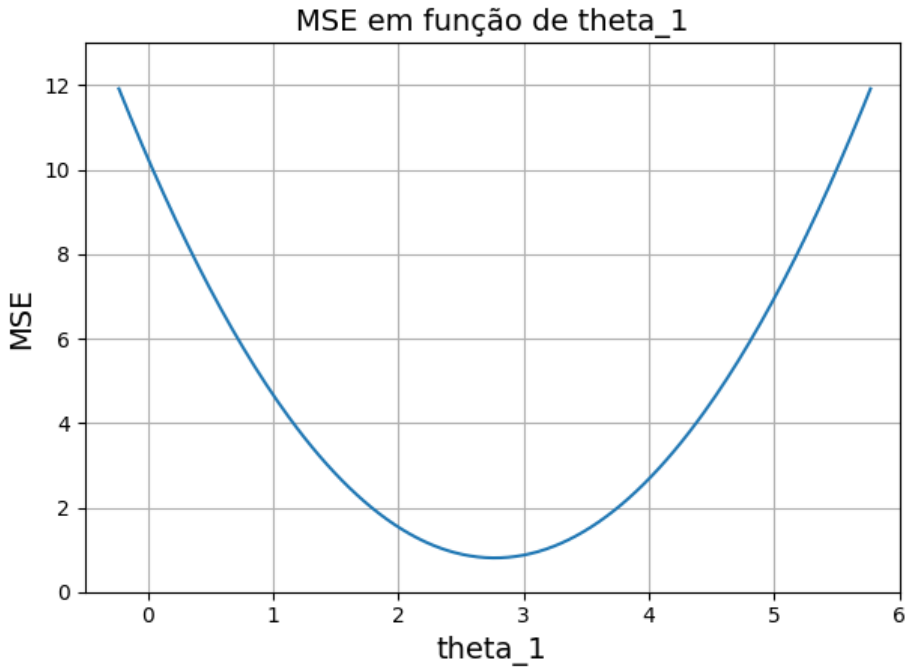

# Objetivo do Treinamento

- **Encontrar os parâmetros θ que minimizam o MSE**

- Solução Analítica (Equação Normal)
  - $\theta = (X^T X)^{-1} X^T y$

- Solução fechada
- Não iterativa
- Pode ser custosa computacionalmente

- **Agora, vamos observar isso na Prática**

# Demonstração

- **Notebook**
  Aulas - 04 Regressão Linear.ipynb
  - Regressão Linear

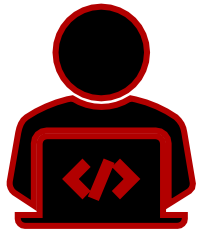

# Gradiente Descendente

## Por que Precisamos do Gradiente Descendente?

## Problemas da Equação Normal

- Inversão de matriz
- Alto custo computacional

Solução → Método iterativo de otimização

# Ideia do Gradiente Descendente

- Inicialização Aleatória dos parâmetros **θ**
- É definido um η (eta) → taxa de aprendizado
- É calculado o gradiente do MSE
  - Identifica a direção em que, ao ajustar o θ, o MSE aumenta
- Atualiza θ na direção oposta ao gradiente
- Repete até atingir um critério de parada
  - convergência
  - número máximo de epochs

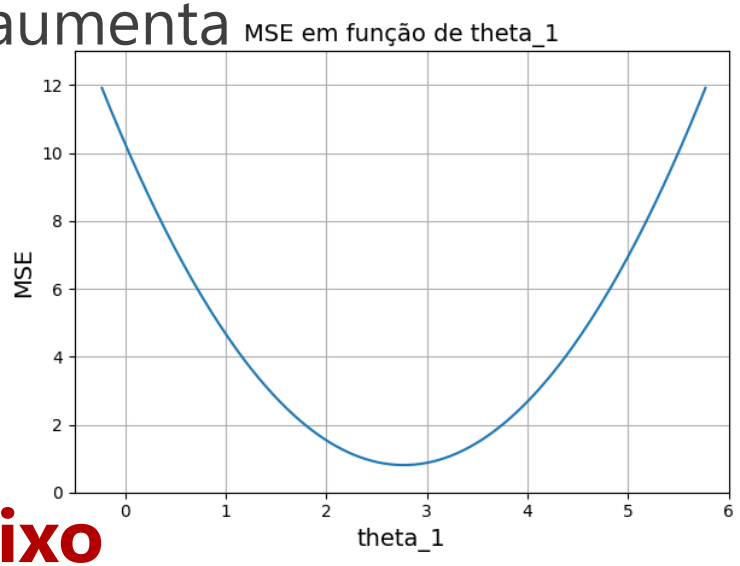


**Intuição – Descer um vale até o nível mais baixo**

# Tipos de Gradiente Descendente

- **Batch Gradient Descent (BGD)**
  - Calcula o gradiente usando **todo o conjunto de dados** a cada atualização dos parâmetros
- **Stochastic Gradient Descent (SGD)**
  - Atualiza os parâmetros usando **uma única amostra por vez**, tornando o processo mais rápido e ruidoso
- **Mini-batch**
  - Atualiza os parâmetros usando **pequenos lotes de amostras**, sendo um método que aplica o método do BGD, mas sem utilizar todo o conjunto de dados, de forma que o aproxima do SGD

Qual tipo de Gradiente Descendente você prefere aplicar?

# Demonstração

- **Notebook**
  Aulas - 04 Regressão Linear.ipynb
  - Gradiente Descendente

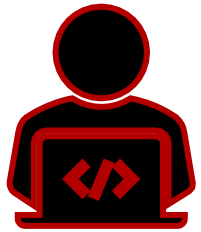

# Regressão Polinomial

E se os dados não forem lineares?

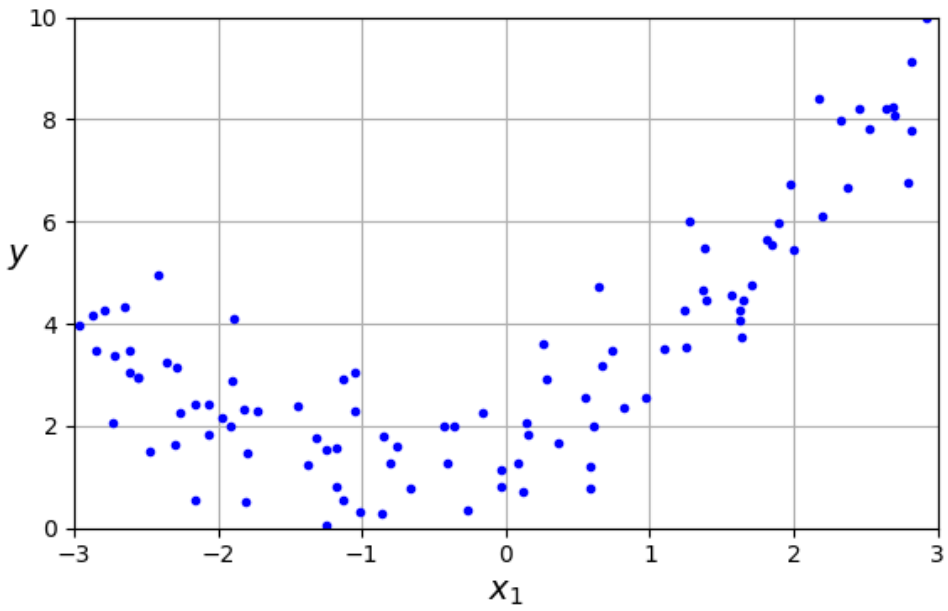


Podemos transformar as características

- $\hat{y} = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \ldots$

**Ideia Central** → O modelo continua sendo linear nos parâmetros, mas não nas variáveis

# Como Funciona na Prática?

- Transformamos **x** em
  - $[x, x^2, x^3, \ldots]$
- E aplicamos Regressão Linear normalmente

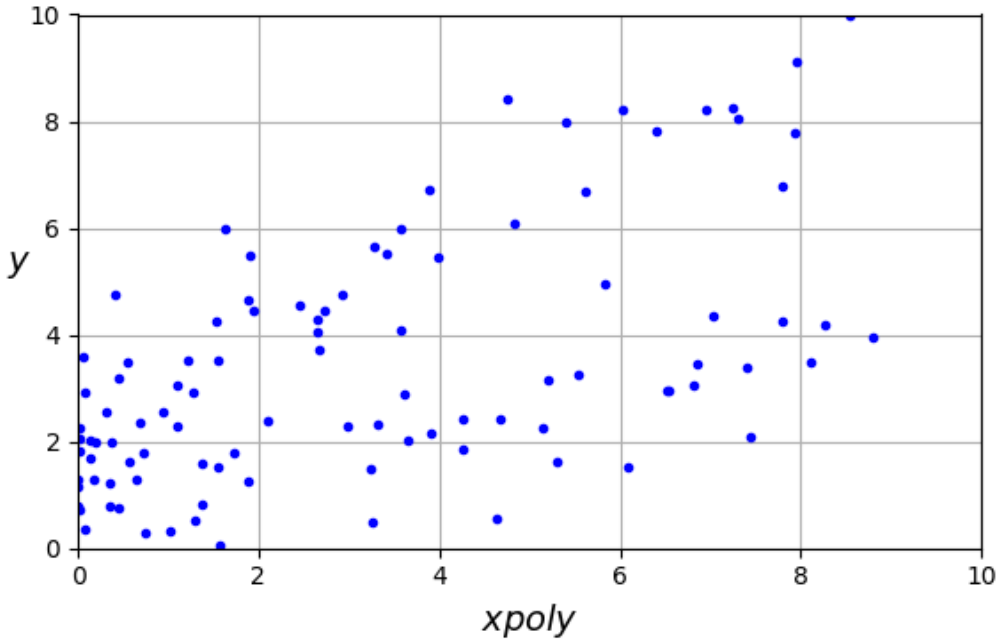


*Estudamos isso na aula de Pré-processamento → Isso é Engenharia de Características*

# Demonstração

- **Notebook**
  Aulas - 04 Regressão Linear.ipynb
  - Regressão Polinomial

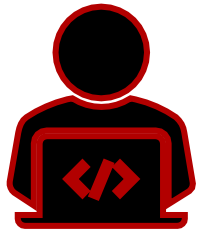

# Curva de Aprendizado

## Risco: Overfitting

- Modelos polinomiais de alto grau podem
  - Ajustar perfeitamente os dados de treino
  - Generalizar mal para novos dados

- Trade-off → Viés × Variância

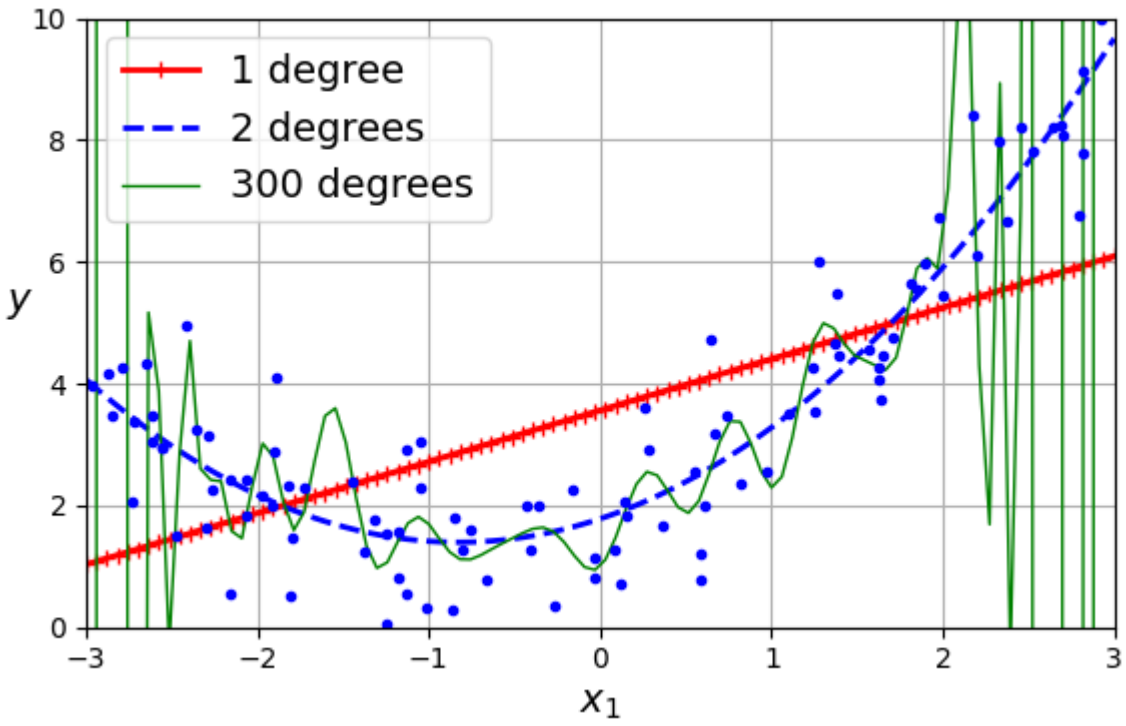

# Regularização → Ideia Geral

- **Objetivo → Controlar a complexidade do modelo**

- Como é feito?
  - Adicionando uma “penalização” à complexidade do modelo
  - Ou seja, força os parâmetros a não crescerem demais
    - Isso reduz a variância, mas pode aumentar um pouco o viés

# Regressão Ridge (L2)

- Penaliza coeficientes grandes, procurando minimizar o valor dos valores $\theta_1$, $\theta$ até o $\theta_n$ da função
- Reduz variância
- Não zera coeficientes

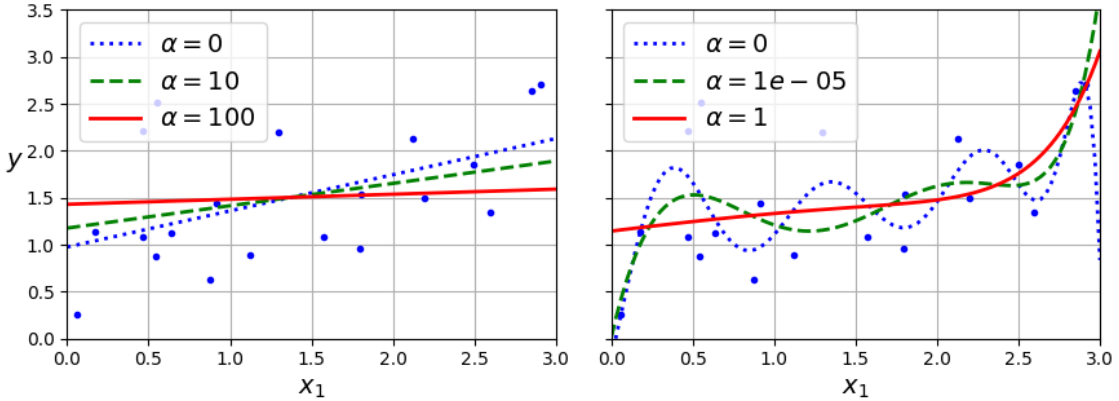


- As funções de Regularização possuem o hiperparâmetro **alpha (α)** para controlar a penalização da complexidade do modelo
  - **α pequeno** → pouca regularização → menor viés, maior variância
  - **α grande** → forte regularização → maior viés, menor variância

# Regressão Lasso (L1)

- É um modelo que procura eliminar os coeficientes que trazem impacto pequeno ao cálculo deixando-os com valor 0
- Atua como seleção automática de Características (engenharia de características)

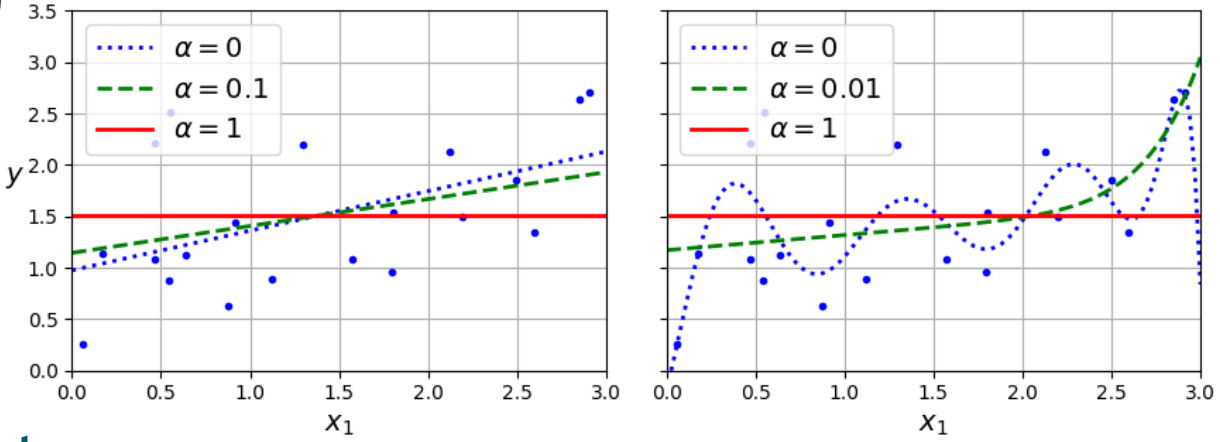


- Aqui também temos o hiperparâmetro **alpha (α)** para controlar a regularização

# Elastic Net

- **Combinação de L1 (Lasso) e L2 (Ridge)**

- Equilibra
  - Estabilidade (Ridge)
  - Seleção de atributos (Lasso)

# Resumo Visual
# Viés x Variância e aplicação prática

Identificado → Underfitting / Overfitting

Avaliação do Trade-off → viés × Variância

Necessidade de Controle da Complexidade

Regularização

Lasso / Ridge / Elastic Net

# Demonstração

- **Notebook**
  Aulas - 04 Regressão Linear.ipynb
  - Modelos Lineares Regularizados

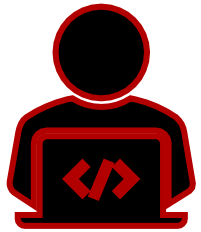

# Avaliação do Modelo

## Métricas de Avaliação

- **MSE** → Mean Squared Error (Erro Quadrático Médio)
- **RMSE** → Root Mean Squared Error (Raiz do Erro Quadrático Médio)

Interpretação → RMSE retorna erro na mesma unidade do alvo

Qual métrica comunica melhor para um gestor?

# Parada Antecipada

Técnica de **regularização implícita** que interrompe o treinamento quando o modelo começa a piorar no conjunto de validação

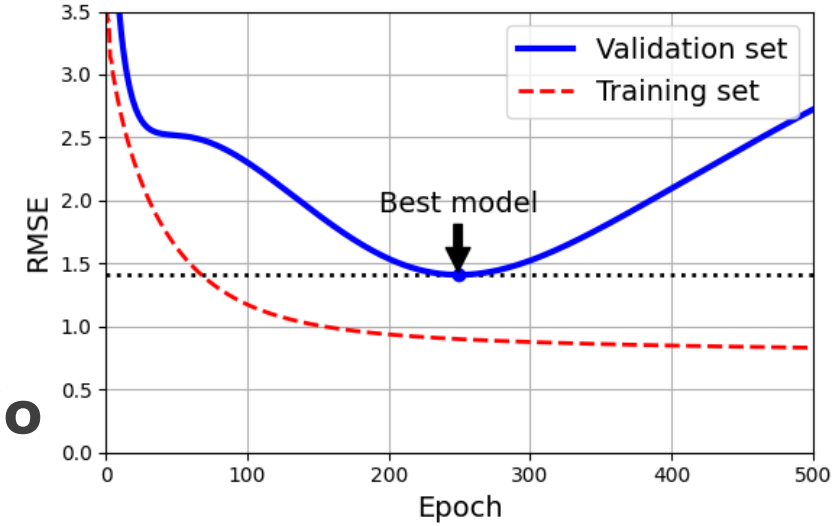


- Durante o Treinamento
  - Erro no Dataset de Treino → **Sempre diminui**
  - Erro no Dataset de Validação → **Diminui no início**
  - Depois começa a aumentar (**overfitting**)
  - A parada antecipada interrompe o treino **no ponto mínimo do erro de validação**

# Demonstração

- **Notebook**
  Aulas - 04 Regressão Linear.ipynb
  - Avaliação do Modelo

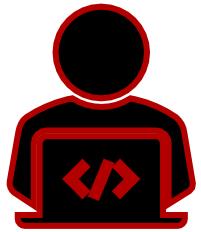

# Problemas Comuns

- Overfitting
- Underfitting
- Dados não escalonados
- Interpretação incorreta do erro

# Notebooks

- Ao final do Notebook estão os exercícios para Prática
- A cada Notebook apresentado em aula, vocês vão ter novas ferramentas, e códigos de referência para desenvolver seus próprios trabalhos
- A cada exercício que desenvolverem, além de consolidar o conhecimento, tornando-o realmente de vocês, também criarão novas referências para os próximos trabalhos (em aula, ou no mercado de trabalho)

# Encerramento

- Foco de Hoje → **Compreender o conceito da Regressão Linear, e todas as técnicas e ferramentas associadas**

- Hoje vimos diversas ferramentas e muito código, agora a consolidação do conhecimento, vem com a **PRÁTICA**

- Próxima aula → ***Regressão Logística***