Regressão Logística

Prof. Milton Roman de Brito

Fatec Votorantim Benedicto Pagliato
Centro Paula Souza

Objetivo

Ao final da aula, vocês devem ser capazes de:

- Compreender o problema de classificação em Machine Learning
- Entender a diferença entre regressão e classificação
- Interpretar probabilidades em modelos de classificação
- Compreender a função sigmoide
- Entender a função de custo da Regressão Logística
- Interpretar fronteira de decisão
- Identificar, interpretar e selecionar Métricas de Classificação

Conteúdo da Aula

- Problema de Classificação
- Da Regressão Linear à Regressão Logística
- Função Sigmoide
- Interpretação Probabilística
- Função de Custo (Log Loss)
- Fronteira de Decisão
- Métricas de Classificação
- Classificação Binária e Multiclasse

O Problema de Classificação

Diferente da Regressão

- Saída não é contínua
- Saída representa categorias

- Exemplos
  - Spam / Não Spam
  - Doença / Saudável
  - Aprovado / Reprovado

Por que não podemos usar Regressão Linear para classificação?

Problema de Usar Regressão Linear

- Não representa probabilidade
- Sensível a outliers
- Precisamos de uma função que permita identificar as Categorias

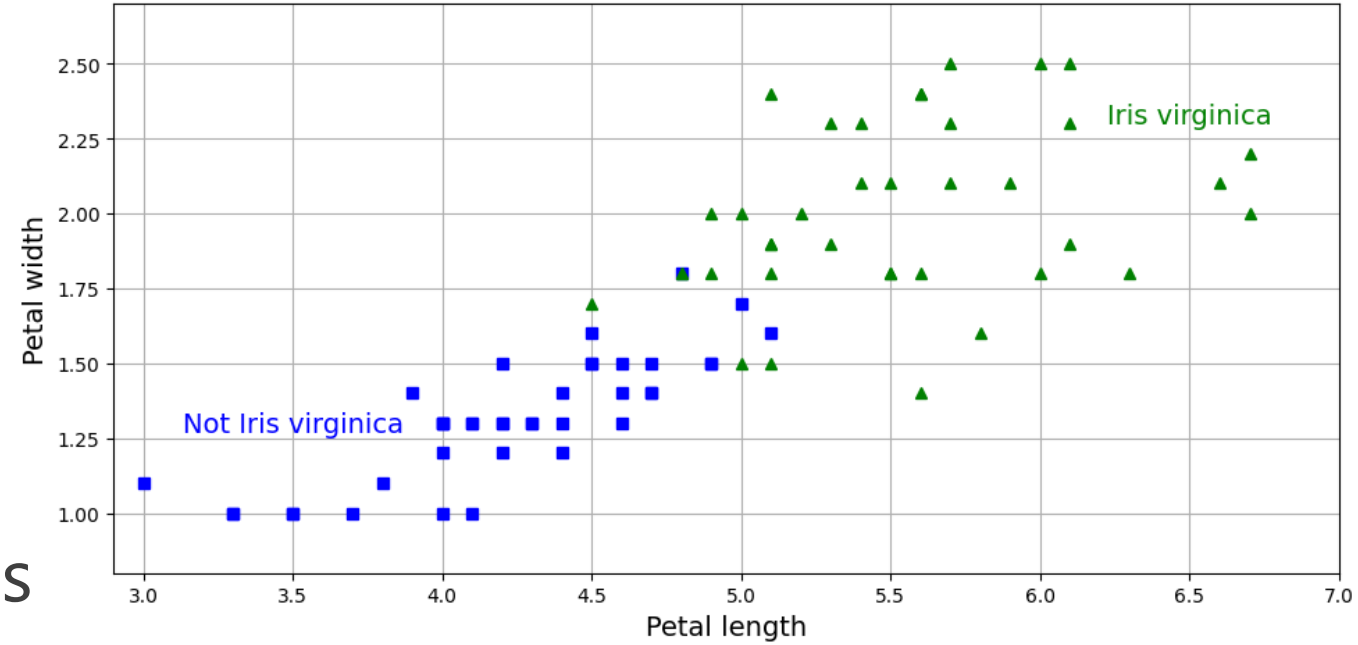

A Função Sigmoide

$$\sigma(t) = \frac{1}{(1+e^{-t})}$$

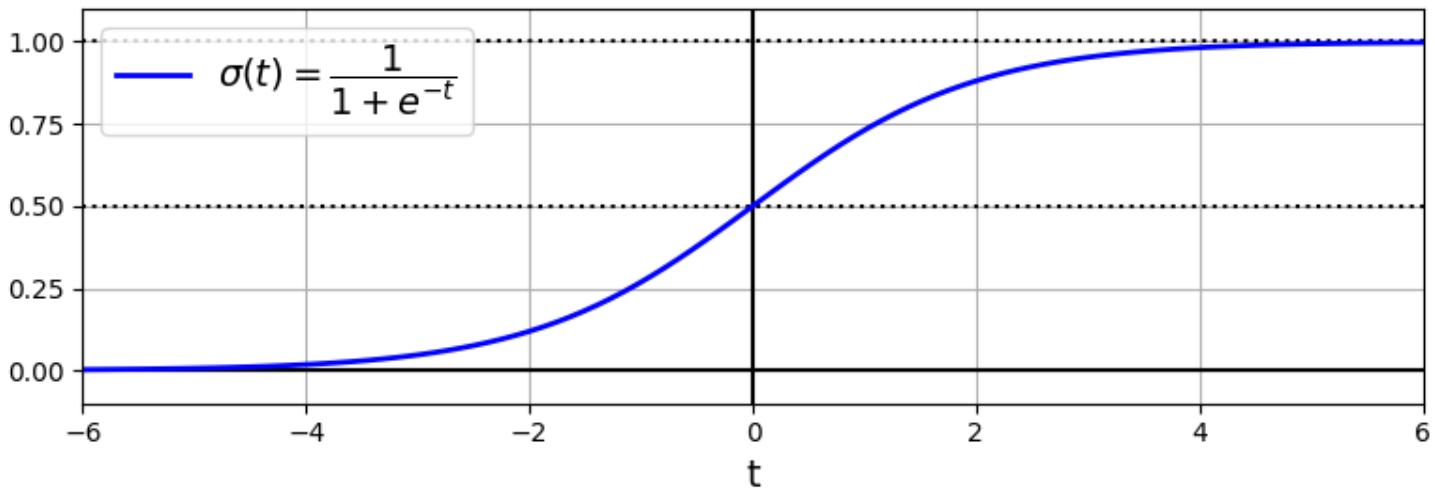

Propriedades

- Intervalo (0,1)
- Curva em formato de "S"
- Interpretação probabilística

O que acontece quando T é um valor muito grande? Ou um valor muito negativo?

Modelo da Regressão Logística

- **Primeiro**
  - **$t = \theta^T x$** → *Esta fórmula é familiar?*

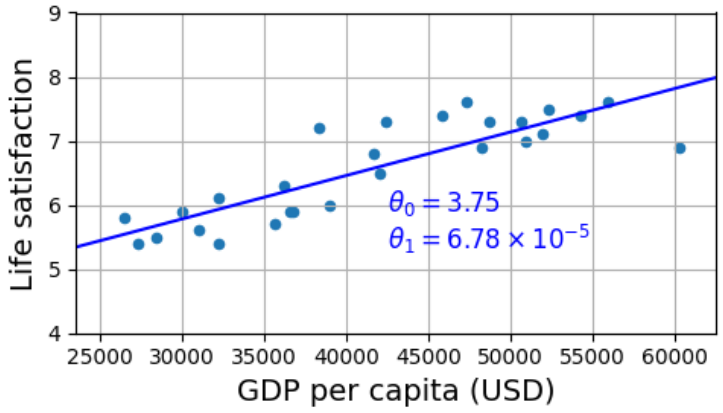

- **Depois é aplicado**
  - **$\hat{y} = \sigma(\theta^T x)$** → E esta?

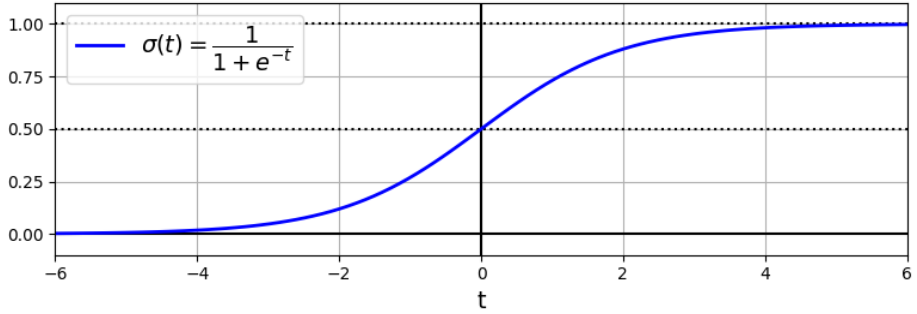

Modelo da Regressão Logística

- **$t = \theta^T x$**
  - $\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \end{bmatrix}$ $\quad x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix}$ $\quad t = \theta^T x = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2$

- O problema aqui, é que *t* pode ser
  - Negativo
  - Positivo
  - Muito Grande
  - Muito Pequeno

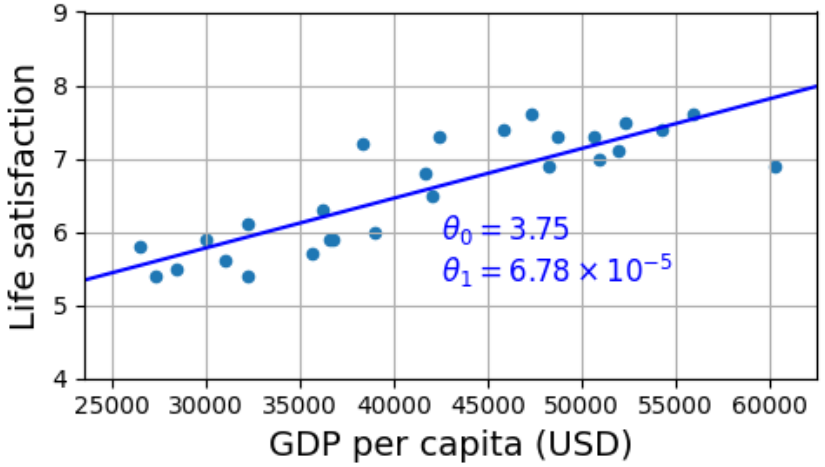

Para classificação, queremos um número entre 0 e 1, portanto é aplicada a função sigmoide

Modelo da Regressão Logística

- $\hat{y} = \sigma(\theta^T x) \rightarrow \hat{y} = \sigma(t)$

- $\sigma(t) = \dfrac{1}{(1+e^{-t})} \rightarrow \sigma(t) = \dfrac{1}{(1+e^{-(\theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2)})}$

- $e^{-t} \rightarrow$ **Sempre será um valor Positivo**
- $\sigma(t) \rightarrow$ **Sempre ficará entre 0 e 1**

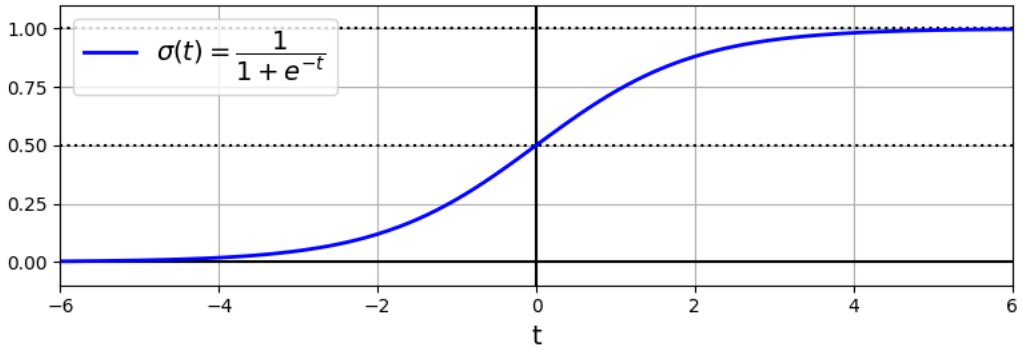

Como isso se conecta com o problema da classificação?

Regra de Decisão

- **A Classificação segue a regra**
  - $\hat{y} \geq 0{,}5 \rightarrow$ Classe 1
  - $\hat{y} < 0{,}5 \rightarrow$ Classe 0

- Por padrão, o resultado 0,5 da função sigmoide é considerado como a "Fronteira de Decisão", ou "Threshold"

O threshold precisa ser sempre 0.5?

Demonstração

- **Notebook**
  Aulas - 05 - Regressão Logística.ipynb
  - Regressão Logística

Função de Custo da Regressão Logística

- **Como é o Treinamento da Regressão Logística?**
  - O objetivo é encontrar os coeficientes da matriz θ, de modo que o modelo atribua
    - Alta probabilidade à classe correta
    - Baixa probabilidade à classe errada

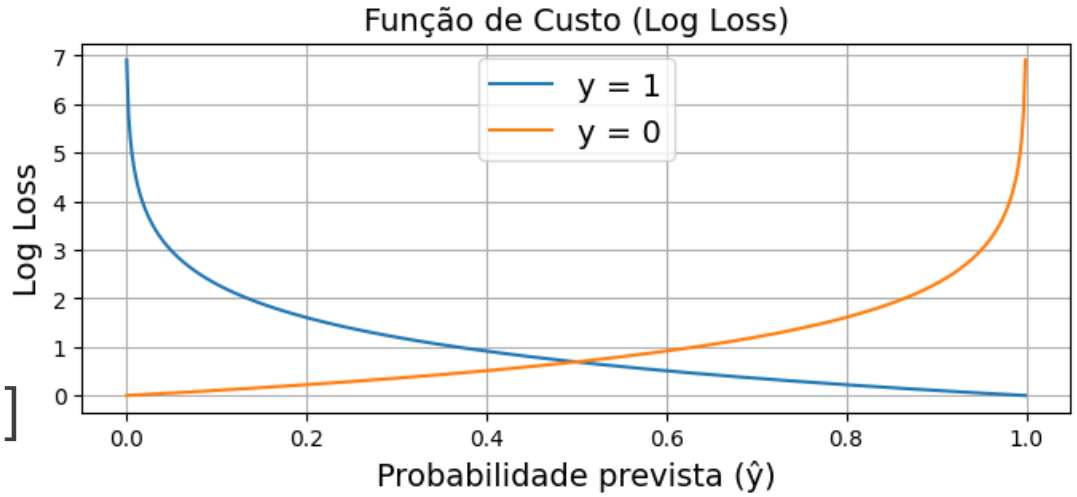

- Log Loss (Entropia Cruzada)
  - $J(\theta) = -1/m \, \Sigma \, [\, y \log(\hat{y}) + (1-y) \log(1-\hat{y}) \,]$

Por que MSE não é ideal aqui?

Intuição da Log Loss

- Penaliza fortemente classificações erradas com alta confiança
- Função convexa
- Permite otimização eficiente

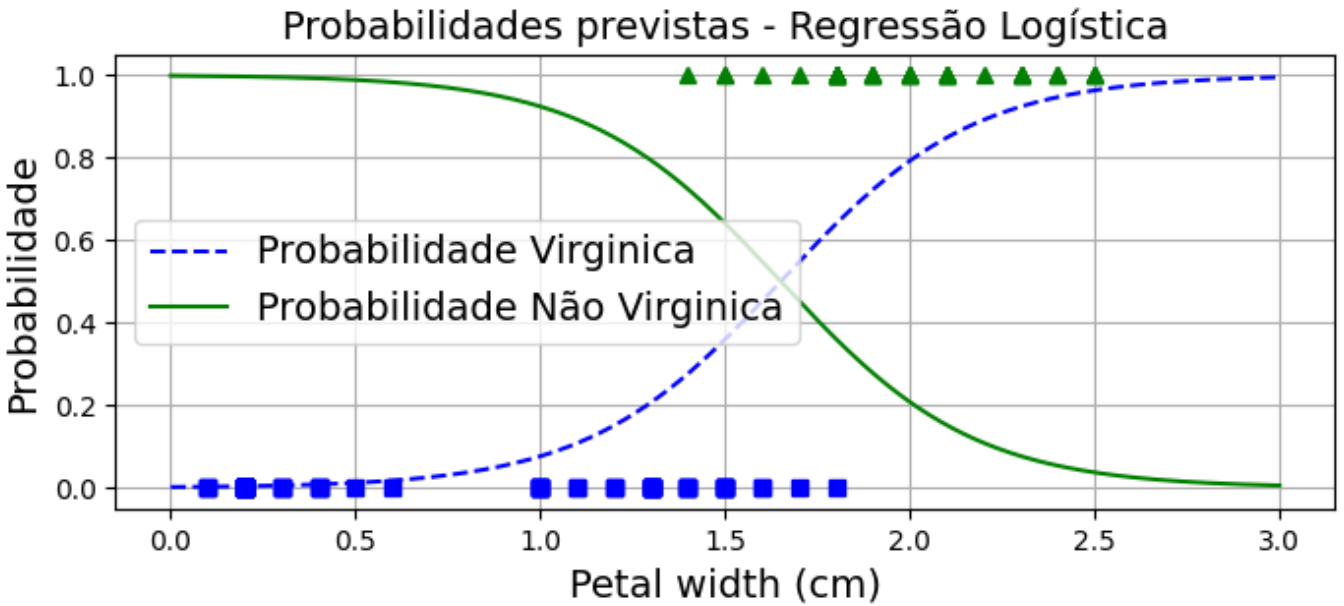

Regularização na Regressão Logística

- Assim como na Regressão Linear
  - **L2 → Ridge**
  - **L1 → Lasso**

- Objetivo
  - **Evitar Overfitting** → Preparar o modelo para dados novos
  - **Controlar Complexidade** → Redução de custo computacional

Demonstração

- **Notebook**
  Aulas - 05 - Regressão Logística.ipynb
  - Função de Custo e Regularização

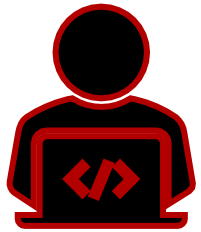

Métricas de Classificação

Por que Precisamos de Métricas?

Como podemos identificar com segurança que o modelo atende aos objetivos estabelecidos?

- Exemplo
  - 95% não-doentes / 5% doentes
  - Modelo que sempre prevê "não-doente"
  - Acurácia = 95% → *Uma medida excelente, não?*
  - Modelo **Inútil**

Acurácia

$$\boldsymbol{Acurácia} = \frac{\boldsymbol{TP(True\ Positive) + TN(True\ Negative)}}{\boldsymbol{Total}}$$

Percentual de previsões corretas

- **Quando funciona bem?**
  - Classes equilibradas
  - Custos semelhantes para erro

Validação Cruzada

Problema da Divisão de Dataset entre Treino/Teste (Holdout)

- O resultado depende muito da divisão

Solução

- K-Fold Cross Validation
  - Divide o Dataset em “k” partes
  - Treina “k” vezes
  - Cada parte vira teste uma vez
  - Calcula a média das métricas
- **Benefícios**
  - Reduz variância
  - Melhor estimativa de generalização

Matriz de Confusão

	Predict Positive	Predict Negative
True Positive	TP	FN
True Negative	FP	TN

TP → True Positive

TN → True Negative

FP → False Positive

FN → False Negative

A	Predict A	Predict B	Predict C
True A	TP	FN	FN
True B	FP	TN	TN
True C	FP	TN	TN

B	Predict A	Predict B	Predict C
True A	TN	FP	TN
True B	FN	TP	FN
True C	TN	FP	TN

C	Predict A	Predict B	Predict C
True A	TN	TN	FP
True B	TN	TN	FP
True C	FN	FN	TP

Precisão (*Precision*)

Intuição → *Das previsões positivas, quantas estavam corretas?*

$$\boldsymbol{Precisão} = \frac{TP\ (True\ Positives)}{TP\ (True\ Positives) + FP\ (False\ Positives)}$$

Importante quando → Falso positivo é caro

Exemplo → Filtro de Spam

	Predict Positive	Predict Negative
True Positive	TP	FN
True Negative	FP	TN

Revocação (*Recall*)

Intuição → *Dos positivos reais, quantos detectamos?*

$$\boldsymbol{Recall} = \frac{TP\ (True\ Positives)}{TP\ (True\ Positives) + FN\ (False\ Negatives)}$$

Importante quando → Falso Negativo é crítico

Exemplo → Diagnóstico Médico

Em um diagnóstico, o que é pior? FP ou FN?

	Predict Positive	Predict Negative
True Positive	TP	FN
True Negative	FP	TN

F1 Score

Intuição → Média harmônica entre Precisão e Recall

$$\boldsymbol{F1} = 2 \,.\, \frac{Precision \,.\, Recall}{Precision + Recall}$$

Importante quando

- Classes desbalanceadas
- Equilíbrio é importante

Exemplo → Detecção de Fraude

Trade-off → Precisão × Recall

Decision Function → Antes de identificar a classe final, o modelo calcula um **score contínuo**, onde

- Valores Positivos → **Classe Positiva**
- Valores Negativos → **Classe Negativa**

Threshold → Na Scikit Learn, o Valor 0 é a fronteira de decisão, quando comparado ao que a *Decision Function* retorna

Aumentar Threshold	↑ precisão	↓ recall
Diminuir Threshold	↑ recall	↓ precisão

Curva ROC

Receiver Operating Characteristic ou Característica de Operação do Operador

Eixo Y

- **TPR** → True Positive Rate (Recall)

Eixo X

- **FPR** → False Positive Rate (Fall-Out)
- $FPR = \frac{False\ Positive}{False\ Positive + True\ Negative}$

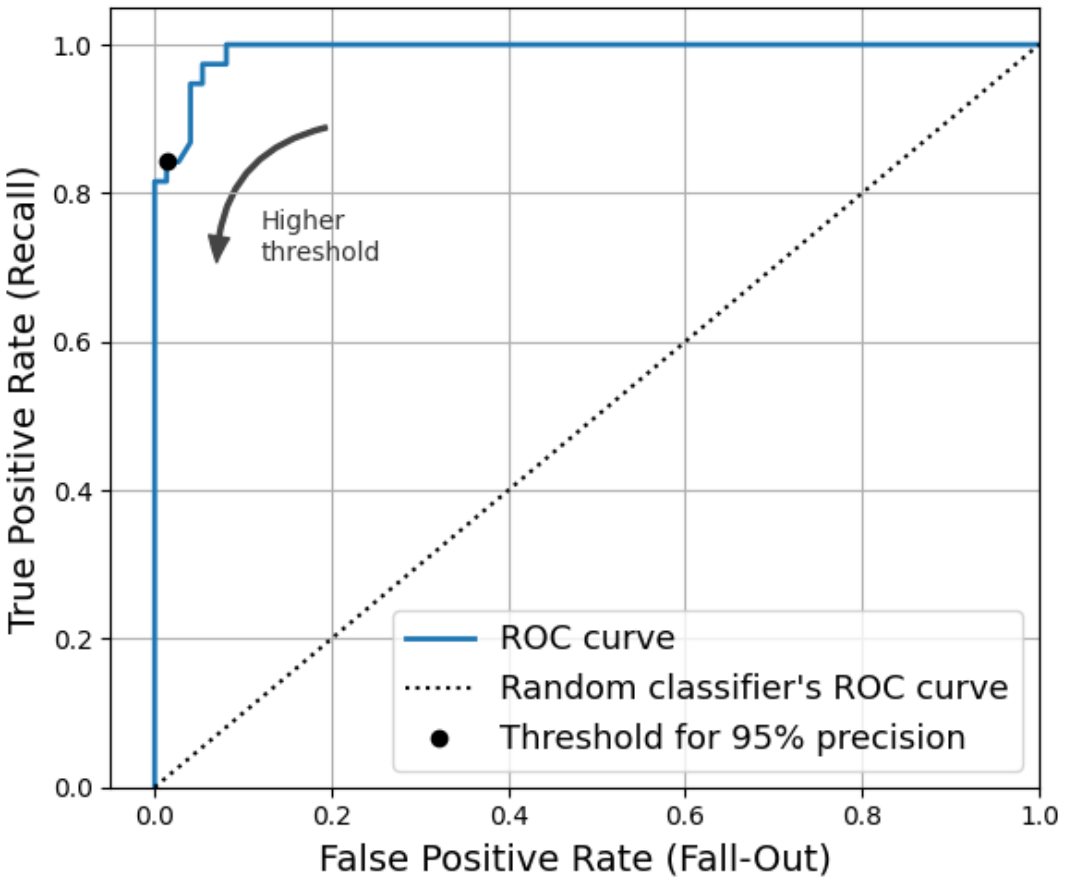

AUC (Area Under Curve)

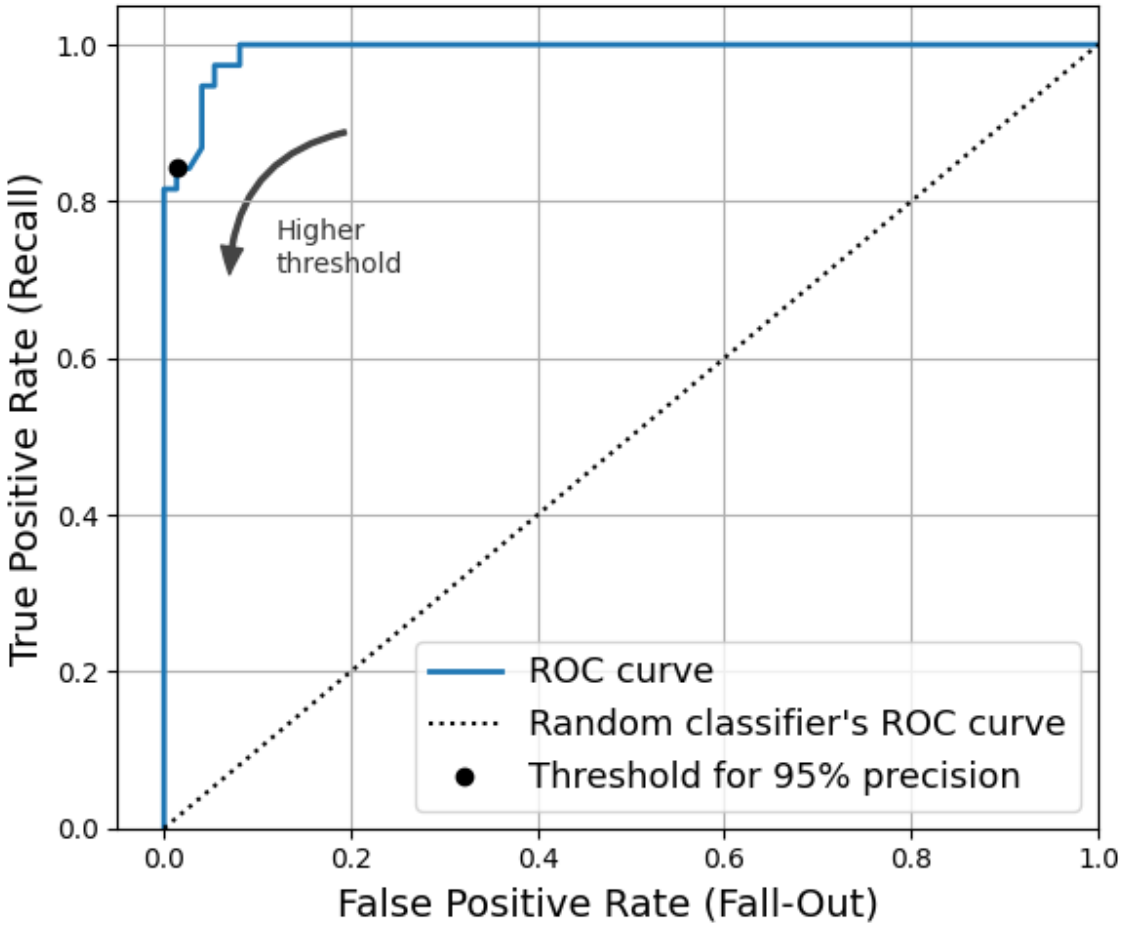

É a probabilidade de o modelo dar um score maior para um exemplo positivo do que para um exemplo negativo escolhido ao acaso

- **0.5** → Aleatório → Linha pontilhada
- **1.0** → Modelo Perfeito
- **0.991** → AUC do gráfico gerado
  - 99,1% das vezes, um Valor Positivo Real recebe um score maior pelo modelo, que um Valor Negativo Real

Demonstração

- **Notebook**
  Aulas - 05 - Regressão Logística.ipynb
  - Métricas

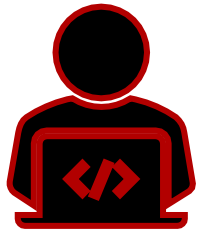

Classificação Multiclasse

- Dataset com 3 Classes
  - *Iris Virginica*, *Iris Versicolor* e *Iris Setosa*

- Estratégias
  - **One-vs-Rest** (OvR)
  - **One-vs-One** (OvO)
  - **Softmax** → Regressão Logística Multinomial

Conceito central → Probabilidade para múltiplas classes

Classificação Multiclasse One-vs-Rest (OvR)

- Necessário 3 Modelos Binários
  - **Setosa** vs Outros
  - **Versicolor** vs Outros
  - **Virginica** vs Outros

Previsão → Calcula-se a probabilidade de cada modelo, a classe vencedora, é aquela com a maior probabilidade

Classificação Multiclasse One-vs-One (OvO)

- Necessário Modelos Binários para todos os “pares” de classe
  - **Setosa** vs **Versicolor**
  - **Setosa** vs **Virginica**
  - **Versicolor** vs **Virginica**

Previsão → Calcula-se a probabilidade de cada modelo, a classe vencedora, é aquela escolhida pela maior quantidade de modelos

Classificação Multiclasse
Softmax → Regressão Logística Multinomial

- Um modelo Multiclasse Único
  - ***Entropia Cruzada Multiclasse***

- Cada classe tem seus **próprios parâmetros**
  - $z_k = \theta_k^T x$

- É aplicada a função **softmax**
  - $P(y = k|x) = \frac{e^{z_k}}{\sum_{j=1}^{k} e^{z_j}}$

Previsão → A função softmax transforma o score de cada classe em probabilidades (com soma 1), e a Classe com maior probabilidade é a escolhida

Demonstração

- **Notebook**
  Aulas - 05 - Regressão Logística.ipynb
  - Classificação Multiclasse

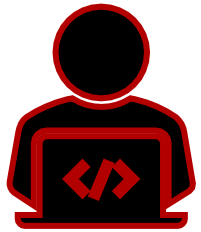

Notebooks

- Ao final do Notebook estão os exercícios para Prática
- A cada Notebook apresentado em aula, vocês vão ter novas ferramentas, e códigos de referência para desenvolver seus próprios trabalhos
- A cada exercício que desenvolverem, além de consolidar o conhecimento, tornando-o realmente de vocês, também criarão novas referências para os próximos trabalhos (em aula, ou no mercado de trabalho)

Encerramento

- Foco de Hoje → **Compreender o problema de classificação e como ele é trabalhado com a Regressão Logística, aplicando os conceitos de função de custo(LogLoss) e fronteira de decisão, métricas aplicadas, e como a Regressão Logística pode ser aplicada para classificação Multiclasse**

- Agora já temos pelo menos uma ferramenta para solução de problemas de Regressão e também de Classificação, cada vez mais, é importante a consolidação do conhecimento, com a **PRÁTICA**

- Próxima aula → ***Projeto de Aprendizagem de Máquina de Ponta a Ponta***