Máquinas de Vetores de Suporte (SVM – Support Vector Machines)

Prof. Milton Roman de Brito

Fatec Votorantim Benedicto Pagliato
Centro Paula Souza

Objetivo

Ao final da aula, vocês devem ser capazes de:

- Compreender o conceito de margem máxima
- Entender como funciona um classificador SVM
- Interpretar o papel dos vetores de suporte
- Compreender o impacto da regularização (hiper parâmetro c)
- Entender o Kernel Trick
- Aplicar SVMs para classificação e Regressão

Conteúdo da Aula

- Intuição das SVMs
- Margem Máxima
- Vetores de Suporte
- Regularização e margem suave
- SVM não linear
- Truque do Kernel
- Tipos de Kernel
- Regressão com SVM

O Problema de Classificação Linear

- Classificadores lineares
  - **Regressão Logística**
  - Perceptron

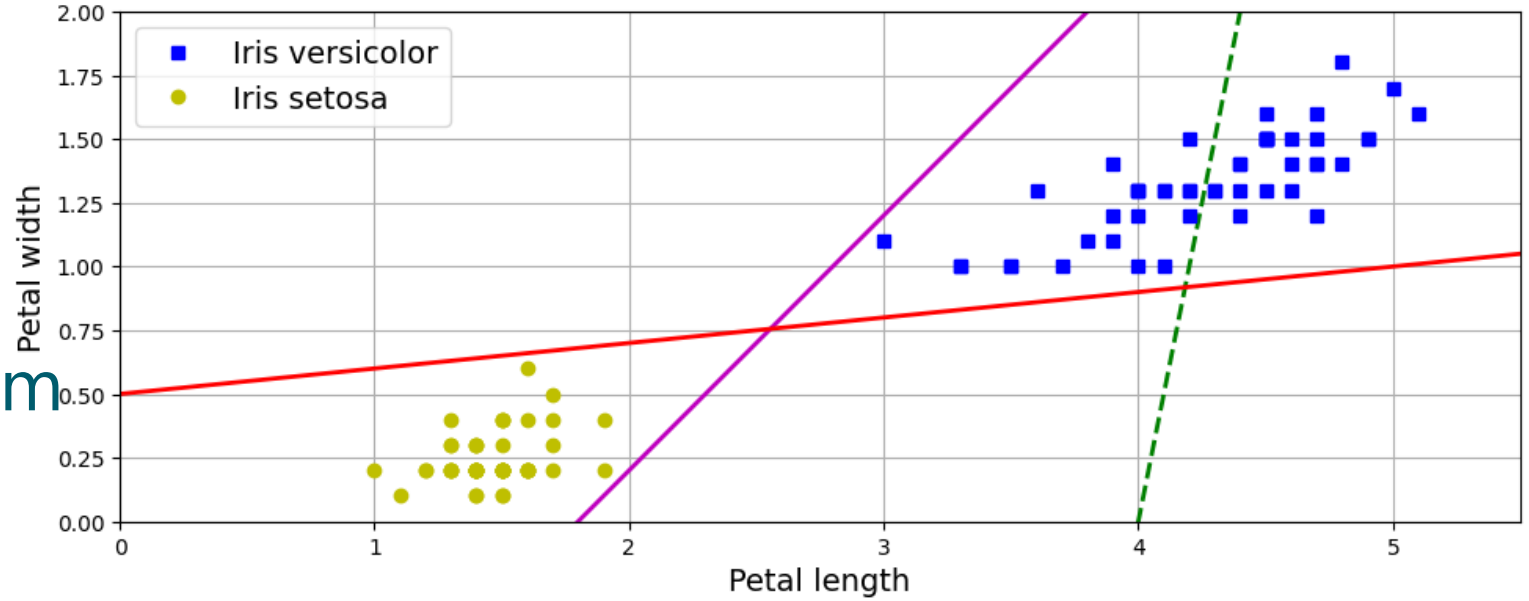

- Esses modelos aprendem
  - $w^T x + b = 0$

- Nestes modelos existem **infinitas retas** que separam os dados

Qual dessas retas é a melhor?

Ideia Central das SVMs

- A SVM escolhe o hiperplano que maximiza a margem entre as classes

- **Margem** → *Distância entre o hiperplano e os pontos mais próximos das classes*

- **Objetivo** → *Maximizar essa margem*

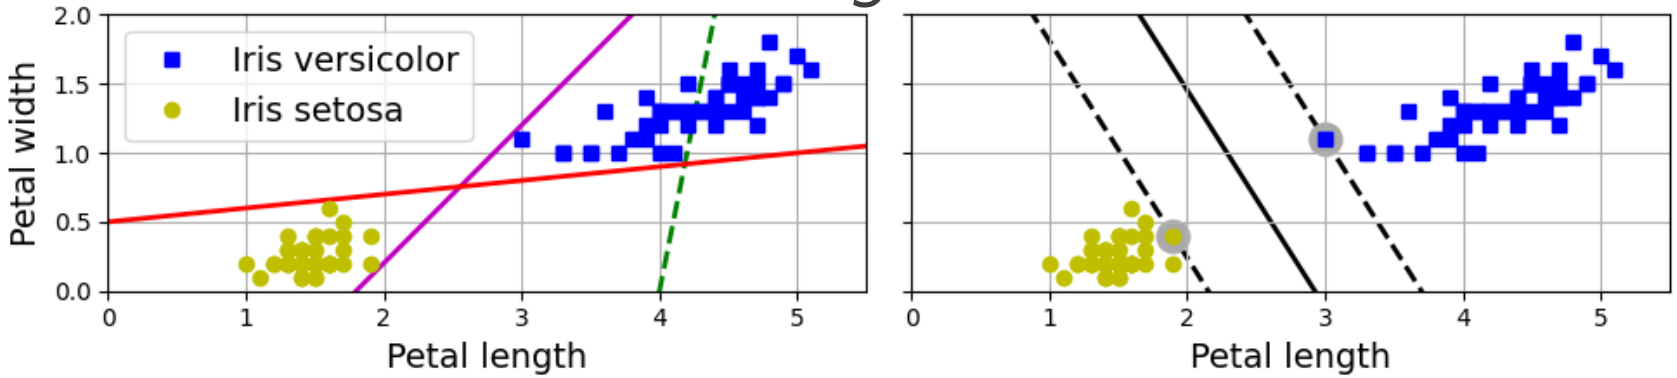

Intuição Geométrica

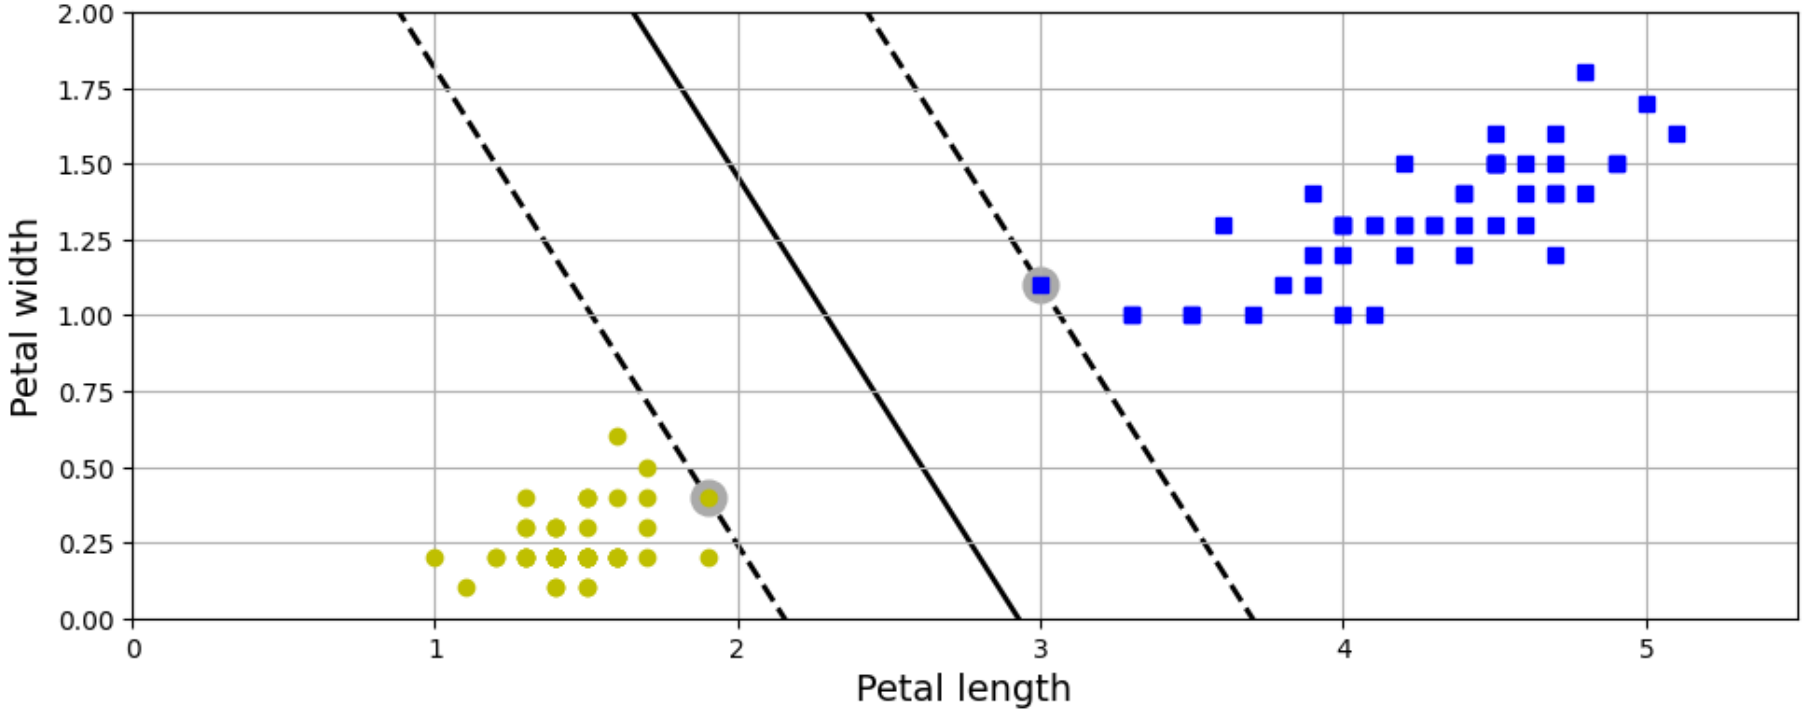

Modelos com margens maiores tendem a generalizar melhor

Vetores de Suporte

- **Vetores de Suporte**
  - São os pontos de dados mais próximos da fronteira de decisão

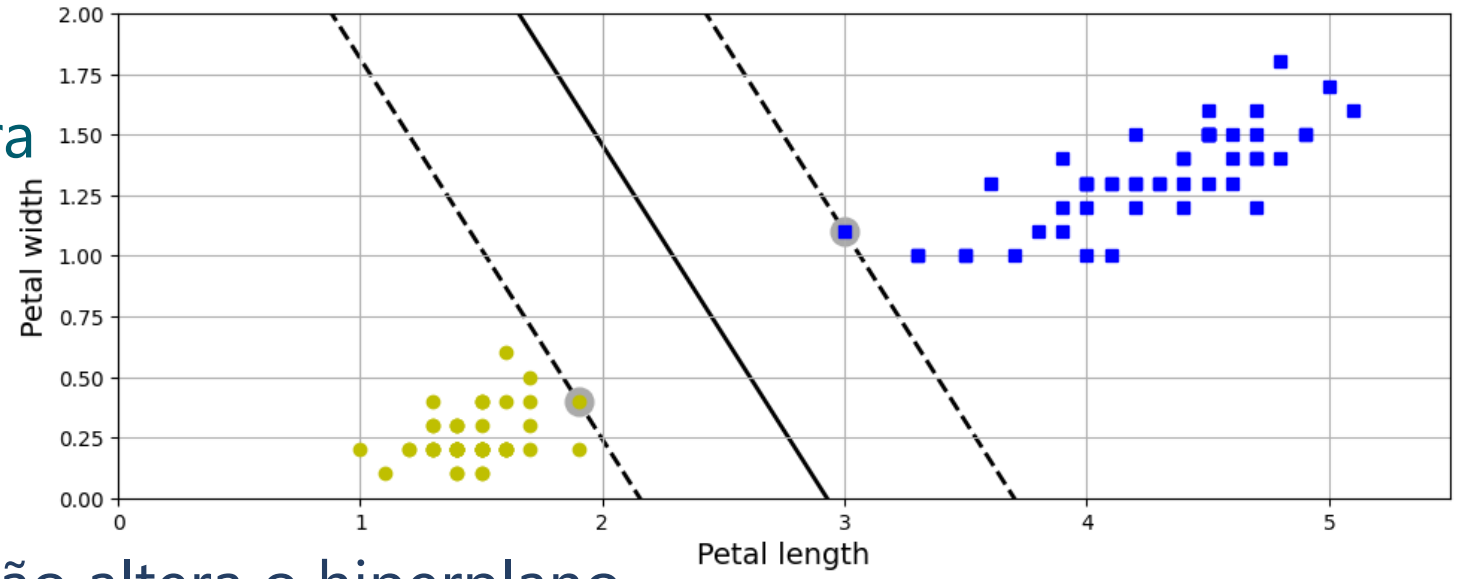

- **Características**
  - Determinam o modelo
  - Remover outros pontos não altera o hiperplano

A SVM depende apenas desses pontos

SVMs e Escalonamento

- **O SVM é sensível à escala das características**

Exemplo

- **Variável - Escala**
- Idade 20 – 80
- Salário 10.000 – 100.000

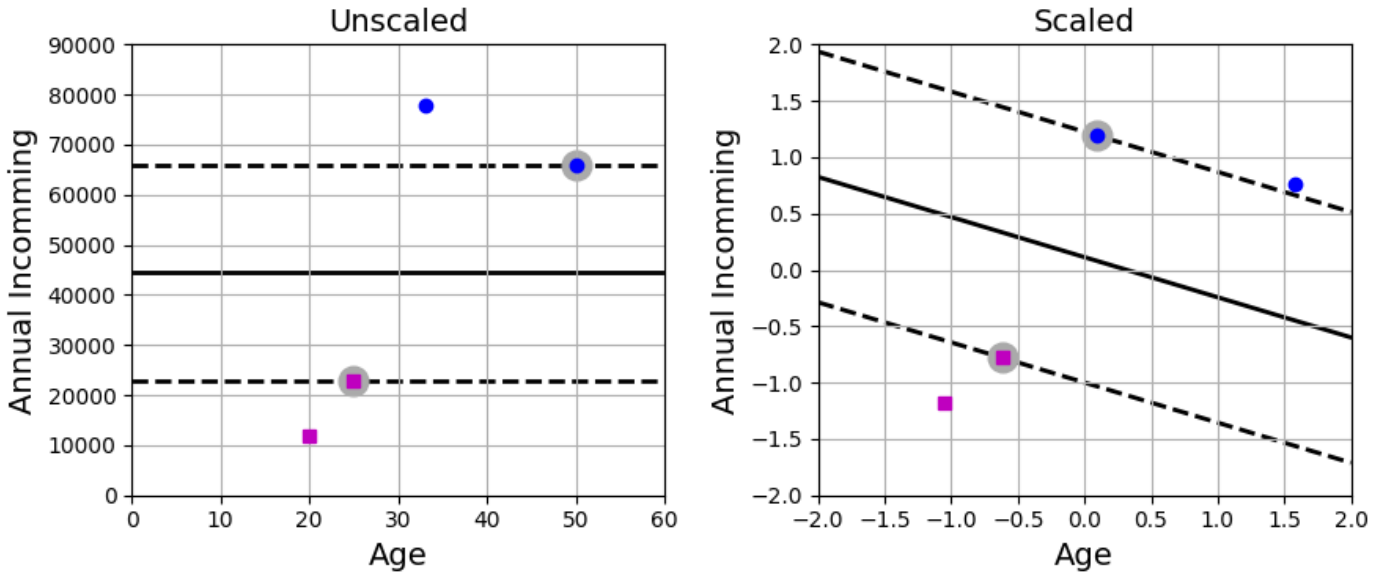

Nesse caso

- A variável **salário domina o cálculo**
- A fronteira de decisão pode ser distorcida

Margem Rígida (Hard Margin)

- **Hipótese**
  - Dados perfeitamente separáveis
  - Nenhuma violação permitida

- **Problema**
  - Sensível a ruído
  - Pouco realista

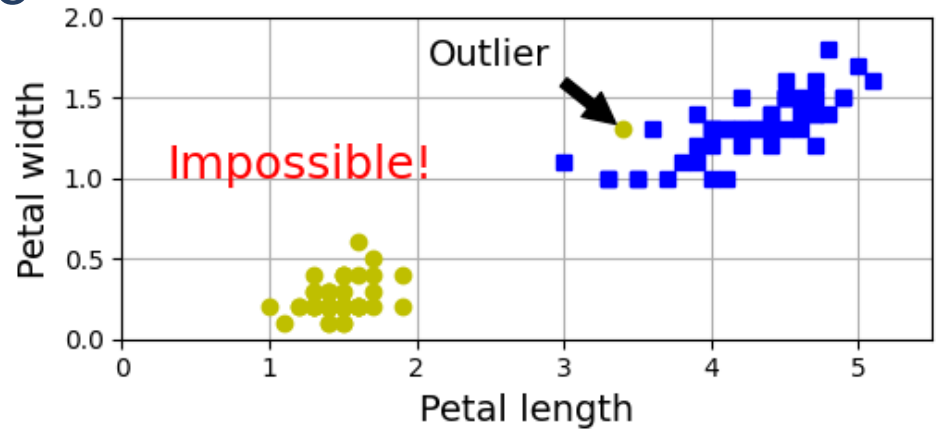

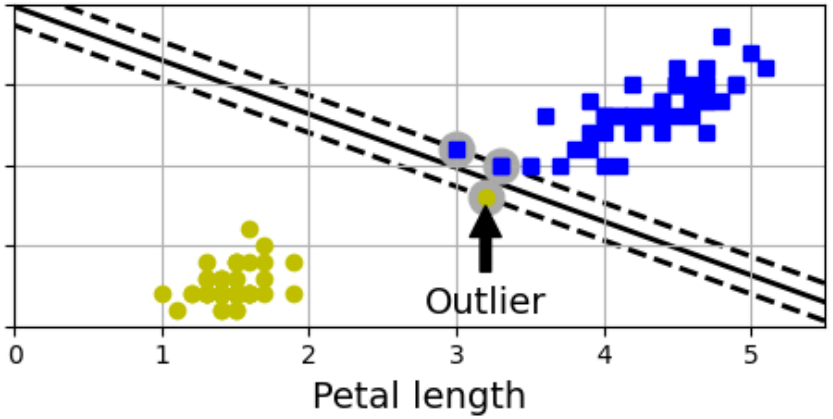

Margem Suave (Soft Margin)

- **Dica** → Equilíbrio entre manter a *"maior rua"* possível e limitar violações de margem

- **Como Resolver?**
  - Parâmetro de Regularização
    → **"c"** (Regressão Ridge – L2)

  - **Valores Menores**
    → Margem Alarga
    → Marior risco de Subajuste (underfitting)

  - **Valores Maiores**
    → Margem Estreita
    → Marior risco de Sobreajuste (overfitting)

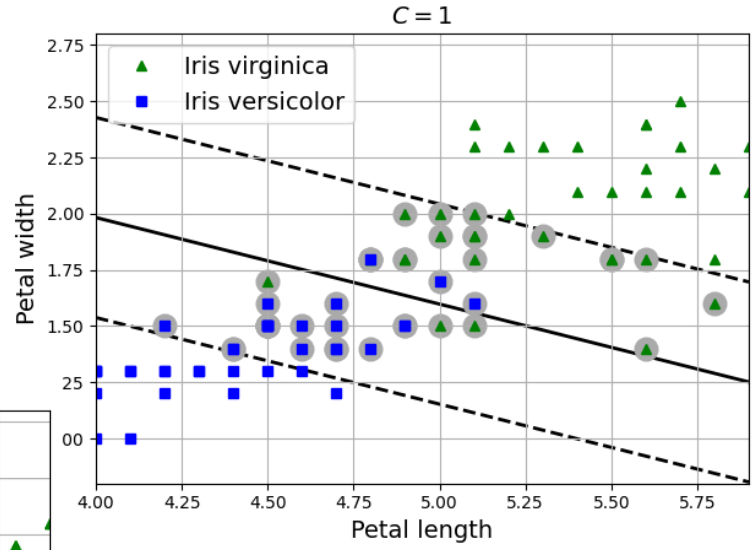

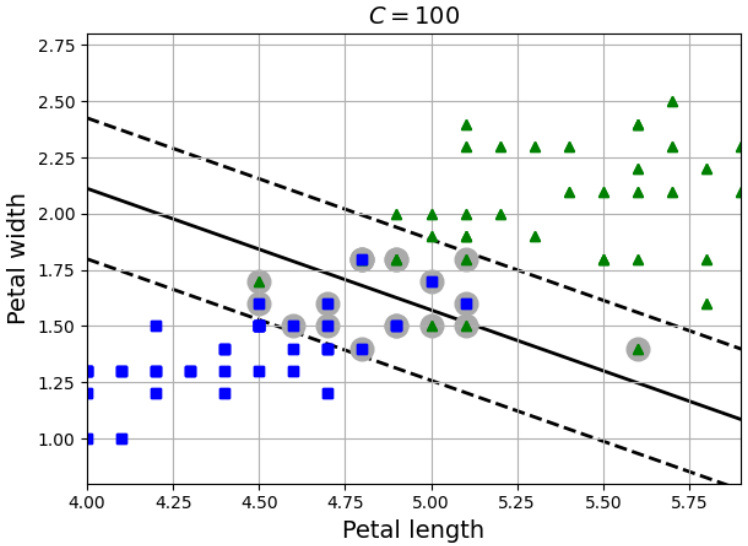

Demonstração

- **Notebook**
  Aulas 07 - Máquinas de Vetor de Suporte.ipynb
  - Classificação Linear da SVM

Quando os Dados Não São Lineares?

Nem sempre as classes são separáveis por uma **linha**

Exemplo

- Círculos Concêntricos
- Padrões Complexos

Como este problema pode ser resolvido?

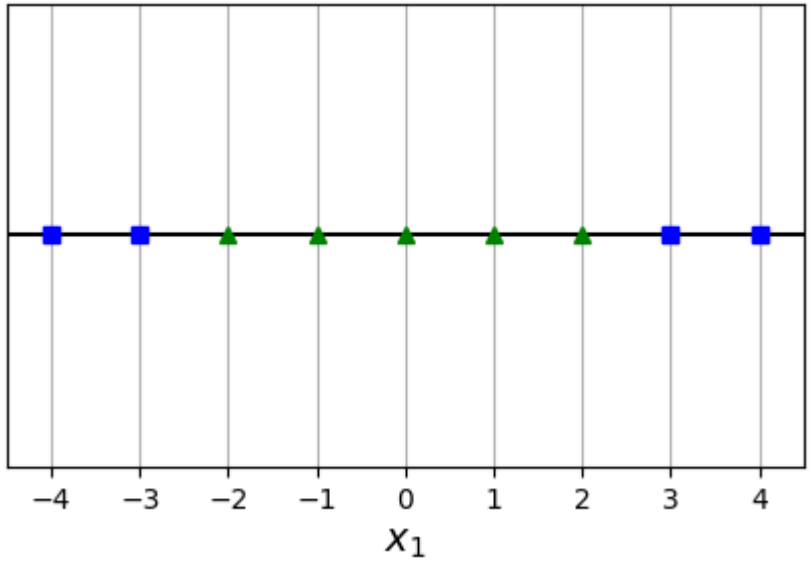

Transformação de Espaço de Características

Transformar os dados para um espaço de **maior dimensão**

Exemplo

- $x \rightarrow (x, x^2)$

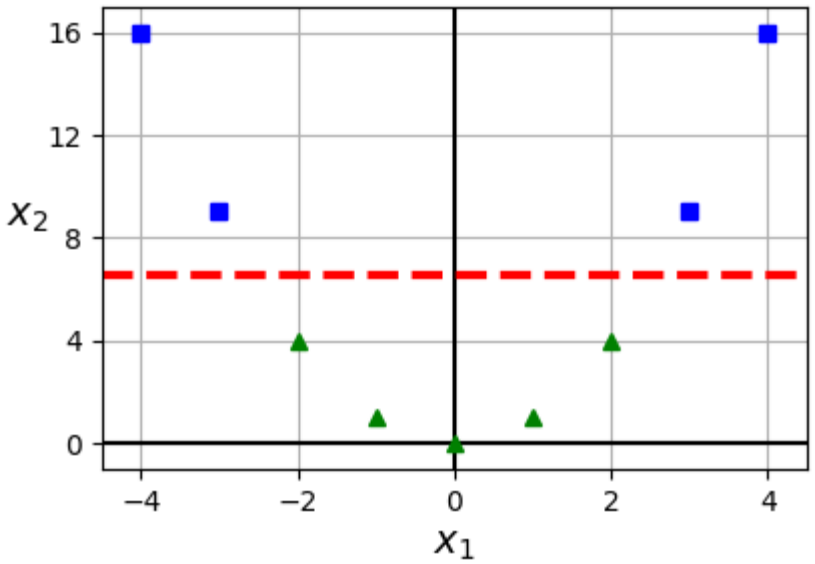

Isso pode tornar os dados **linearmente separáveis**

Existe alguma alternativa para resolver o problema, sem criar novas características?

O Truque do Kernel

Transformar explicitamente pode **ser caro**

Solução

- **Kernel Trick (Truque de Kernel)**

Permite calcular o produto interno no espaço transformado **sem calcular a transformação explicitamente**

Kernel Polinomial

- Exemplo de Modelo treinado com Grau 3 e com Grau 100
  - Quanto **maior** o **grau polinomial**, **maior** o **risco de sobreajuste**
  - O parâmetro **"coef0"** da classe SVC atua na **suavização da fronteira de decisão**

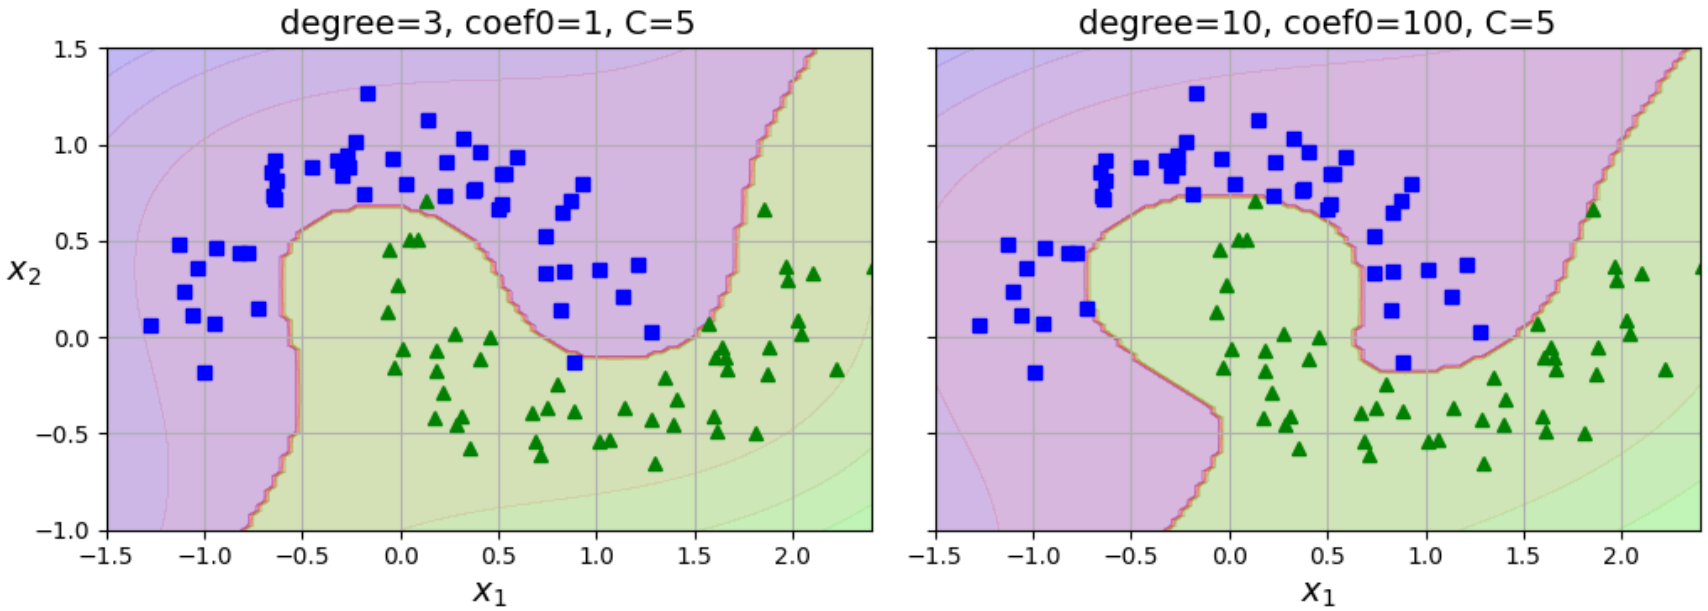

Kernel - RBF (Radial Basis Function)

- Base → Criação de **Características de Similaridade**
  - *"Pontos de Referência" calculados a partir de uma função de similaridade com uma função radial gaussiana*
  - *A função gaussiana gera gráfico em formato de sino e varia de 0 (muito longe do ponto de referência) e 1 (no ponto de referência)*

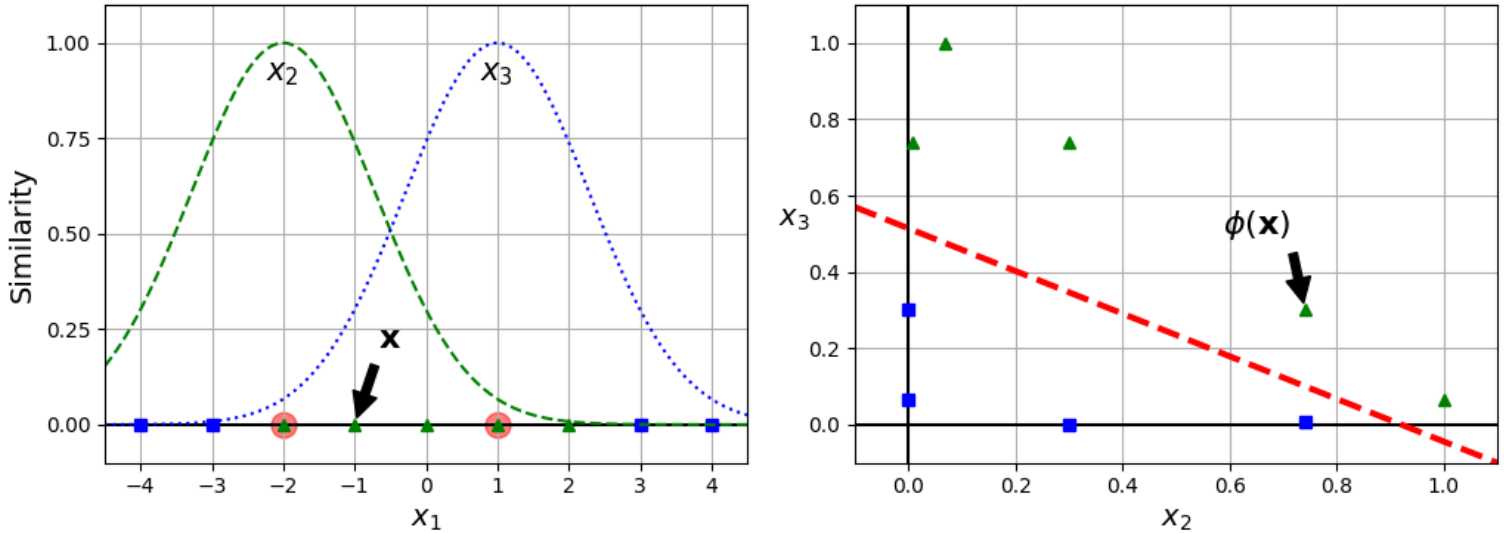

Kernel - RBF (Radial Basis Function) Parâmetros

- **gamma** - Controla o **alcance do intervalo de influência de cada ponto** (instância), definindo o quão "local" ou "global" é a fronteira de decisão
  - Atua como um parâmetro de regularização do modelo
  - Quanto maior o valor, menor a influência de cada ponto, deixando a fronteira de decisão mais irregular, aumentando o risco de overfitting
- **C** - Controla o **quanto o modelo é tolerante ao erro**.
  - Quanto maior o valor, menos o modelo tolera erros, o que aumenta o risco de overfitting

Kernel - RBF (Radial Basis Function) Parâmetros

gamma	C	Efeito
Baixo	Baixo	Underfitting
Baixo	Alto	Fronteira rígida e global
Alto	Baixo	Curvas locais controladas
Alto	Alto	Overfitting

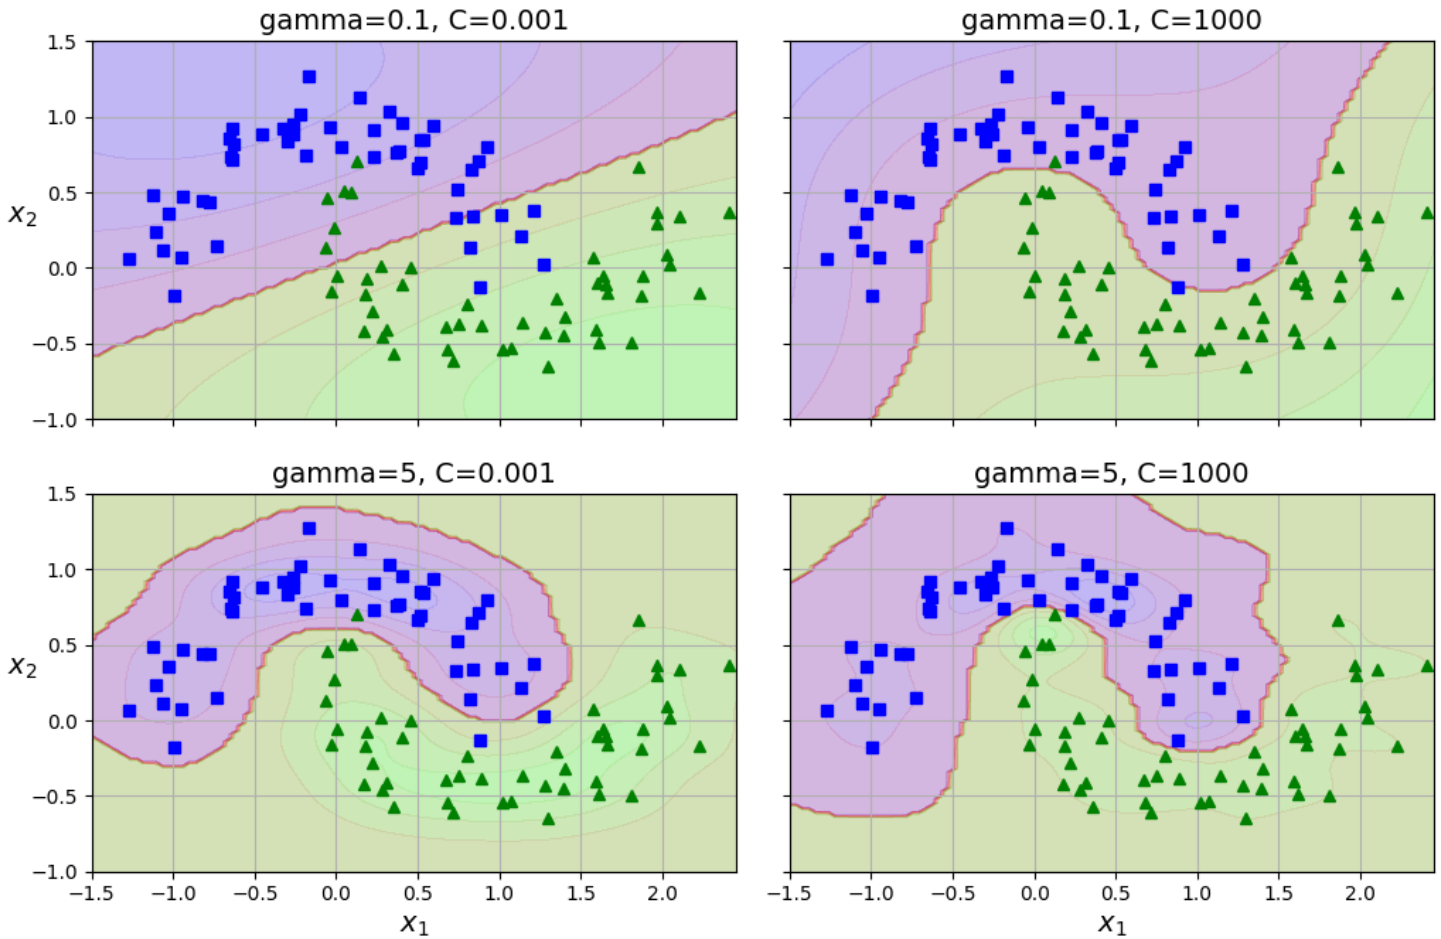

Demonstração

- **Notebook**
  Aulas 07 - Máquinas de Vetor de Suporte.ipynb
  - Classificação SVM Não Linear

Quando Usar SVM?

- **Recomendado nesta Situação**
  - Dataset Médio
  - Margens claras entre classes
  - Espaço de características moderado
- **Menos Eficientes quando**
  - Datasets muito grandes

LinearSVC vs SVC vs SGDClassifier e Complexidade Computacional

LinearSVC

- Implementação otimizada para **SVM linear**, pensada para **alto desempenho**, biblioteca liblinear

- **Uso indicado para**
  - Dados são aproximadamente Lineares
  - Dataset Grande
  - Performance é Prioridade
  - Muitas Features/Características
  - Mais rápida e econômica em memória

- **Limitações**
  - Não aceita kernel trick
  - Não fornece probabilidades diretamente
  - Menos flexível

LinearSVC vs SVC vs SGDClassifier e Complexidade Computacional

SVC

- Implementação **clássica e completa de SVM** no scikit-learn, baseado na libsvm e suporta **Kernel Trick**

- **Uso indicado para**
  - Dados são não lineares
  - Dataset é pequeno ou médio
  - Você precisa de kernels como RBF
  - Pode precisar calcular probabilidades

- **Limitações**
  - Custo computacional alto
  - Escala mal para datasets grandes
  - Uso intenso de memória (matriz de kernel)

LinearSVC vs SVC vs SGDClassifier e Complexidade Computacional

SGDClassifier

- **Classificador linear genérico**, que pode treinar vários modelos diferentes apenas mudando a **função de perda (loss)**
- Realiza **classificação de margem grande por padrão**, mas permite ajustes através de seus parâmetros de regularização

- **Uso indicado para**
  - Dataset é muito grande
  - Dados chegam em fluxo
  - Treino precisa ser rápido
  - Aceita solução aproximada

- **Limitações**
  - Treinamento mais instável Sensível a: Taxa de aprendizado; Regularização; Número de épocas e resultado depende da ordem dos dados

- ***Requer mais cuidado no Tuning*** ⚠

SVM também pode fazer Regressão?

Support Vector Regression (SVR)

Ideia

- Até agora vimos SVM para **classificação**
- Mas também podemos usar SVM para **regressão**

Diferença principal

- **Classificação** → Separa Classes
- **Regressão** → Aproxima Valores Contínuos

Intuição da SVR

Objetivo

- Encontrar uma função que
  - Se aproxime dos dados
  - Manter uma **margem de tolerância**
  - Visualmente, a função encontra uma ***rua*** ou ***tubo*** por onde os dados passam

Conceito-chave

- Em vez de minimizar erro diretamente, a SVR tenta:
  - Manter os erros dentro de uma "**faixa aceitável**"

Margem de Tolerância (ε-insensitive)

Ideia central

- Definimos uma margem → ε (épsilon)
  - Erros menores que ε → **ignorados**
  - Erros maiores que ε → **penalizados**

Visualmente

- "Tubo" em torno da função
- pontos dentro do tubo → ok
- pontos fora → penalizados

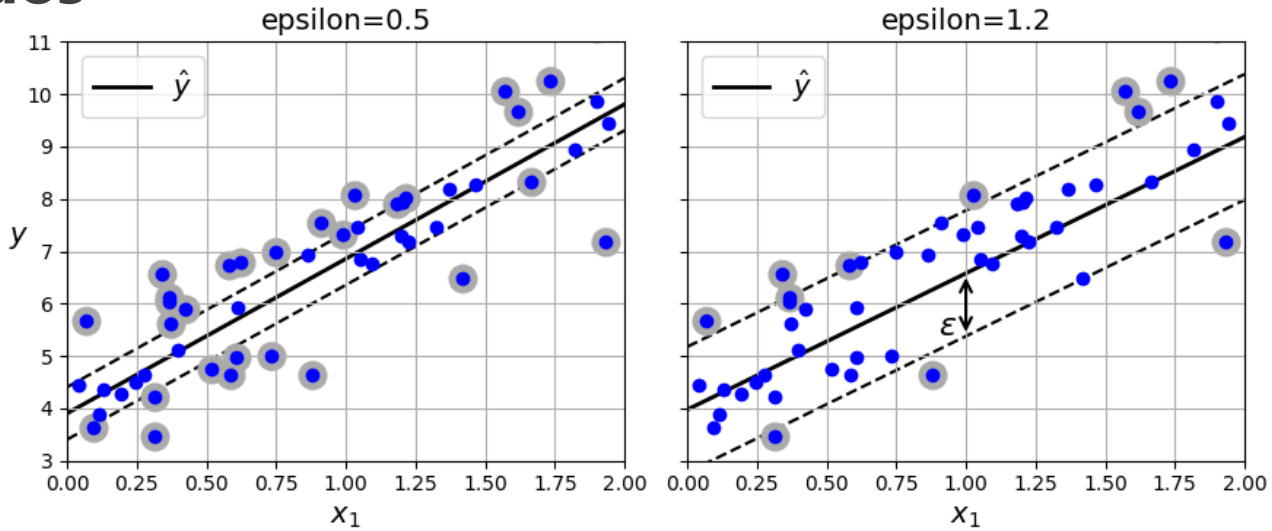

Vetores de Suporte na Regressão

Assim como na classificação

- Apenas alguns pontos influenciam o modelo
- São os pontos **fora da margem ε**

Quanto mais pontos fora da margem, mais complexo o modelo

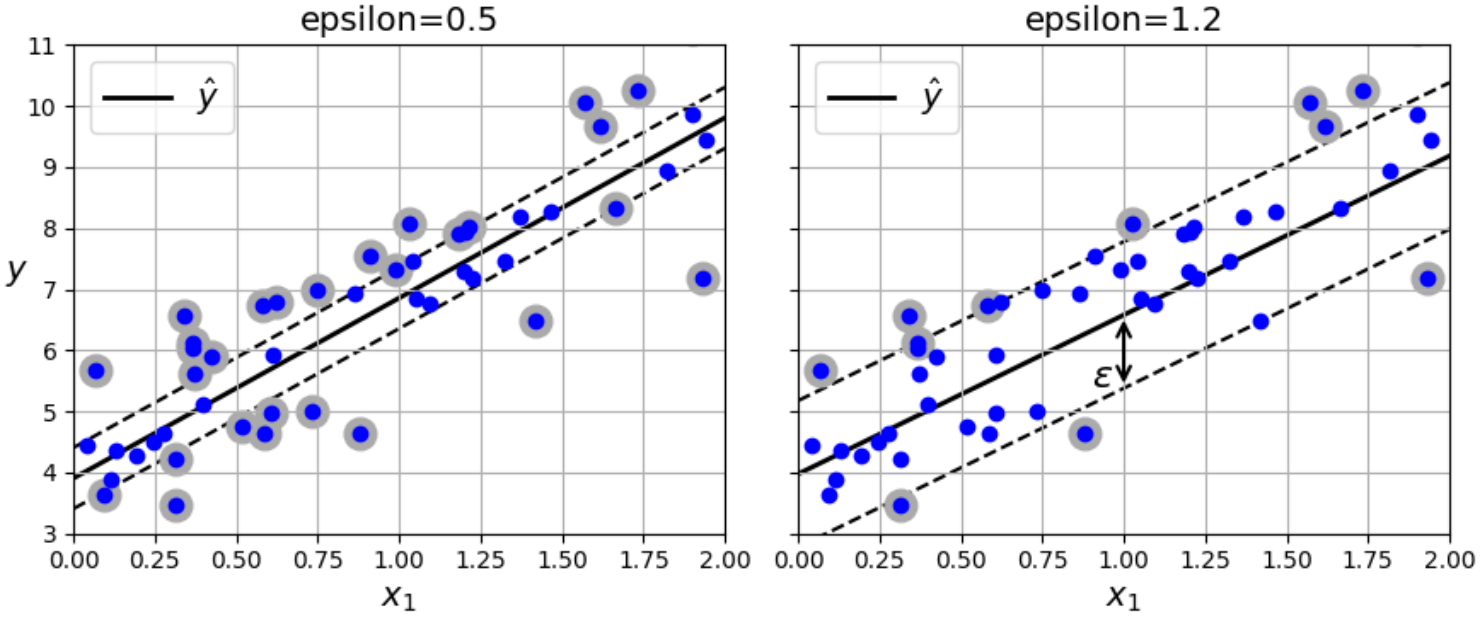

Parâmetros Importantes da SVR

- **ε (epsilon)**
  - Define largura da margem
  - Controla tolerância ao erro
- **C (regularização)**
  - Penaliza erros fora da margem
  - Controla complexidade do modelo
- **γ (gamma) - (kernel RBF)**
  - Controla influência dos pontos
  - Impacto na curvatura da função

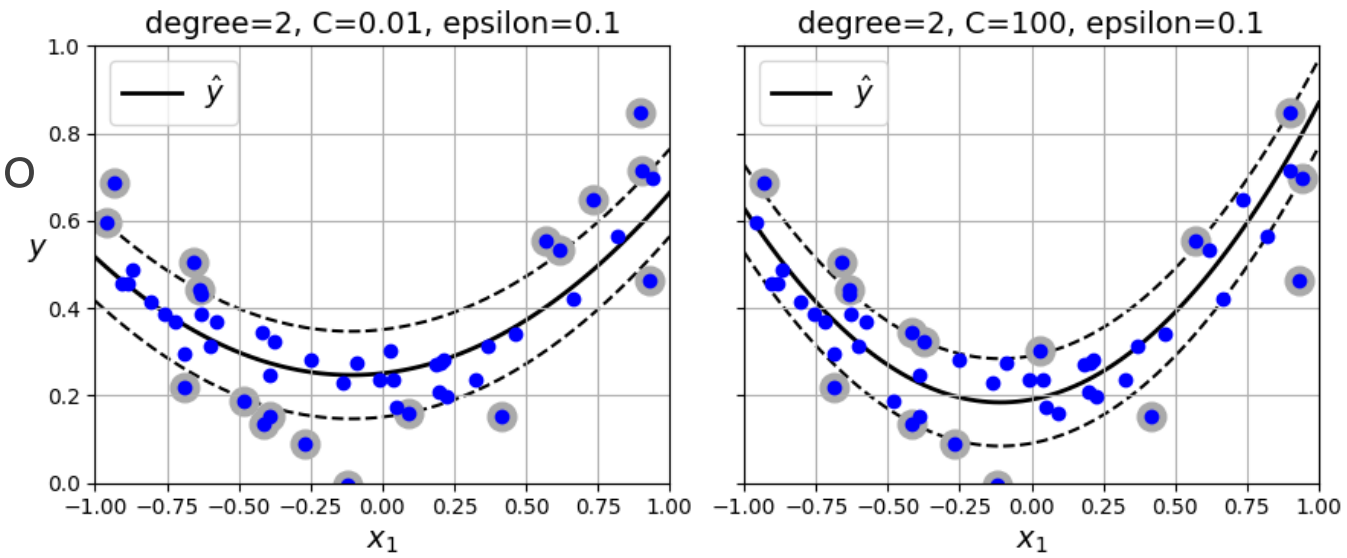

Demonstração

- **Notebook**
  Aulas 07 - Máquinas de Vetor de Suporte.ipynb
  - Regressão SVM

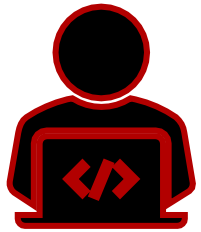

Kernel na Regressão

Assim como na classificação

- **Linear** → Relação simples
- **Polinomial** → Relações não lineares
- **RBF** → Alta flexibilidade

SVR com kernel RBF pode modelar

- Curvas Complexas
- Padrões não lineares

Vantagens

- Robusto a Outliers (com ε adequado)
- Controla complexidade
- Funciona bem com datasets pequenos/médios

Limitações

- custo computacional alto
- Difícil ajuste de hiper parâmetros

Encerramento

- Foco de Hoje → **Compreender as Máquinas de Vetores de Suporte (SVMs), sua gama de parametrizações e aplicações, tanto para solução de problemas de Classificação, como para Regressão**

- Agora nossa caixa de ferramentas já está começando a ter peso, e a consolidação do conhecimento, com a **PRÁTICA** cada vez mais passa a ser importante, principalmente para aprender a **escolher a ferramenta** mais adequada ao problema

- Próxima aula → ***Árvores de Decisão***