Árvores de Decisão

Prof. Milton Roman de Brito

Fatec Votorantim Benedicto Pagliato
Centro Paula Souza

Objetivo

Ao final da aula, vocês devem ser capazes de:

- Relacionar a definição de regras simples em Árvores
- Compreender como métricas de impureza definem os critérios de decisão
- Avaliar e atuar nos hiper parâmetros de regularização para evitar Sobreajuste e melhorar generalização em Árvores de Decisão
- Aplicar Árvores de Decisão em modelos de Classificação e Regressão
- Ser capaz de identificar vantagens e principalmente, as limitações de Árvores de Decisão

Conteúdo da Aula

- Introdução à Árvores de Decisão
- Impureza de Gini vs Entropia
- Impacto da regularização e hiper parâmetros
- Aplicação de Árvores de Decisão para Regressão
- Vantagens e Limitações de Árvores de Decisão

Árvores de Decisão - Intuição e Motivação

Classificação baseada em Regras Simples e Interpretáveis

Como humanos tomam decisões?

- **Idade > 30?**
- **Renda > X?**

Modelos podem aprender ***regras de decisão automaticamente***

O que é uma Árvore de Decisão?

Estrutura em forma de Arvore

- Nó raiz → ***Nível 0***
- Nós internos → ***Decisões***
- Folhas → ***Respostas → Previsões***

Pode ser usada para

- **Classificação**
- **Regressão**

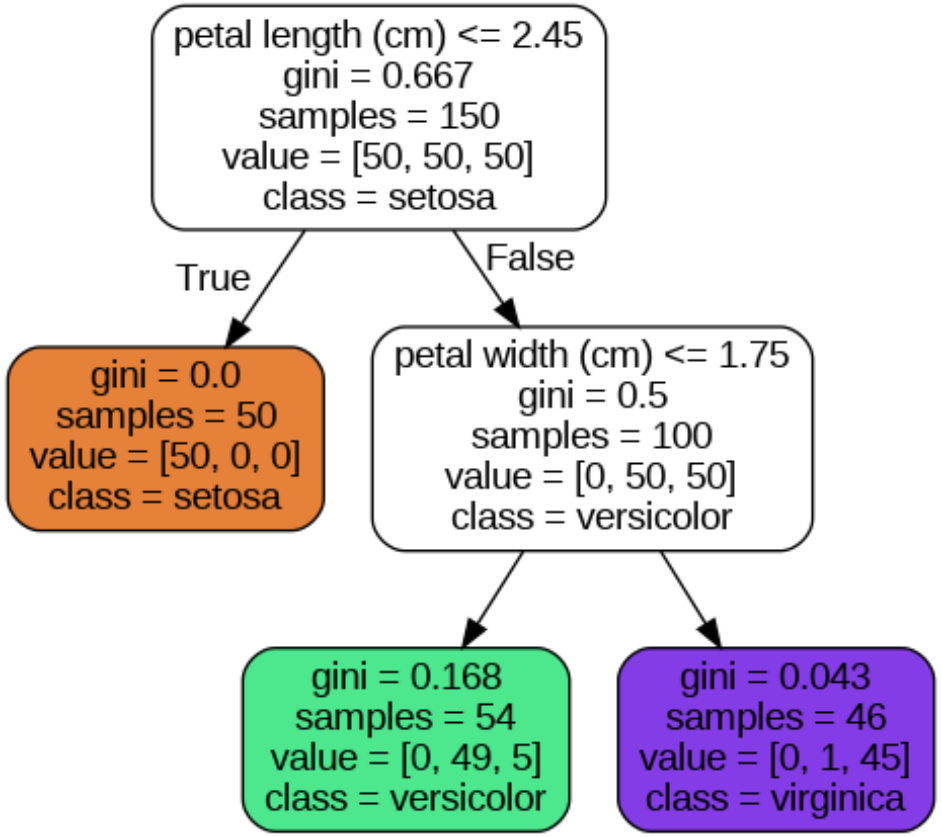

Como a Árvore Aprende?

Como o modelo decide os cortes?

- Testa várias divisões possíveis
- Escolhe a melhor separação

- **Baseado em**
  - Pureza dos grupos

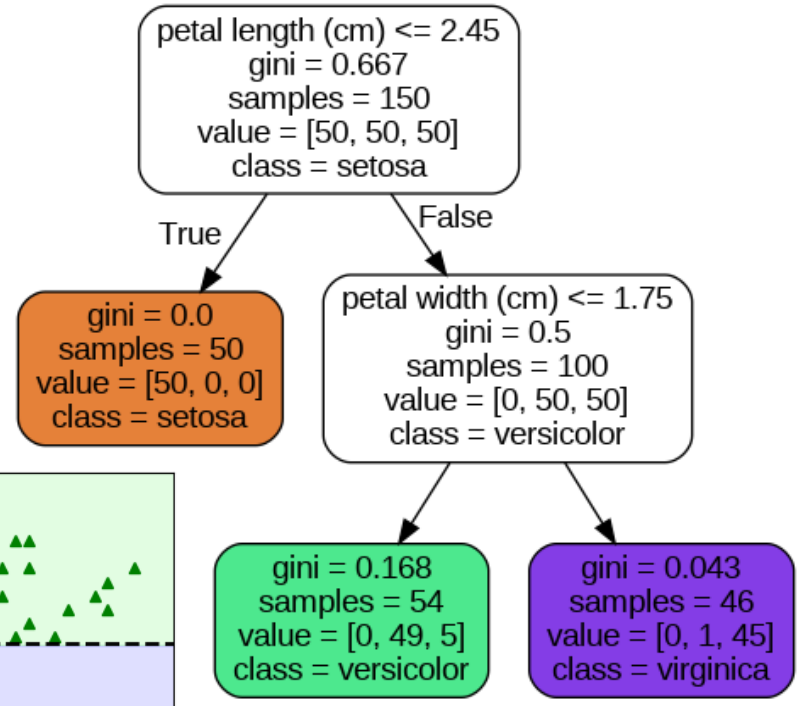

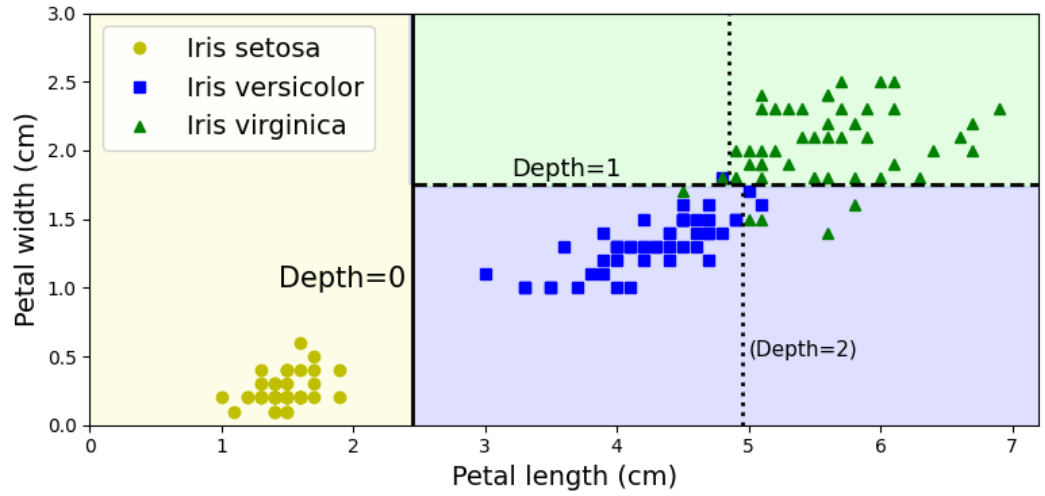

Impureza de Gini e Entropia

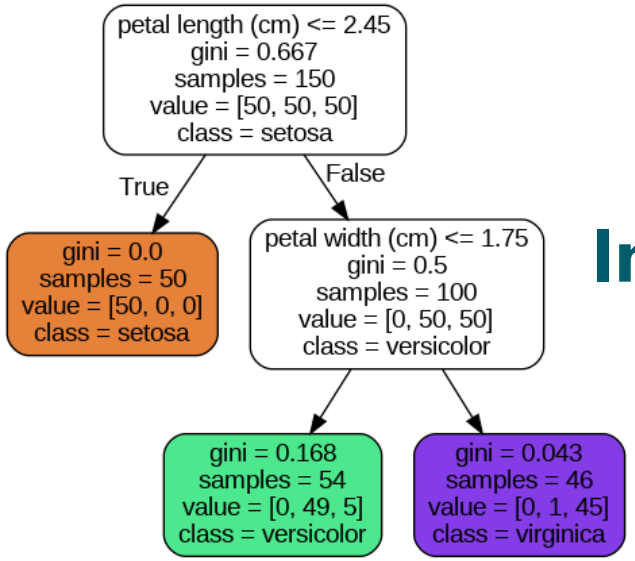

Impureza de Gini → Mede quão "misturado" está um nó

- **0** → puro
- **maior valor** → mais misturado

Entropia → Mede desordem

- **Baixa entropia** → organizado
- **Alta entropia** → confuso

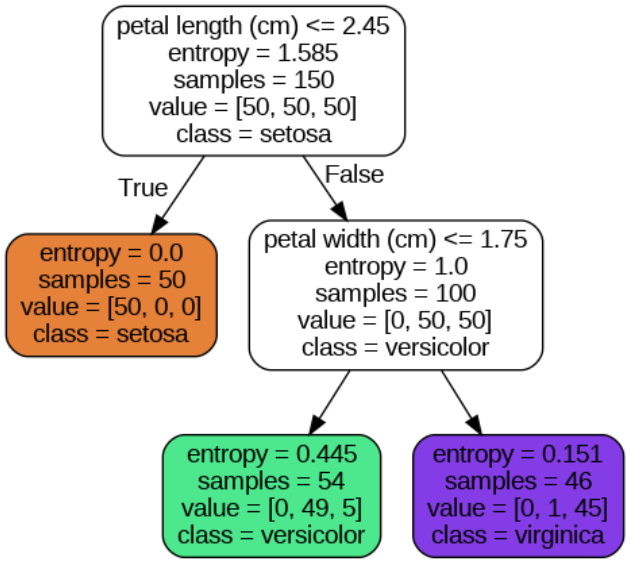

Impureza de Gini vs Entropia

Ambos medem impureza, resultados geralmente similares

Gini → mais comum (padrão)

- Um pouco mais rápido de calcular, é um bom padrão

Entropia → interpretação mais teórica

- Tende a produzir árvores um pouco mais equilibradas

É possível definir a métrica de impureza, através do hiper parâmetro 'criterion' na classe 'DecicionTreeClassifier'

Critério de Divisão

Critério de Divisão

- O modelo calcula/escolhe a divisão que **mais reduz a impureza** para cada ramo da árvore

- Nome técnico
  - **Ganho de informação**

Mas afinal, o que é a impureza?

Demonstração

- **Notebook**
  Aulas 08 - Árvores de Decisão.ipynb
  - Treinando e Visualizando uma Árvore de Decisão

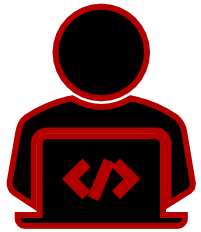

Overfitting e Regularização

Árvore muito profunda → Overfitting

- Aprende ruído
- Perde generalização

Generalização vs **Memorização**

Árvore simples vs **Árvore complexa**

Técnica para evitar → **Poda (Pruning)**

- **Objetivo** → Reduzir complexidade da árvore
  - **Pré-poda** → Definir limites antes
  - **Pós-poda** → Reduzir depois

Exemplo Visual

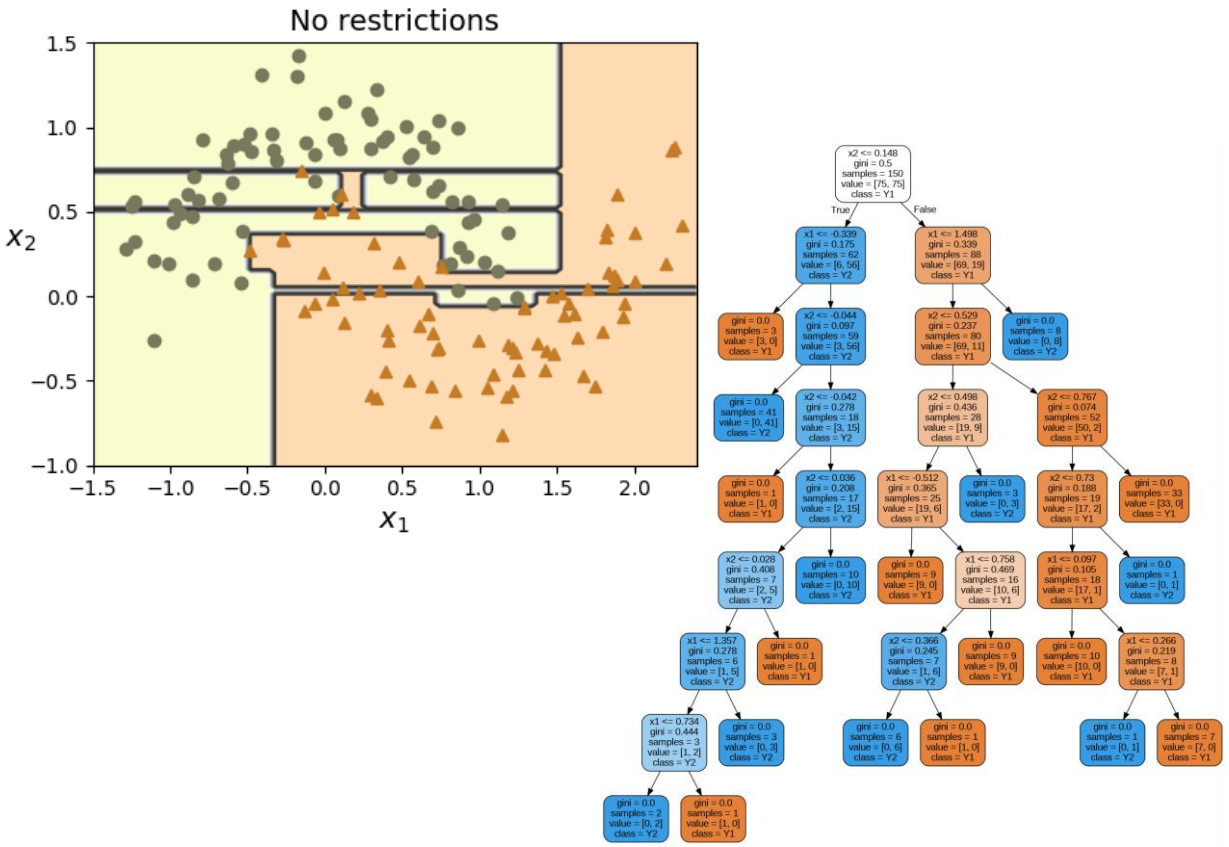

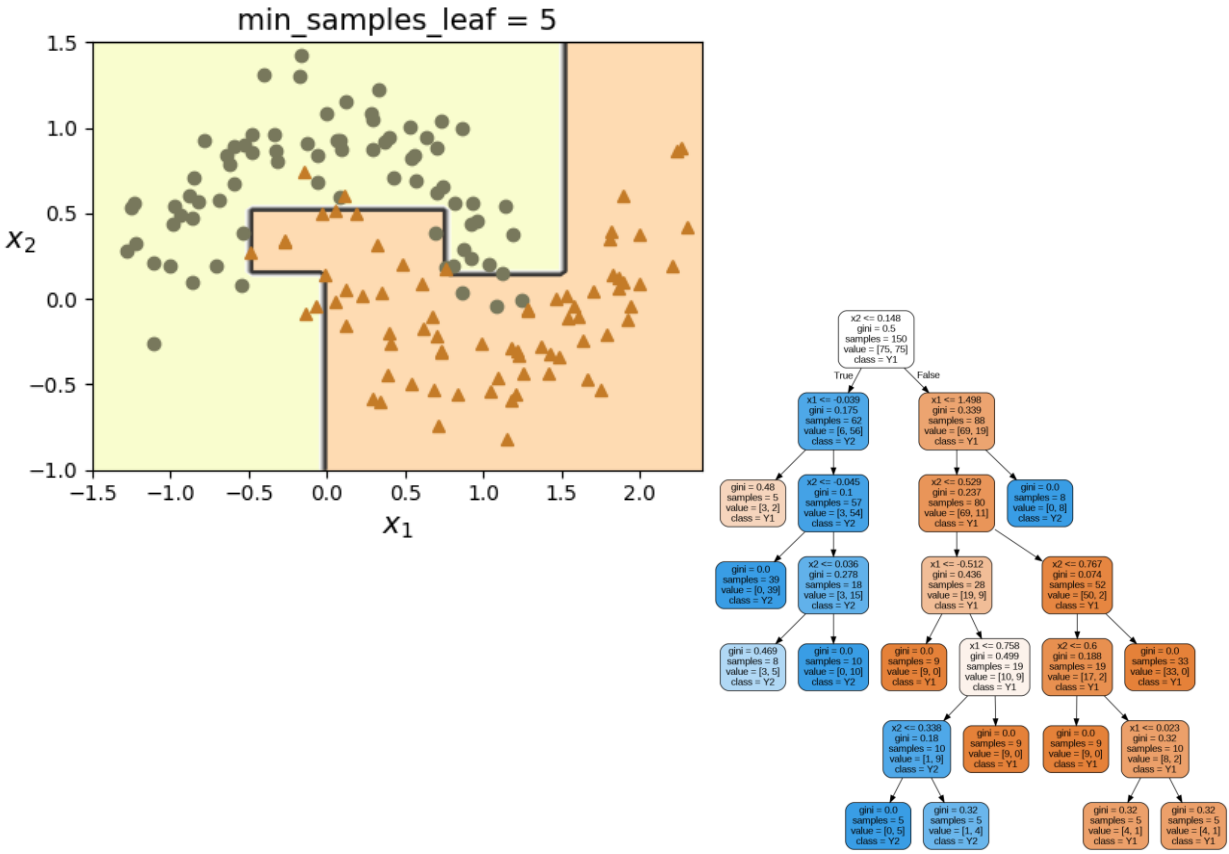

Como controlar o Overfitting?

Principais parâmetros

- **max_depth** → *Profundidade Máxima*
- **min_samples_split** → *Número mínimo de amostras, antes de ser dividido*
- **min_samples_leaf** → *Número mínimo de amostras para que um nó-folha seja criado*

Outros parâmetros

- **max_features** → *Número máximo de características avaliadas para dividir em cada nó*
- **max_leaf_nodes** → *Número máximos de nós-folha da árvore*

Demonstração

- **Notebook**
  Aulas 08 - Árvores de Decisão.ipynb
  - Overfitting e Hiper Parâmetros de Regularização

Regressão com Árvores

Árvores de Regressão

- Em vez de Classes → Valores Contínuos

Como funciona?

- Divide o espaço
- Cada folha retorna → Média dos valores

Regressão com Árvores
Exemplo Visual - Árvore

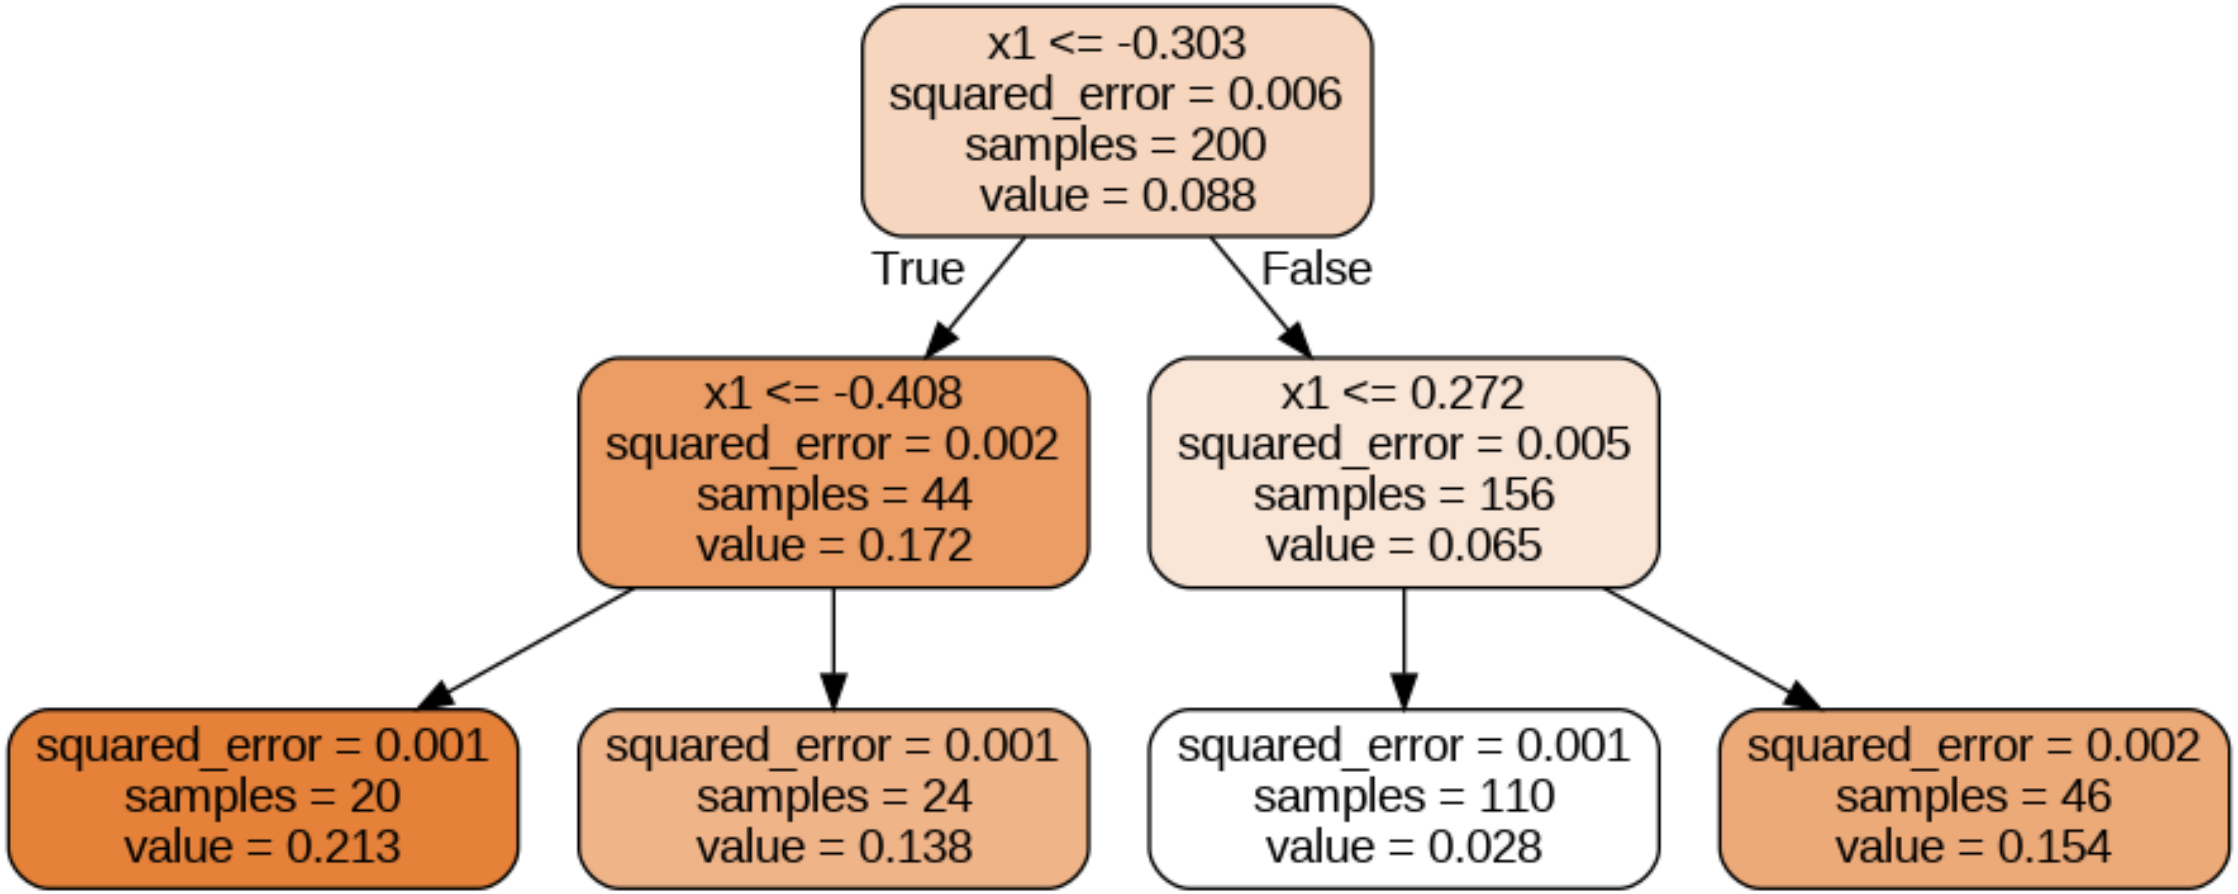

Regressão com Árvores
Exemplo Visual - Gráfico

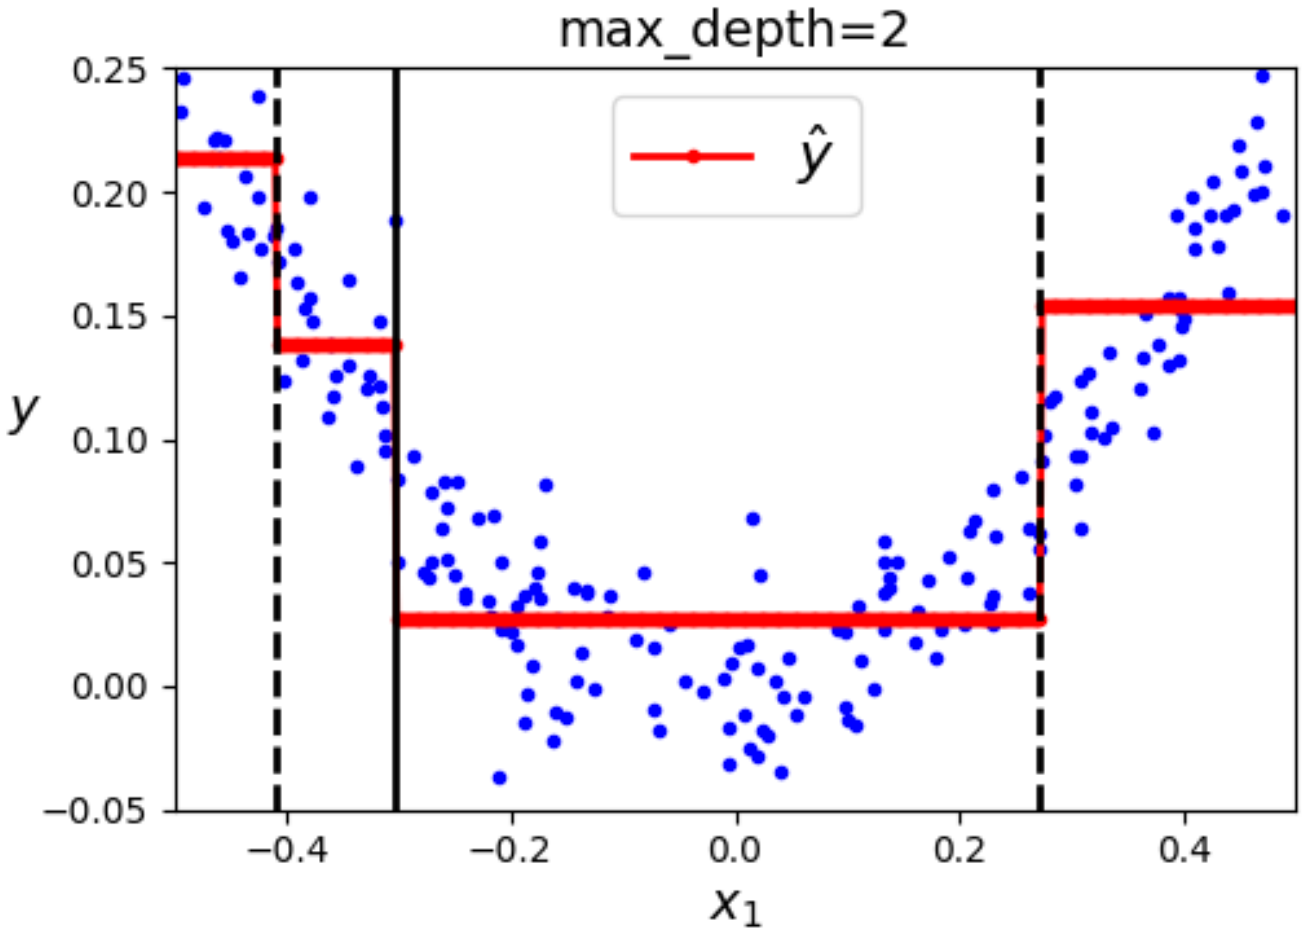

Demonstração

- **Notebook**
  Aulas 08 - Árvores de Decisão.ipynb
  - Regressão com Árvores

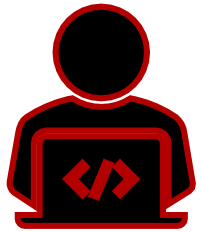

Vantagens das Árvores de Decisão

- **Fácil interpretação** → Simples para entender e aprender
- **Pouca preparação de dados** → Simplicidade no pré-processamento
- Funciona bem com dados não lineares

Limitações das Árvores de Decisão

- Sensível a pequenas variações
- Pode sobreajustar facilmente
- **Sensibilidade à Orientação do Eixo das Informações**
- **Alta Variância na executar de novos treinamentos**

Isso leva ao uso de ***Ensemble (próxima aula)*** ⚠

Demonstração

- **Notebook**
  Aulas 08 - Árvores de Decisão.ipynb
  - Vantagens e Limitações

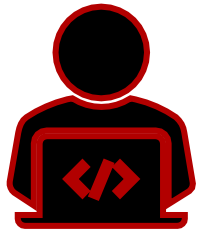

Encerramento

- Foco de Hoje → **Árvores de decisão aprendem regras baseadas em divisões sucessivas dos dados para fazer previsões interpretáveis**

- **Pratique!**
  - Teste diferentes profundidades de árvore
  - Compare Gini vs Entropia
  - Observe overfitting na prática

- Próxima aula → **Aprendizado Ensemble e Florestas Aleatórias**