Aprendizado Ensemble e Florestas Aleatórias

Prof. Milton Roman de Brito

Fatec Votorantim Benedicto Pagliato
Centro Paula Souza

Objetivo

Ao final da aula, vocês devem ser capazes de:

- Compreender o conceito de Aprendizado Ensemble e suas aplicações
- Diferenciar os tipos de Classificadores por Voto
- Desenvolver modelos aplicando os conceitos de Bagging e Pasting
- Aplicar todos os conceitos aprendidos para implementar modelos de Florestas Aleatórias
- Compreender a relação entre Florestas Aleatórias e as Características do Datase

Conteúdo da Aula

- Aprendizado Ensemble
- A Moeda Tendenciosa
- Classificadores por Voto
- Bagging e Pasting
- Avaliação Out of Bag (OOB)
- Florestas Aleatórias
- Importância das Características
- Vantagens e Limitações

Aprendizado Ensemble - Intuição e Motivação

Um único modelo é sempre a melhor escolha?

- E se combinarmos vários modelos? Podemos melhorar o resultado?

- **Ensemble** → Combinação de vários modelos

Objetivo

- Melhorar desempenho e robustez

Aprendizado Ensemble e Árvores Aleatórias – A sabedoria da multidão!

- **Um Especialista** → Pode errar
- **Vários Especialistas** → Decisão mais confiável

Quando Ensemble funciona bem?

- Modelos diversos
- Erros não correlacionados

A Moeda Tendenciosa

E se tivermos uma moeda levemente tendenciosa? ***Que dá "cara" 51% das vezes****?*

Se jogarmos essa moeda

- **1 vez** → Qual seu palpite, "cara" ou "coroa"?
- **10 vezes** → Vai dar mais "cara" ou "coroa"?
- **1000 vezes** → E agora?

Mesmo com uma pequena vantagem, o resultado começa a se tornar previsível com muitas repetições

A Moeda Tendenciosa
10 Séries de 1000 Lançamentos

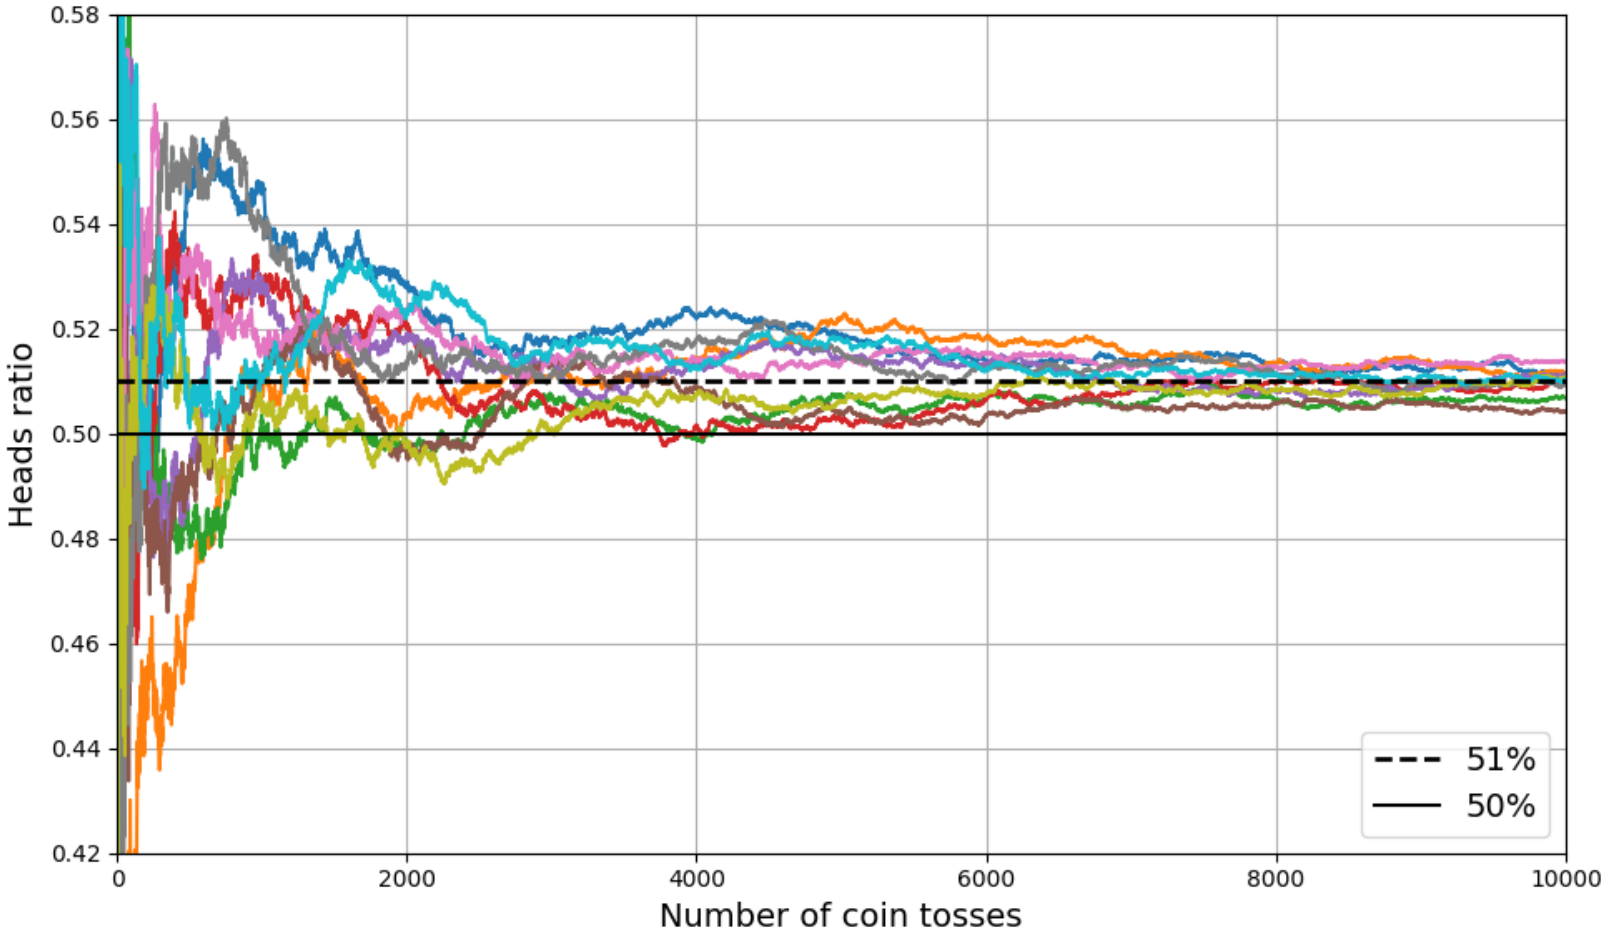

Classificador por Voto

- **Combina previsões de vários modelos**

- Tipos
  - **Hard Voting** → Maioria das Classificações
    - Simples
    - Usa Classes
  - **Soft Voting** → Média das Probabilidades
    - Usa probabilidades
    - Geralmente melhor

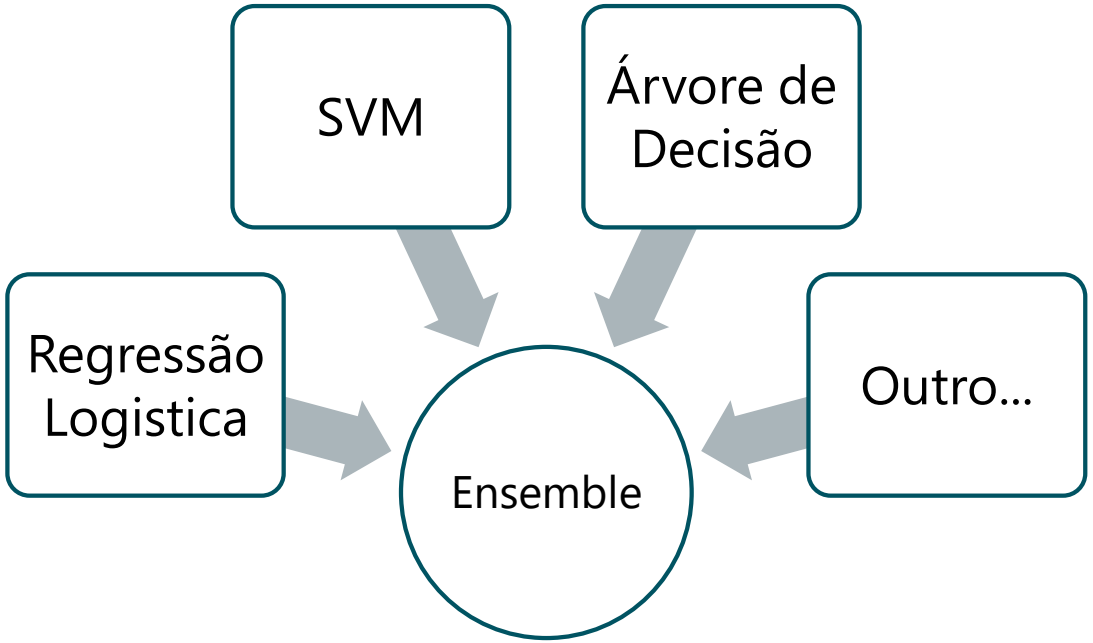

Demonstração

- **Notebook**
  Aulas - 09 - Ensemble a Florestas Aleatórias.ipynb
  - A Moeda Tendenciosa

Bagging e Pasting
Intuição

Outra abordagem para Aprendizado Ensemble

- Aqui é utilizado o mesmo algoritmo de treinamento, mas com diferentes amostras do dataset

Intuição

- Cada modelo vê um "pedaço diferente"
- Erros se compensam

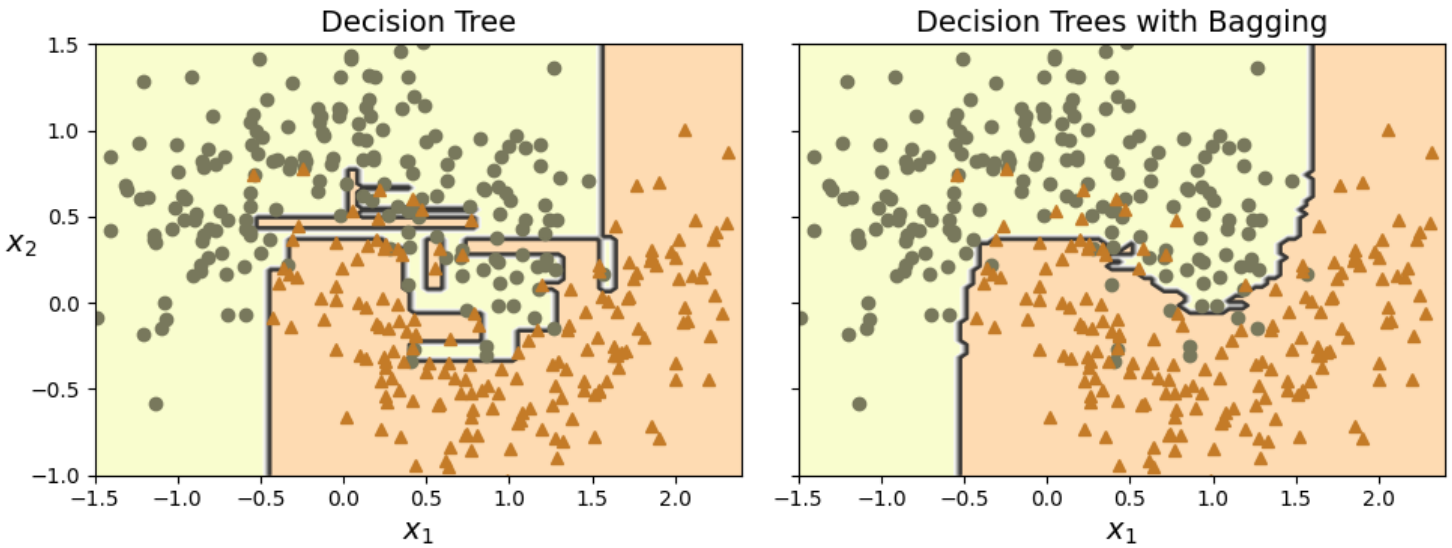

Bagging e Pasting

Bagging (Bootstrap Aggregating)

- Utiliza reposição de amostras (a mesma instância pode ser utilizada por mais de um dos modelos de treinamento)

- **Pasting**
  - Sem reposição de Amostras

Qual Utilizar?

- Em geral, o Bagging apresenta um viés um pouco mais alto e Pasting uma variância maior
- Na maioria dos casos, Bagging tem um desempenho melhor, mas é possível utilizar Validação Cruzada para escolher qual estratégia funciona melhor

Avaliação Out-of-Bag (OOB)

Revisando

- No Bagging, cada preditor utilizará uma parte das instâncias, em torno de 63%

Instâncias não utilizadas no treino

- São utilizadas para validação e calculo de acurácia
- Sem necessidade de utilizar o Conjunto de Dados de Validação

Florestas Aleatórias (Random Forests)

O que é Random Forest?

- Conjunto de Árvores de Decisão
- Baseado em Bagging + aleatoriedade extra

Aleatoriedade Extra → Seleção aleatória de Atributos em cada split

- Reduz correlação entre árvores
- Aumenta diversidade

Importância das Características

Treinamento de Floresta Aleatória → **Mede importância de cada Característica**

Como isso acontece?

- Quanto uma **Característica reduz impureza**
- Média ao longo dos nós das Árvores
- É obtido um **Ranking das Características**

Demonstração

- **Notebook**
  Aulas - 09 - Ensemble a Florestas Aleatórias.ipynb
  - Bagging e Pasting

Vantagens e Limitações

Vantagens

- Alta performance
- Menos overfitting que Árvores Isoladas
- Pouca necessidade de Tuning

Limitações

- Menos interpretável
- Maior custo computacional

Comparação

- **Árvore** → Interpretável
- **Random Forest** → Mais Precisa

Encerramento

- Foco de Hoje → **Modelos ensemble combinam múltiplos modelos para reduzir erros e melhorar a capacidade de generalização**

- **Pratique!**
  - Compare árvore única vs Random Forest
  - Teste diferentes quantidades de árvores
  - Explore importância das features

- Próxima aula → **Redução de Dimensionalidade**