Redução de Dimensionalidade

Prof. Milton Roman de Brito

Fatec Votorantim Benedicto Pagliato
Centro Paula Souza

Objetivo

Ao final da aula, vocês devem ser capazes de:

- Entender o problema da alta dimensionalidade
- Compreender o conceito de Projeção de Dados
- Explicar intuitivamente o PCA
- Aplicar PCA em problemas reais
- Interpretar variância explicada

Conteúdo da Aula

- O problema da Alta Dimensionalidade
- Motivação para Redução de Dimensionalidade
- Projeção e preservação de Informação
- PCA (Análise de Componentes Principais)
- Variância e autovalores
- Aplicações práticas

O problema da Alta Dimensionalidade

- Muitos atributos (Features/Características)
- Dados difíceis de Visualizar
- Aumento de Complexidade

Maldição da dimensionalidade

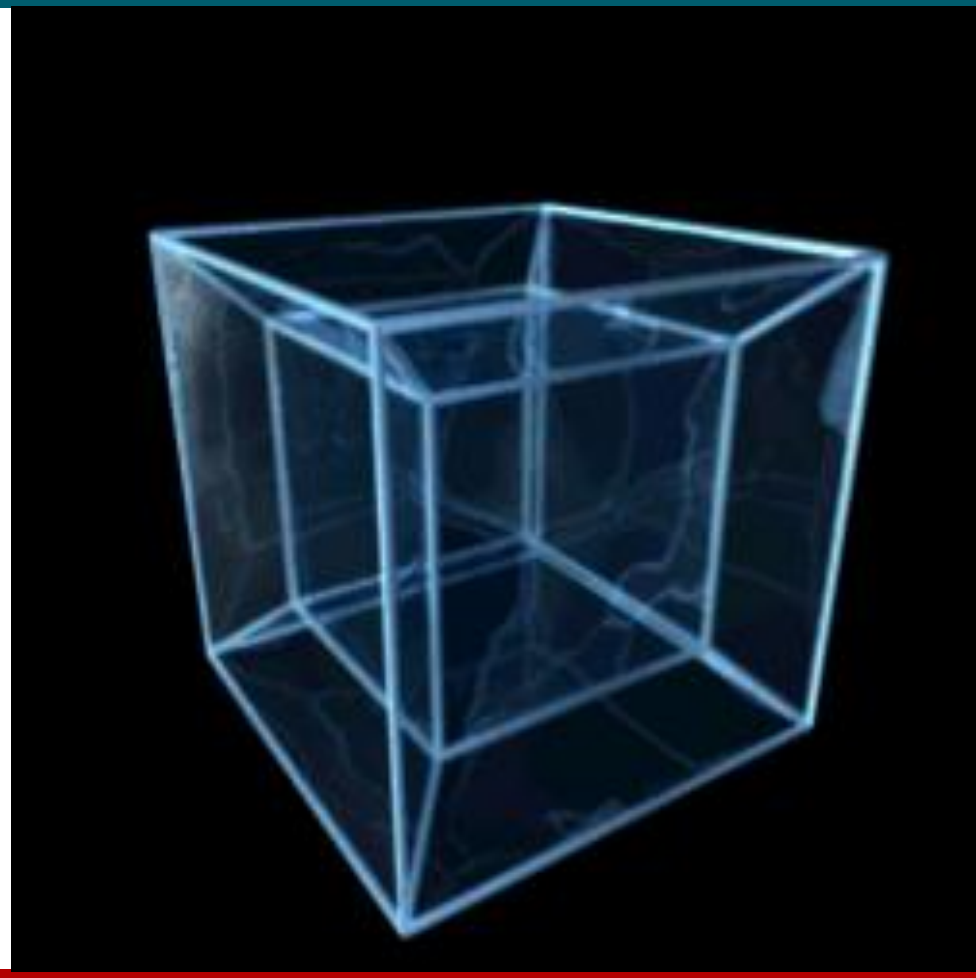

O que é a “Maldição”?

- **Dados ficam esparsos**
- **Distâncias perdem significado**
- **Modelos ficam mais difíceis de treinar**

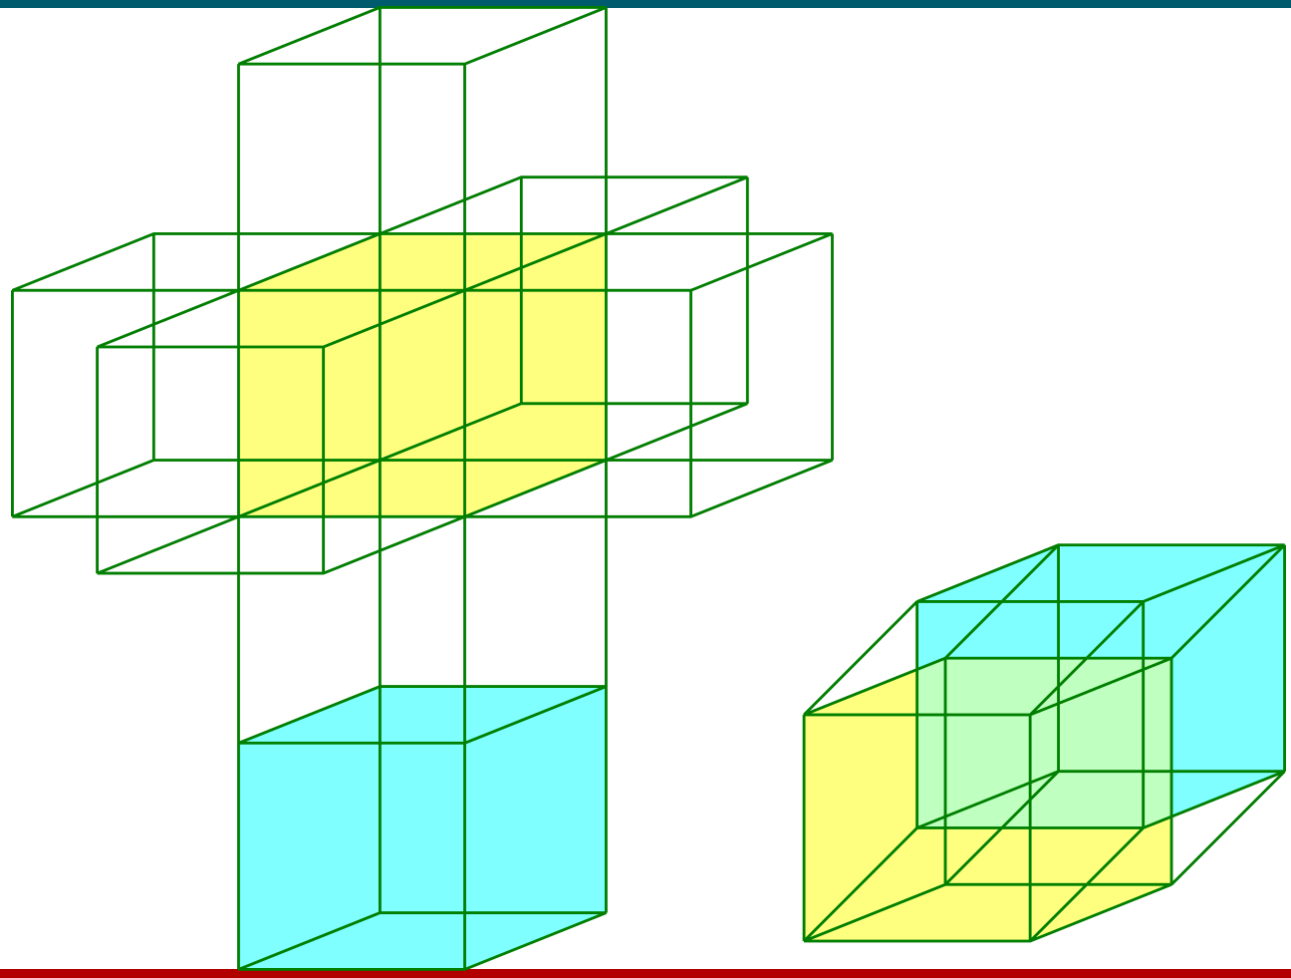

Por que reduzir Dimensionalidade?

- Simplificar o Modelo
- Melhorar Desempenho
- Reduzir Overfitting (sobreajuste)
- Visualizar Dados

Ideia Central

- **Reduzir Dimensões** mantendo o **Máximo de Informação** possível

Intuição Geométrica dos Dados

Dados podem ser projetados em dimensões menores

- 3D → 2D

- Dados em alta dimensão nem sempre ocupam todo o espaço
- Muitas vezes estão concentrados em regiões específicas

Pulo do gato

- *Os dados vivem em uma estrutura menor do que aparenta*

Intuição visual → Projeção

Dados em 3D

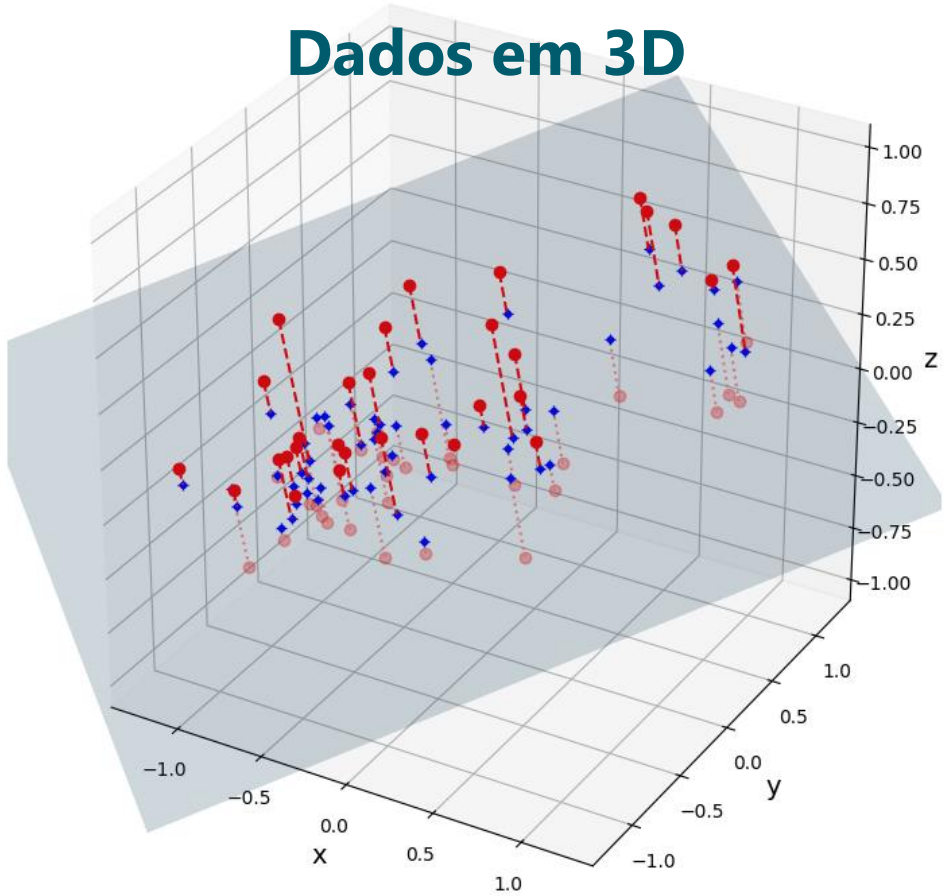

Redução para 2D

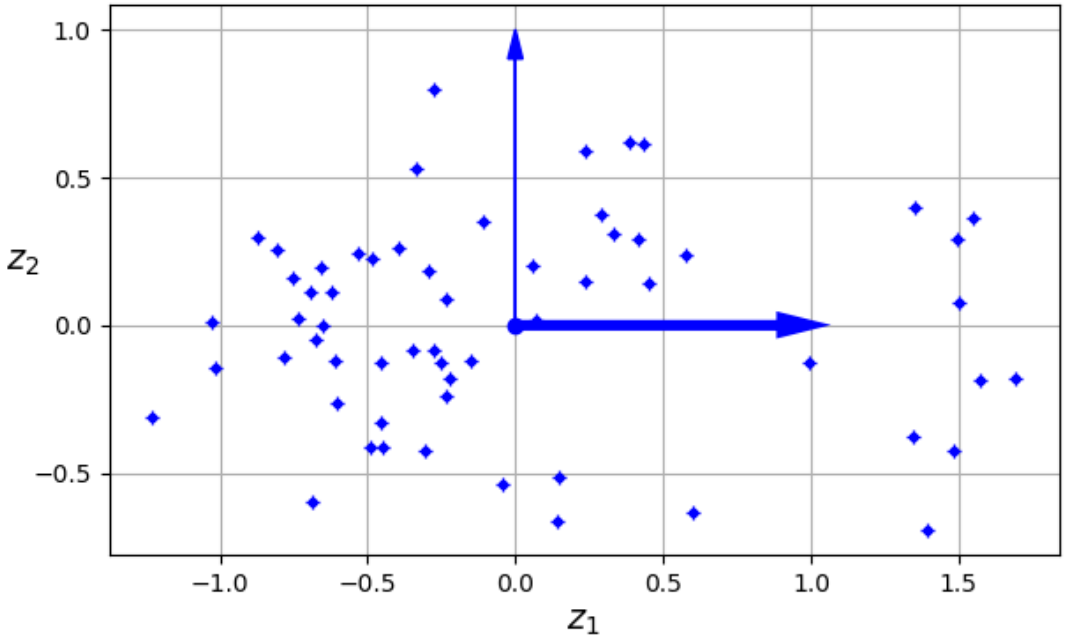

O que é um Manifold(variedade)?

Estrutura de menor dimensão embutida em um espaço de maior dimensão

Exemplos

- Folha de papel (2D) dobrada no espaço (3D)
- Uma curva em um Plano

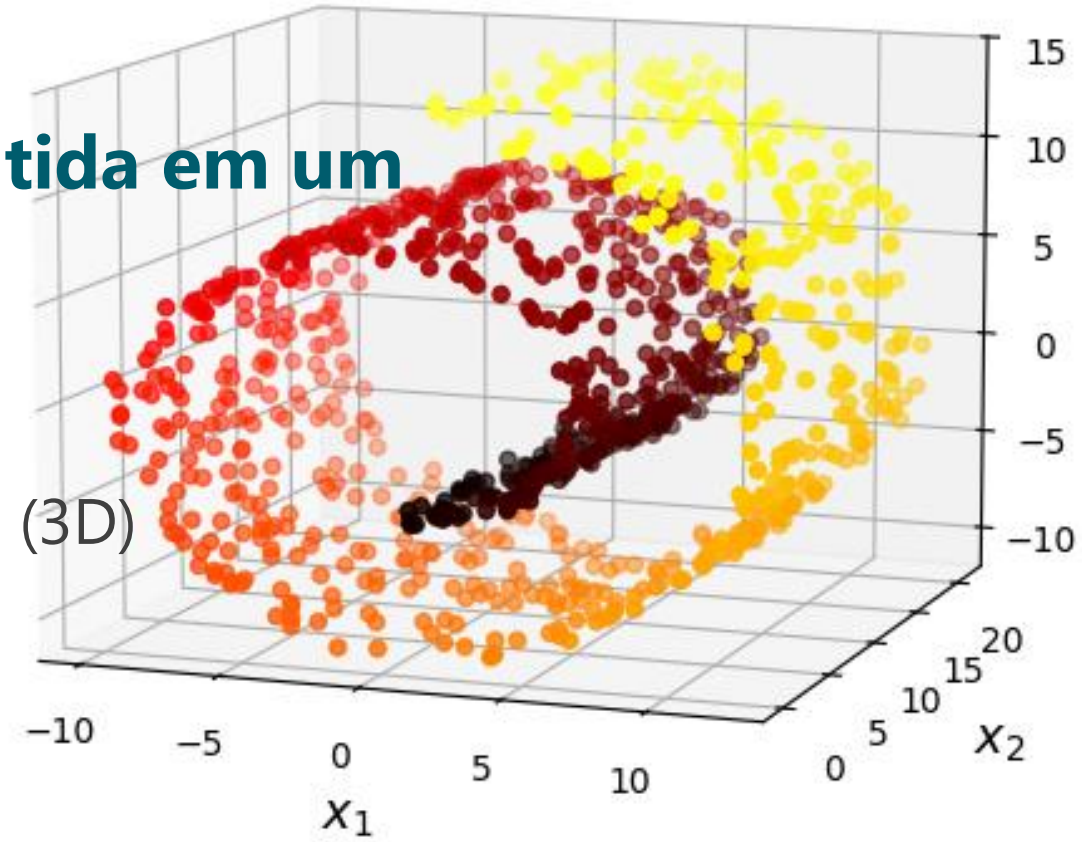

Hipótese de Manifold

Dados do mundo real tendem a estar próximos de variedades de baixa dimensão

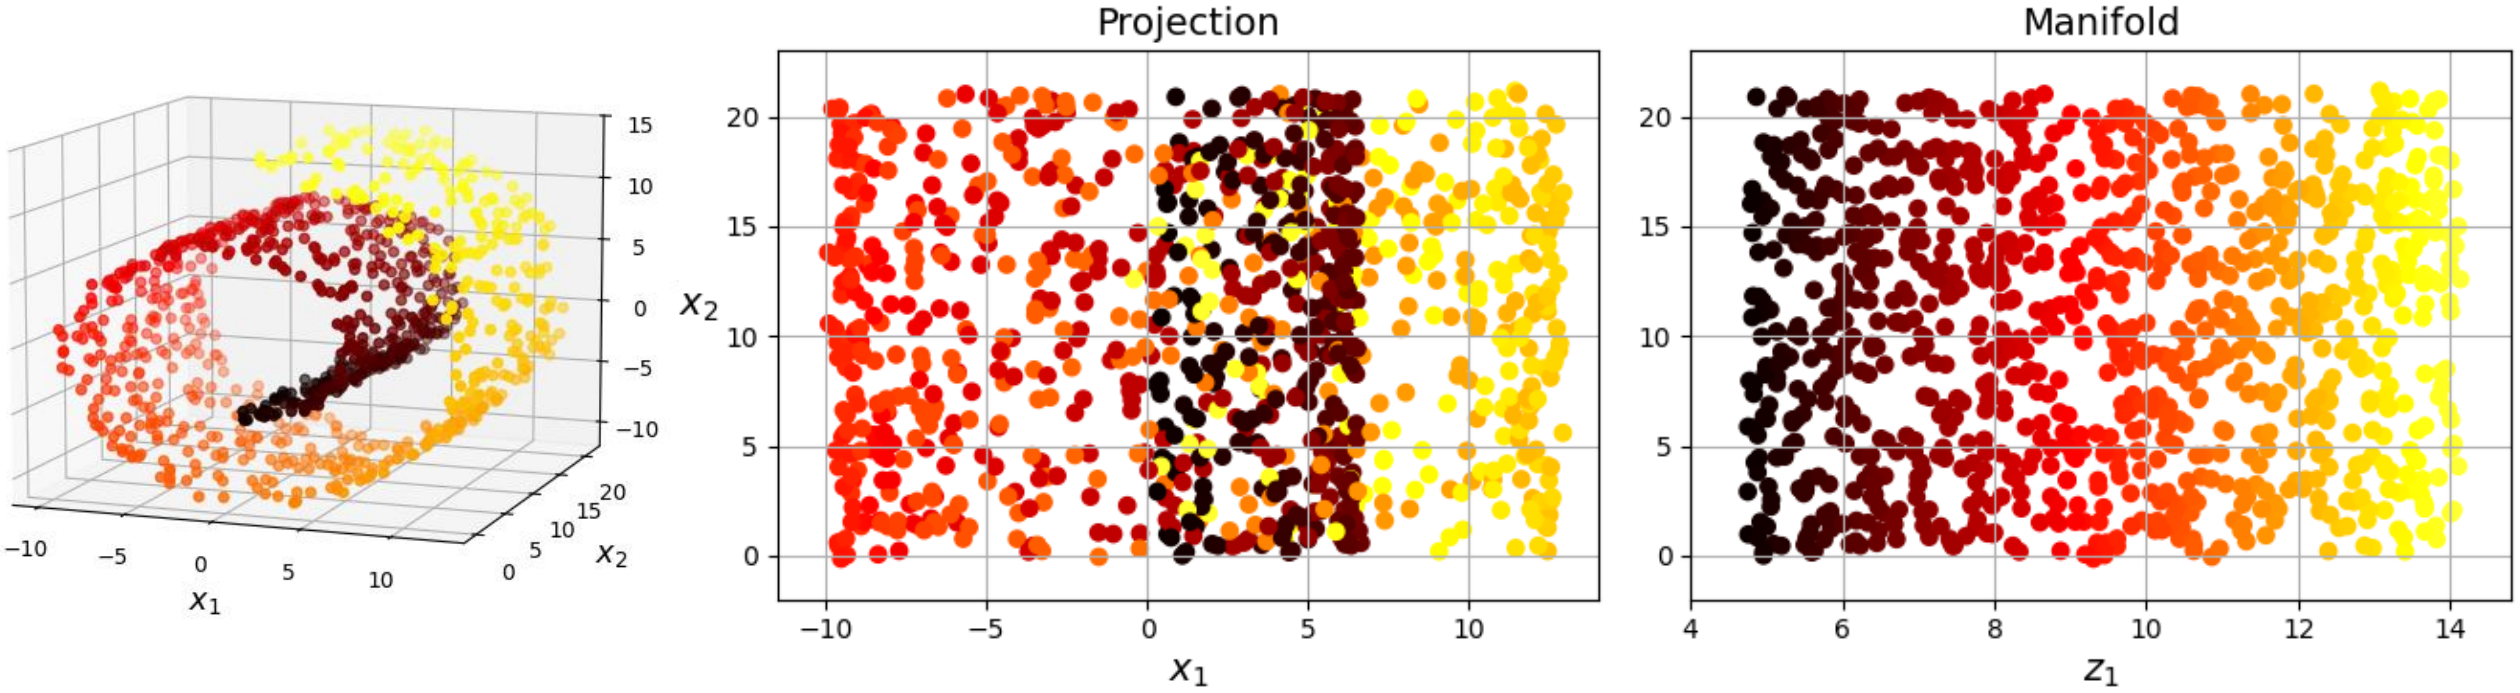

Demonstração

- **Notebook**
  Aulas 10 - Redução de Dimensionalidade.ipynb
  - Intuição Geométrica dos Dados

PCA (Principal Component Analysis)

Técnica para reduzir dimensionalidade

Encontra direções/eixos com maior Variância

- Identifica o Hiperplano que mais preserva a Variância
  - **Evita perda de informação relevante**

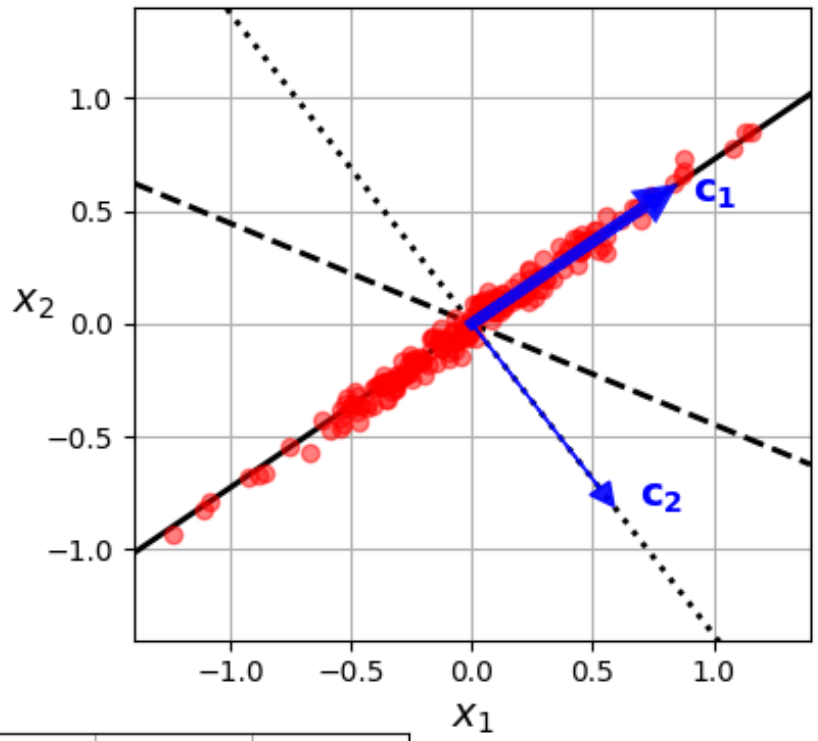

PCA gira o Eixo dos Dados

Alinha com a direção de maior informação

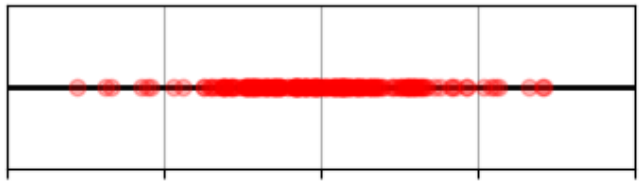

Componentes Principais

Para um Dataset com N Dimensões, teremos a identificação dos Componentes principais

- **1º componente** → Maior variância
- **2º componente** → Segunda maior (ortogonal)
- ...
- **l-ésimo componente** → O último componente, que correspondera a até o Número de Dimensões originais do Dataset

PCA e Componentes Principais

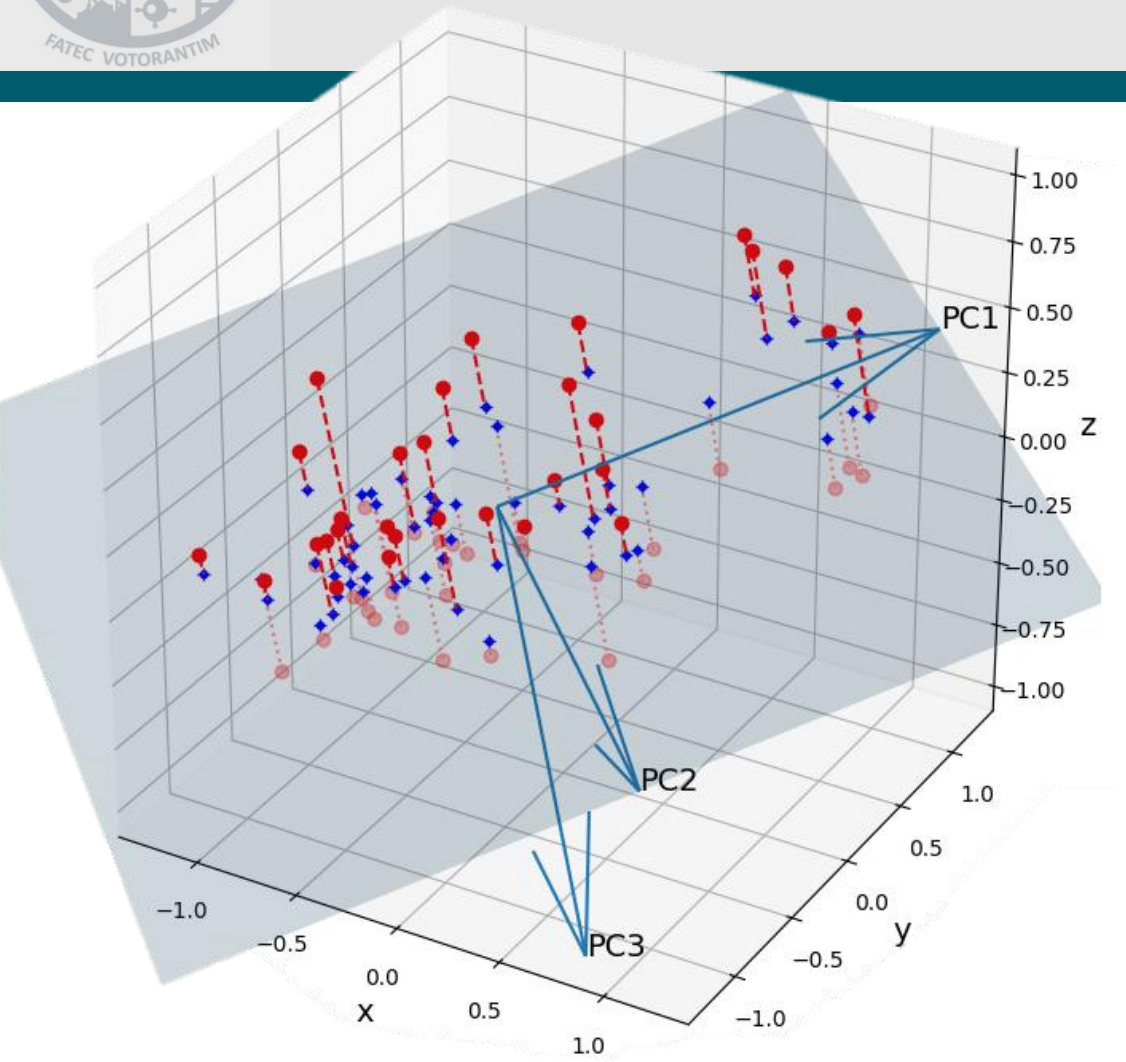

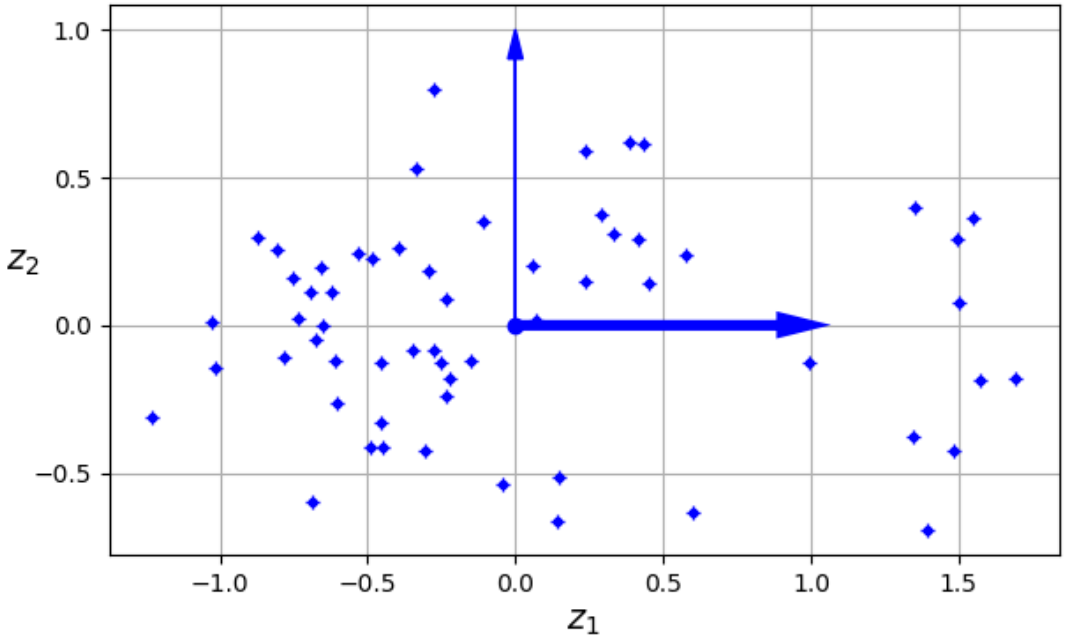

Demonstração

- **Notebook**
  Aulas 10 - Redução de Dimensionalidade.ipynb
  - PCA (Análise de Componente Principal)

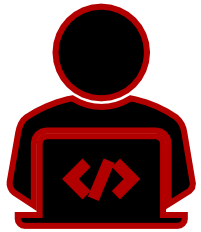

Variância e Informação

Por que Variância?

- Mais variância → Mais informação

Taxa de Variância Explicada

- Quanto da informação original foi mantida

Escolha da Quantidade de Componentes

Como escolher a Quantidade de Componentes a serem Mantidos?

- Indicar uma Quantidade de Componentes
- Indicar um % de Variância a ser preservado

Variância Explicada Acumulada

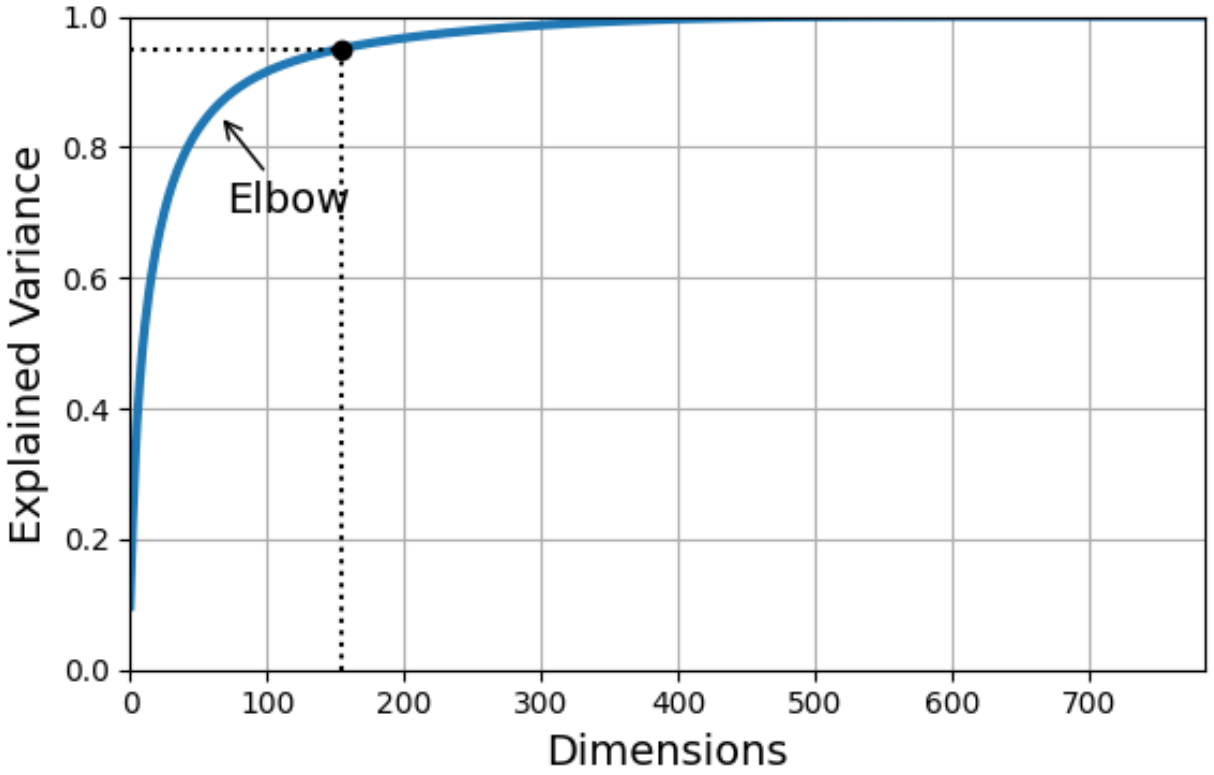

Demonstração

- **Notebook**
  Aulas 10 - Redução de Dimensionalidade.ipynb
  - Escolhendo a Quantidade de Componentes

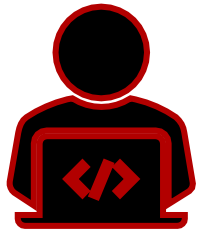

Aplicações Práticas

Para que usar PCA?

- Compressão de Dados
- Visualização
- Redução de Ruído
- Pré-processamento

PCA ajuda modelos a

- Treinar mais Rápido
- Generalizar Melhor

Limitações

- **Perda de Interpretabilidade**
- **Assume relações lineares**
- **Pode descartar informação relevante**

Use com Cuidado

- Quando **Caractarísticas são importantes** individualmente
- Quando **Interpretabilidade é crítica**

Encerramento

- Foco de Hoje → **Redução de dimensionalidade simplifica os dados ao projetá-los em menos dimensões, preservando a maior parte da informação**

- **Pratique!**
  - Aplique PCA em um Dataset real
  - Teste diferentes números de componentes
  - Observe o impacto na performance

- Próxima aula → **Clusterização** → Como encontrar padrões em dados sem rótulos