Clusterização

Prof. Milton Roman de Brito

Fatec Votorantim Benedicto Pagliato
Centro Paula Souza

Objetivo

Ao final da aula, vocês devem ser capazes de:

- Se aprofundar no conceito de Aprendizado não Supervisionado
- Explicar o que é Clusterização
- Compreender o funcionamento do K-Means
- Interpretar resultados de agrupamento
- Avaliar a qualidade de Clusters
- Compreender o funcionamento do DBSCAN
- Compreender as diferenças entre K-Means e DBSCAN
- Identificar algumas aplicações práticas de Clusterização

Conteúdo da Aula

- O que é Clusterização
- Revisão → Aprendizado Supervisionado e não Supervisionado
- Algoritmo K-Means
- Escolha do número de Clusters (K)
- Métricas de Avaliação
- Limitações e Aplicações
- DBSCAN
- Vantagens e Limitações do DBSCAN
- K-Means vs DBSCAN

O que é Clusterização?

Agrupar dados Semelhantes

Não precisa de Rótulos

- Ideia central → Encontrar **Padrões Escondidos nos Dados**

Revisão

- **Aprendizado Supervisionado** → Dados com Rótulo
- **Não supervisionado** → Dados sem Rótulo

Aplicações Práticas

- Segmentação de Clientes
- Análise de Dados
- Redução de Dimensionalidade
- Engenharia de Características
- Detecção de Anomalias
- Aprendizado Semisupervisionado
- Mecanismos de Busca
- Segmentação de Imagens

Intuição visual

- Pontos próximos → **Mesmo grupo**
- Pontos distantes → **Grupos diferentes**

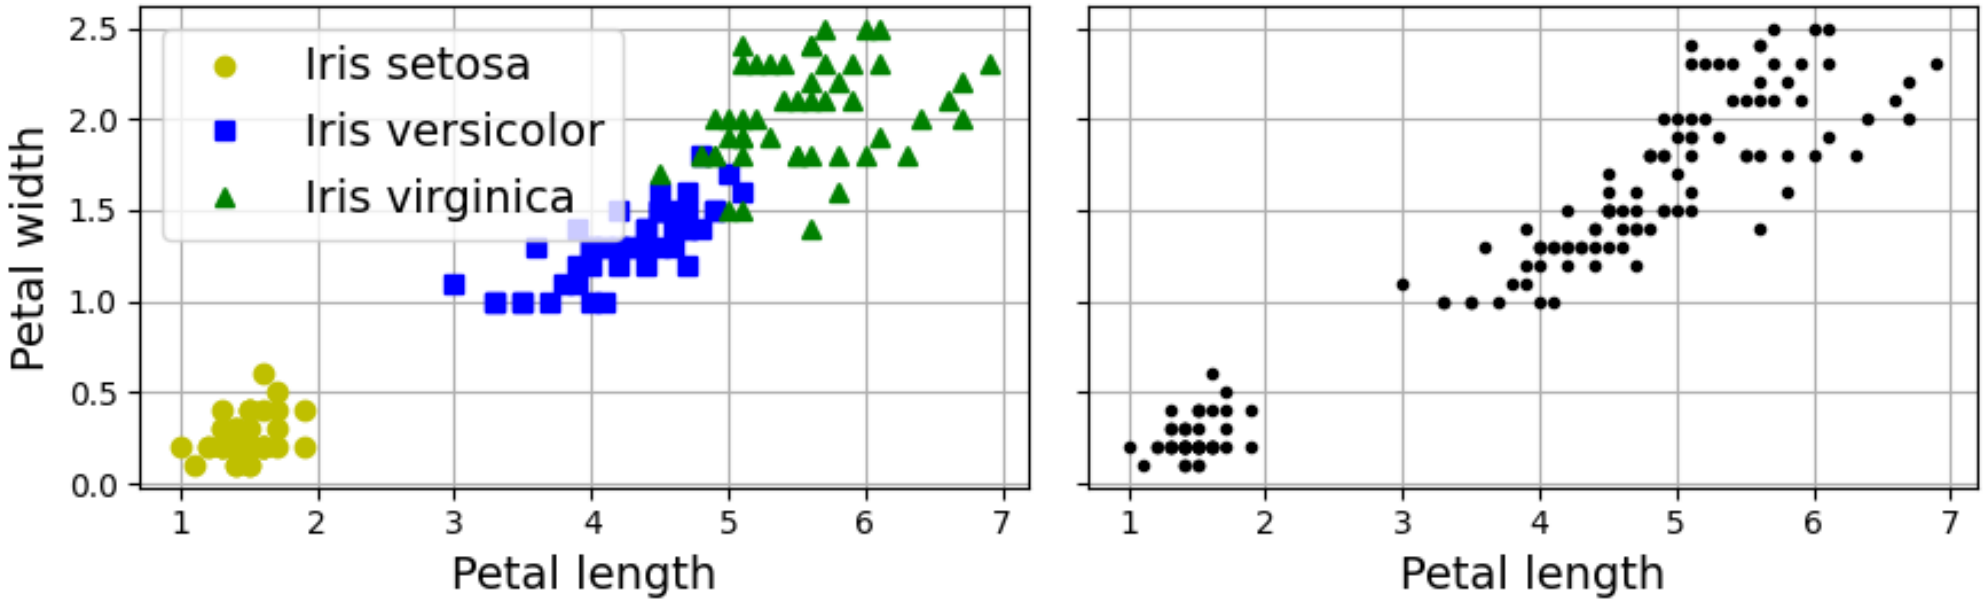

Demonstração

- **Notebook**
  Aulas 11 - Clusterização.ipynb
  - Clusterização (Clustering)

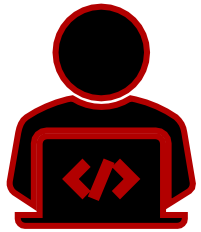

K-Means

O que é K-Means?

- Algoritmo de Clusterização baseado em Centroides
- Cada cluster tem um Centro (Centroide)

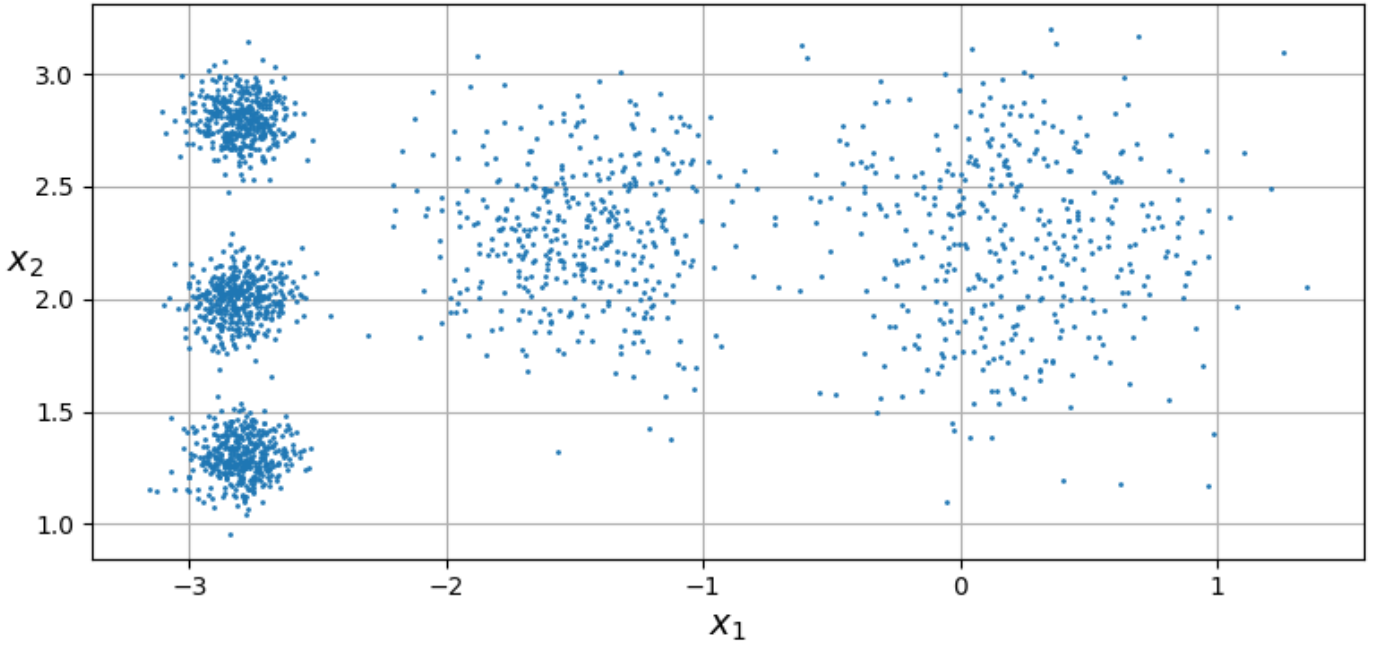

Centroides e Fronteiras de Decisão
Diagrama de Voronoi

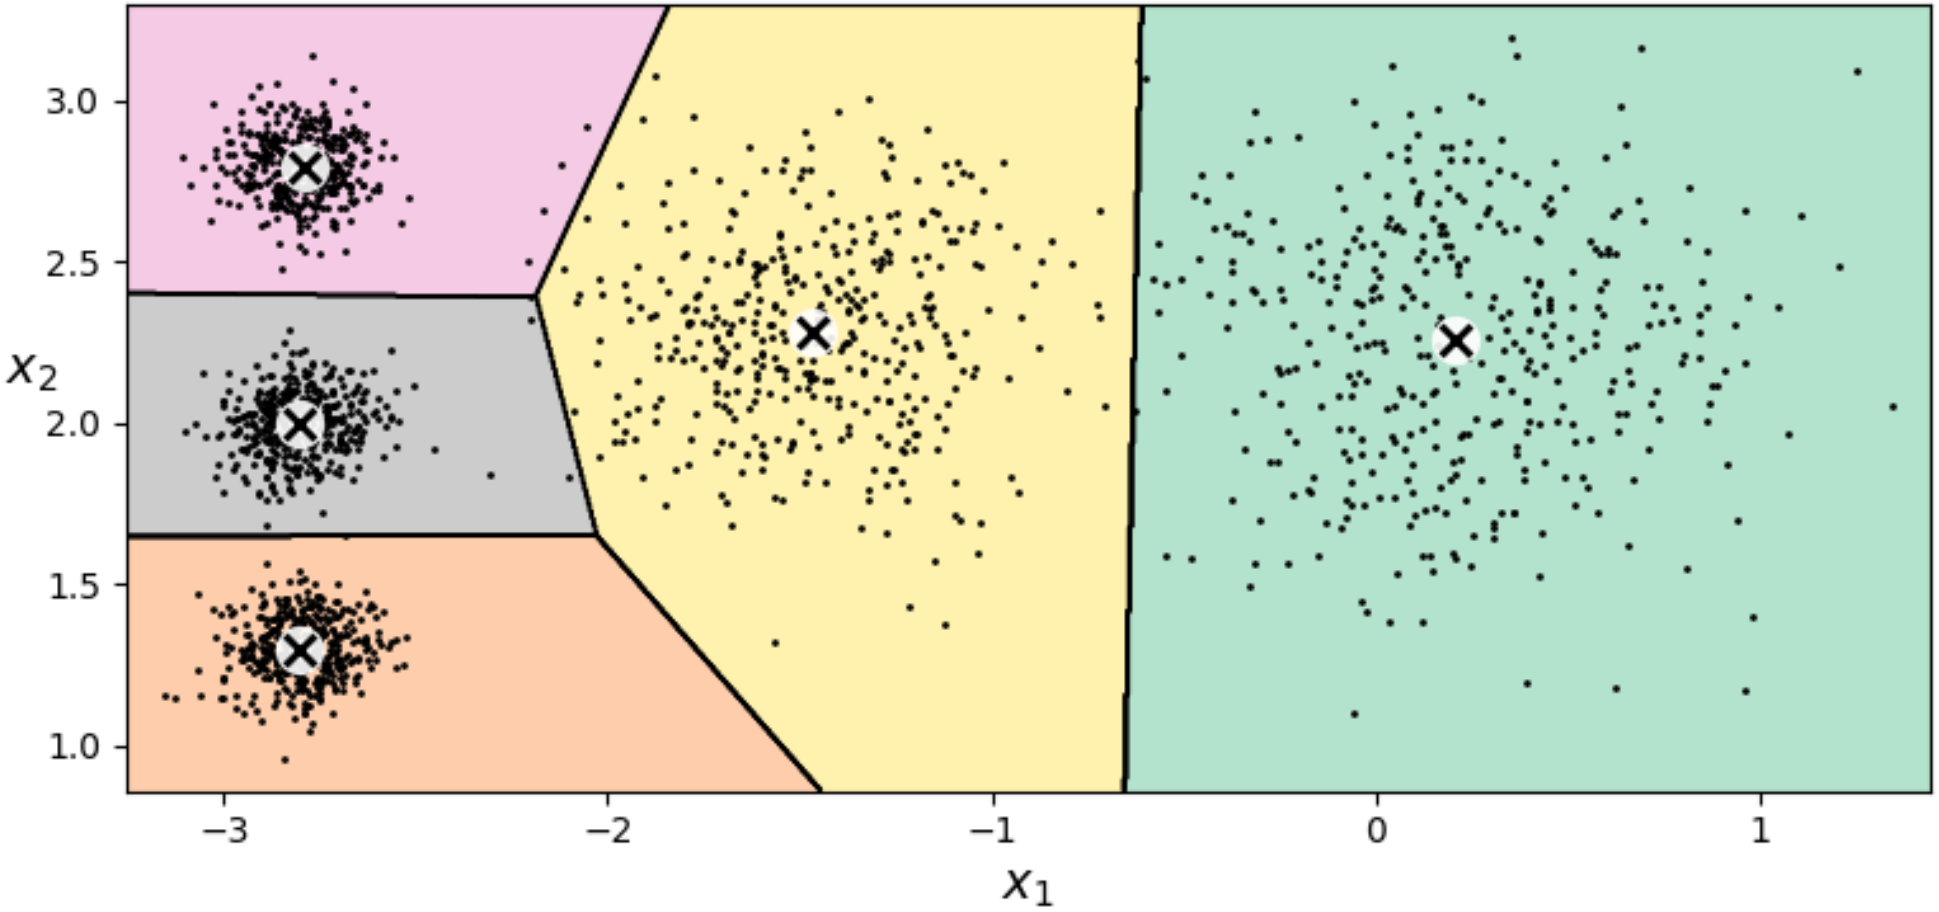

Passo a passo do Treinamento K-Means

1. Escolher “K” Centroides Iniciais
2. Atribuir pontos ao Centro mais próximo
3. Atualizar Centroides para o ponto médio das instâncias
4. Repetir até Convergir

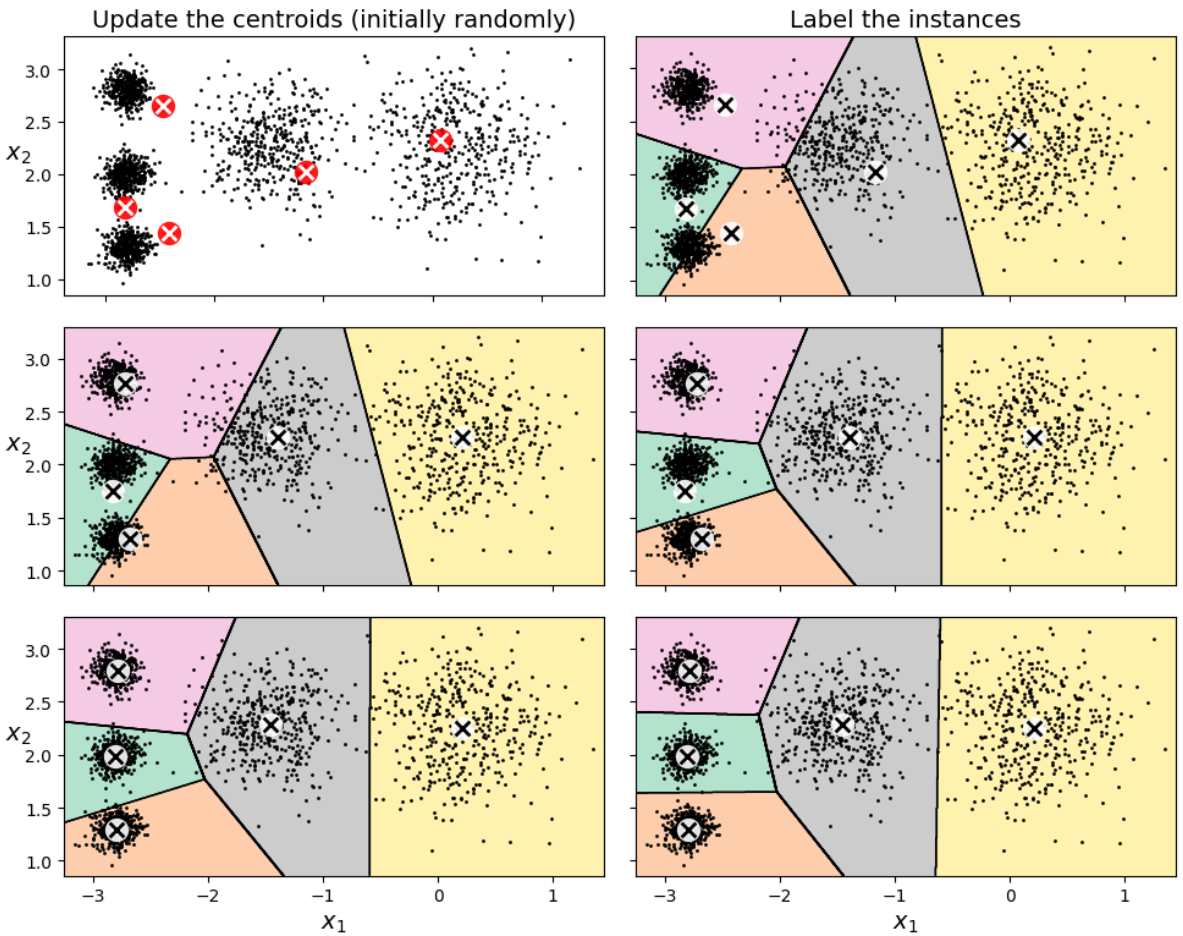

Inércia, Variabilidade e Múltiplas Inicializações

A Inicialização dos Centroides é aleatória

- O Resultado do Treinamento, pode variar

1. O Treinamento do K-Means é executado “n_init” vezes
2. A cada execução, a inicialização dos centroides é aleatória
3. Cada execução gera uma métrica de Inércia
   - A Inércia (“inertia_”), é a soma das distâncias ao centroides ao quadrado
   - Quanto menor a Inércia, mais próximos os pontos estão dos centroides
4. Ao final, é escolhido a execução com a menor Inércia final

Demonstração

- **Notebook**
  Aulas 11 - Clusterização.ipynb
  - K-Means

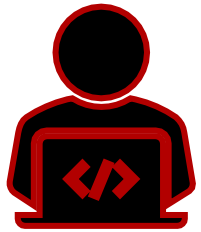

Escolha do "K"

Quantos Clusters escolher?

- *Usar Inércia?*
- *Testes?*
- *Conhecimento de Negócio?*

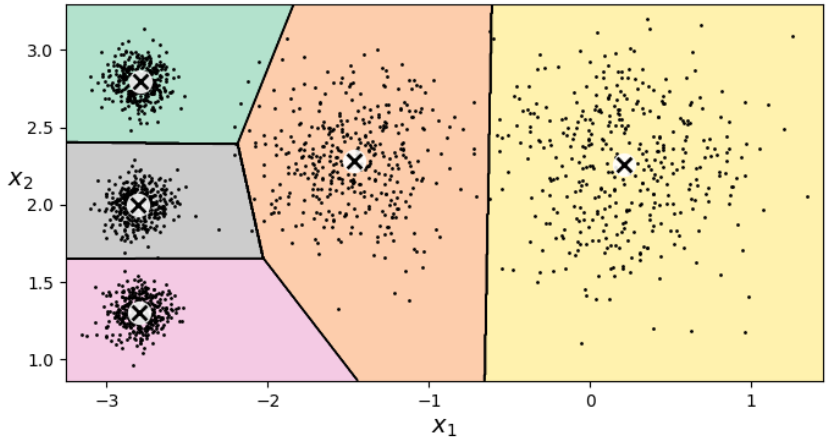

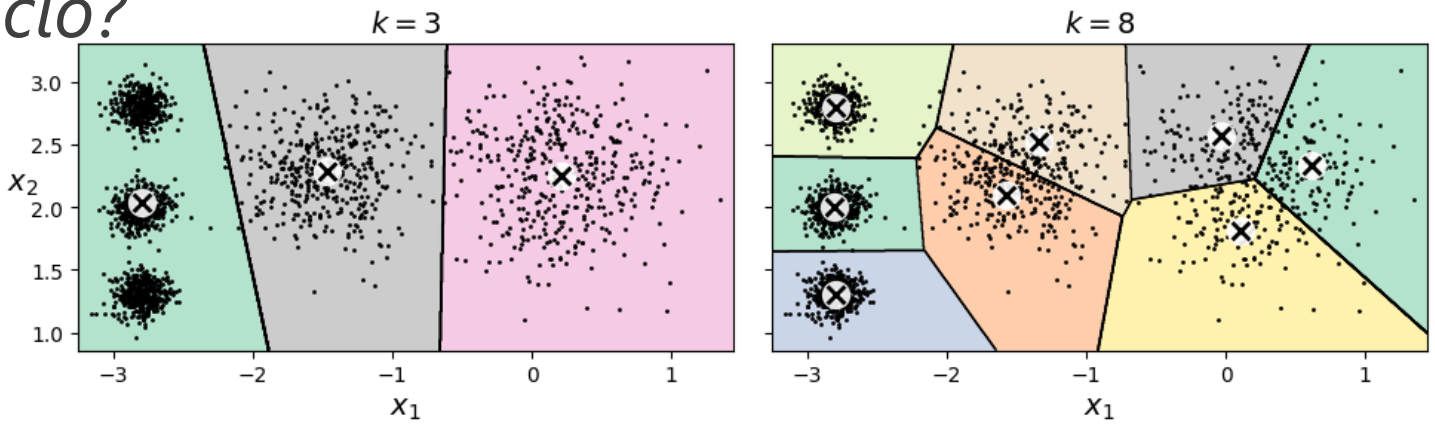

Método do Cotovelo (Elbow)

Avaliando a Inércia em função de “K”

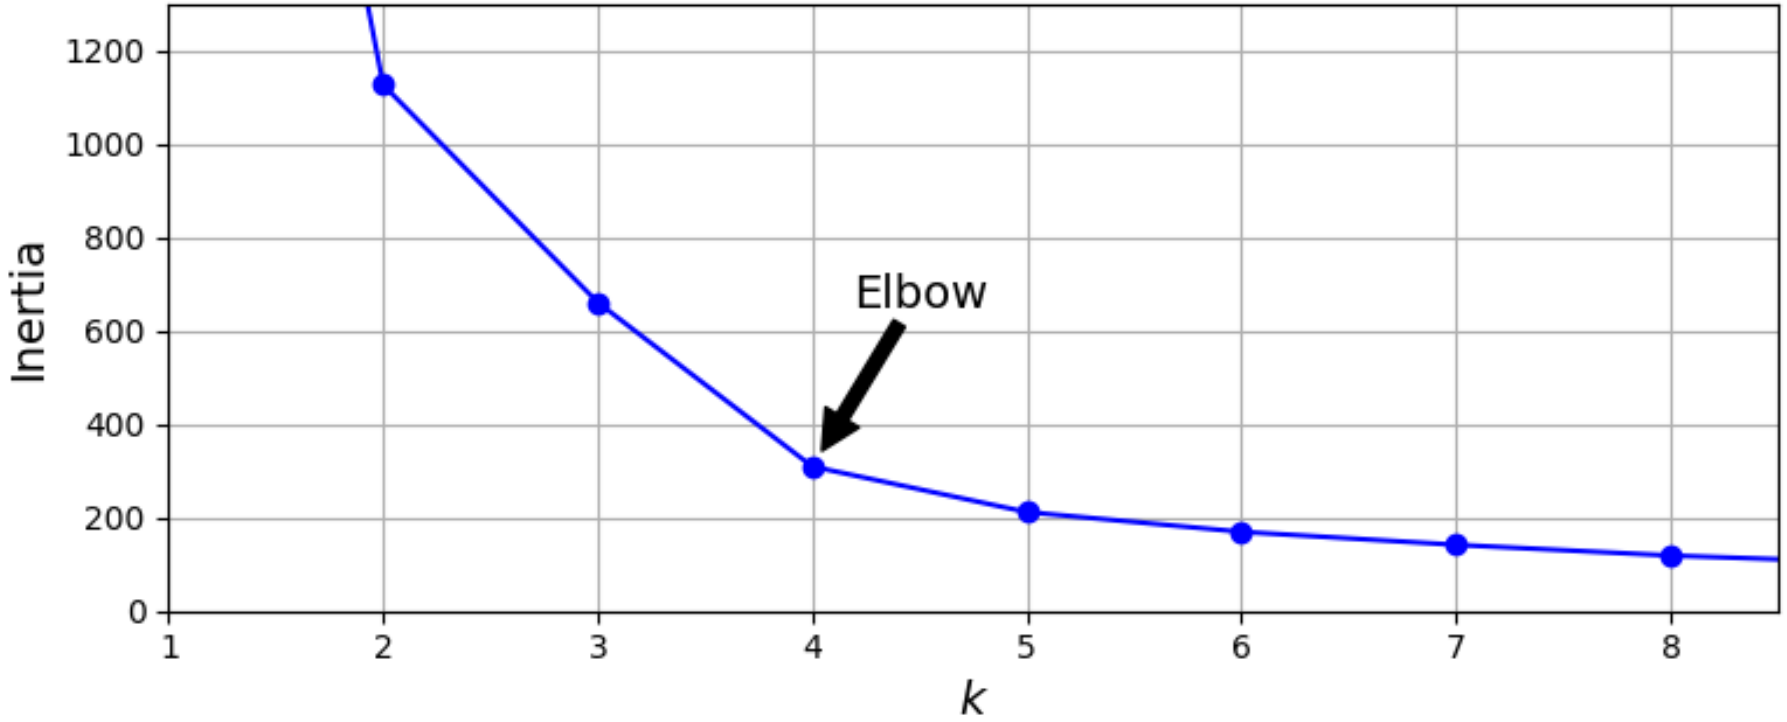

Silhouette Score

Mede separação entre Clusters

- Próximo de 1 → **Bom**
- Próximo de 0 → **Sobreposição**
- Negativo → **Erro**

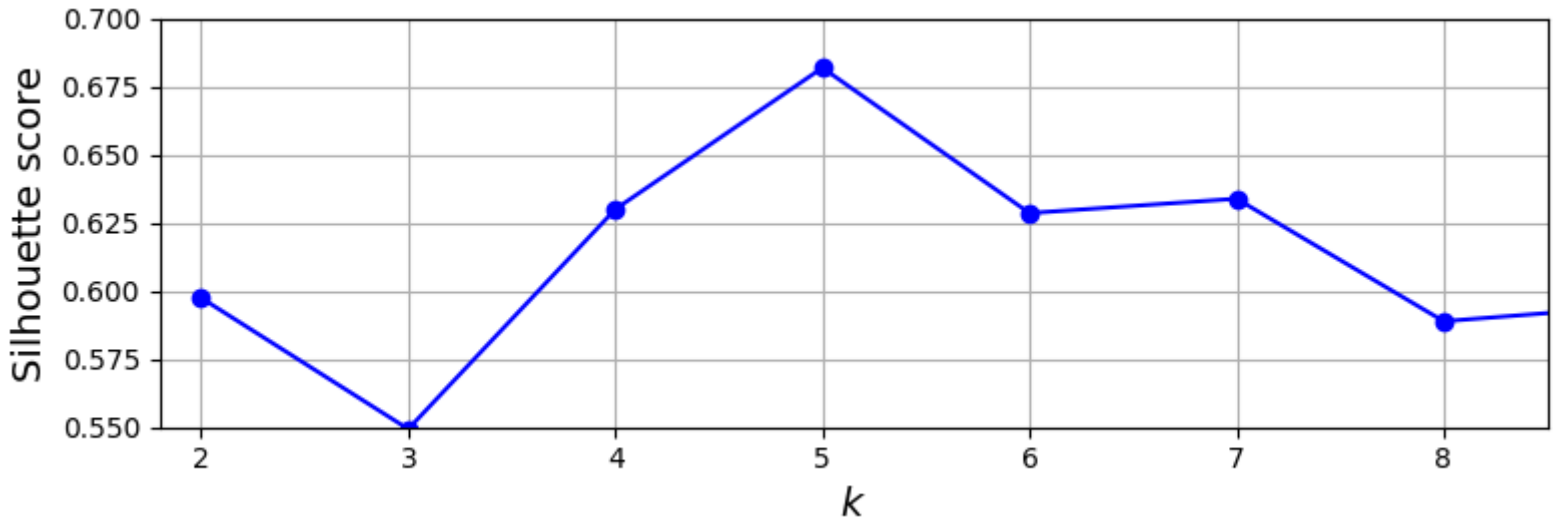

Diagrama de Silhouette

Mostra o Coeficiente de Silhouette de cada instância, ordenado pelo cluster ao qual ela foi atribuída

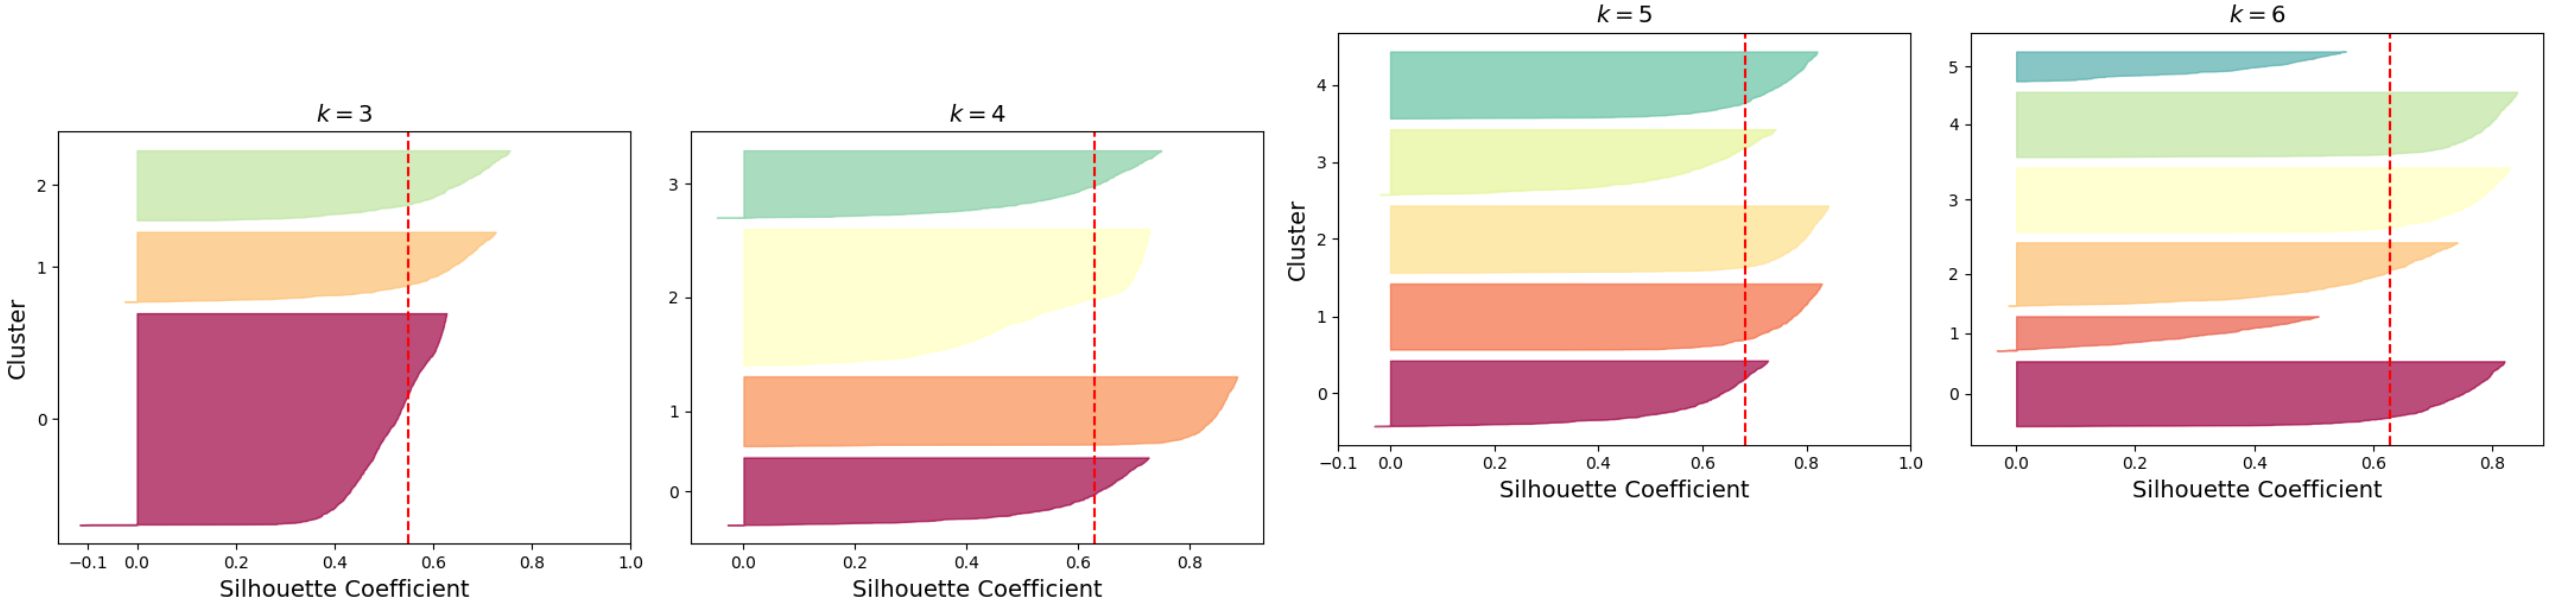

Limitações do K-Means

- Assume Clusters Esféricos
- Sensível a Escala
- Sensível à Inicialização

Problemas comuns

- Clusters de formatos diferentes
- Outliers

Demonstração

- **Notebook**
  Aulas 11 - Clusterização.ipynb
  - Encontrando o número ideal de Clusters

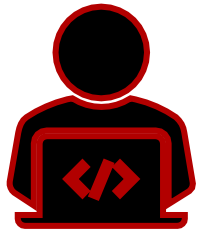

DBSCAN (Density-Based Spatial Clustering)

Agrupa pontos com base em **Densidade**

- Regiões Densas → **Clusters**
- Regiões Esparsas → **Ruído**

Intuição

- *Clusters são áreas com muitos* ***Pontos Próximos***

Classifica os Pontos em

- **Core (núcleo)** → Alta Densidade
- **Border (borda)** → Próximo de um Cluster
- **Noise (ruído)** → Isolado

DBSCAN
Principais Hiper Parâmetros

eps → Raio de Vizinhança

min_samples → Mínimo de Pontos por cluster

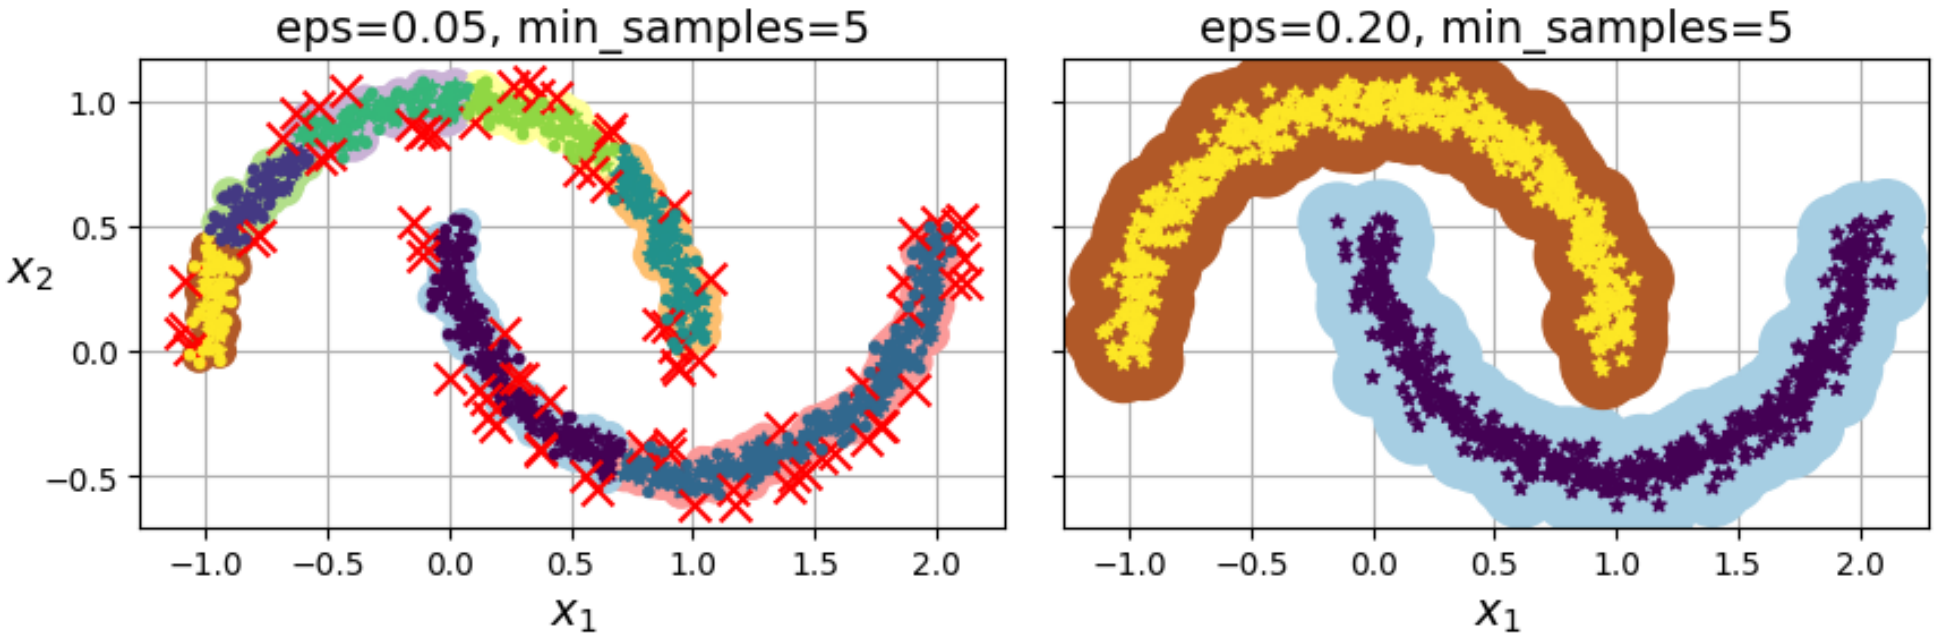

Vantagens e Limitações do DBSCAN

Vantagens

- Não precisa definir K
- Detecta Clusters Arbitrários
- Identifica outliers Automaticamente

Limitações

- Sensível aos Parâmetros
- Difícil em Alta Dimensionalidade
- Problemas com Densidades Variadas

Demonstração

- **Notebook**
  Aulas 11 - Clusterização.ipynb
  - DBSCAN

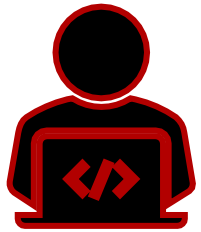

K-Means vs DBSCAN

Característica	K-Means	DBSCAN
Forma dos clusters	Esféricos	Arbitrários
Precisa definir K	Sim	Não
Sensível a outliers	Sim	Não (detecta)
Escala	Sensível	Sensível

Aplicações Práticas

Aplicação Direta

- Segmentação de Clientes
- Detecção de Anomalias
- Análise Exploratória

Clusterização como Característica

- Adicionar Cluster como Variável
- Melhorar modelos Supervisionados

Encerramento

- Foco de Hoje → **Algoritmos de clusterização agrupam dados sem rótulos, revelando padrões. Diferentes técnicas funcionam melhor dependendo da estrutura dos dados.**

- **Pratique!**
  - Compare K-Means e DBSCAN no mesmo Dataset
  - Experimente diferentes valores nos hiper parametros
  - Observe como os Clusters mudam

- Próxima aula → **Introdução à Redes Neurais Artificiais** → Como modelos inspirados no cérebro aprendem padrões complexos