Redes Neurais Artificiais

Prof. Milton Roman de Brito

Fatec Votorantim Benedicto Pagliato
Centro Paula Souza

Objetivo

Ao final da aula, vocês devem ser capazes de:

- Entender a inspiração das Redes Neurais Artificiais
- Explicar o funcionamento de um Neurônio Artificial
- Compreender o conceito de Camadas Neurais
- Interpretar funções de ativação
- Entender intuitivamente como ocorre o treinamento

Conteúdo da Aula

- Inspiração Biológica
- Neurônio Artificial
- Perceptron
- Redes Multicamadas (MLP)
- Funções de Ativação
- Forward Propagation
- Introdução ao Treinamento de Rredes Neurais

Por que Redes Neurais?

Alguns **Problemas** são **Muito Complexos**

Relações altamente **Não Lineares**

Exemplos

- Reconhecimento de Imagens
- Voz
- Linguagem Natural

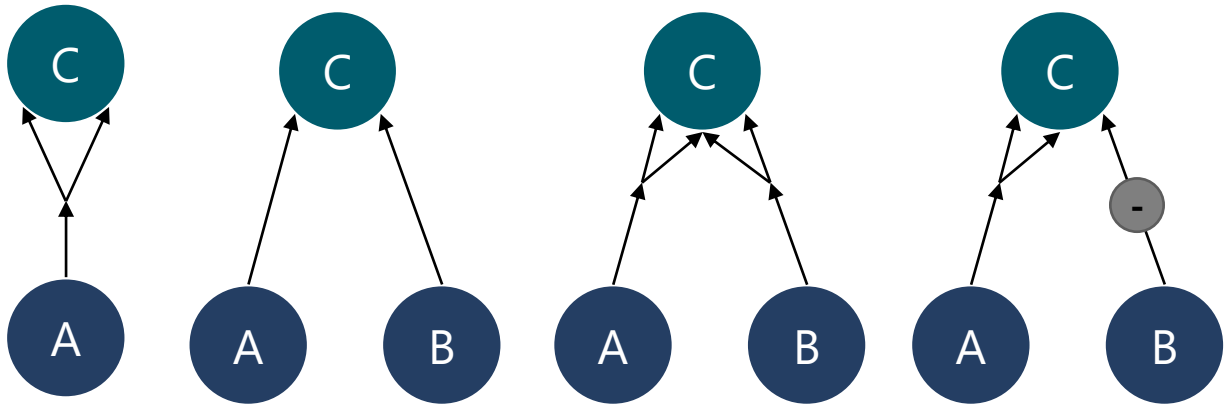

Inspiração Biológica

Neurônios Biológicos

Conexões Sinápticas

- Entrada de Sinais
- Integração / Processamento
- Saída

Importante

- *Redes neurais artificiais são apenas inspiradas no cérebro*

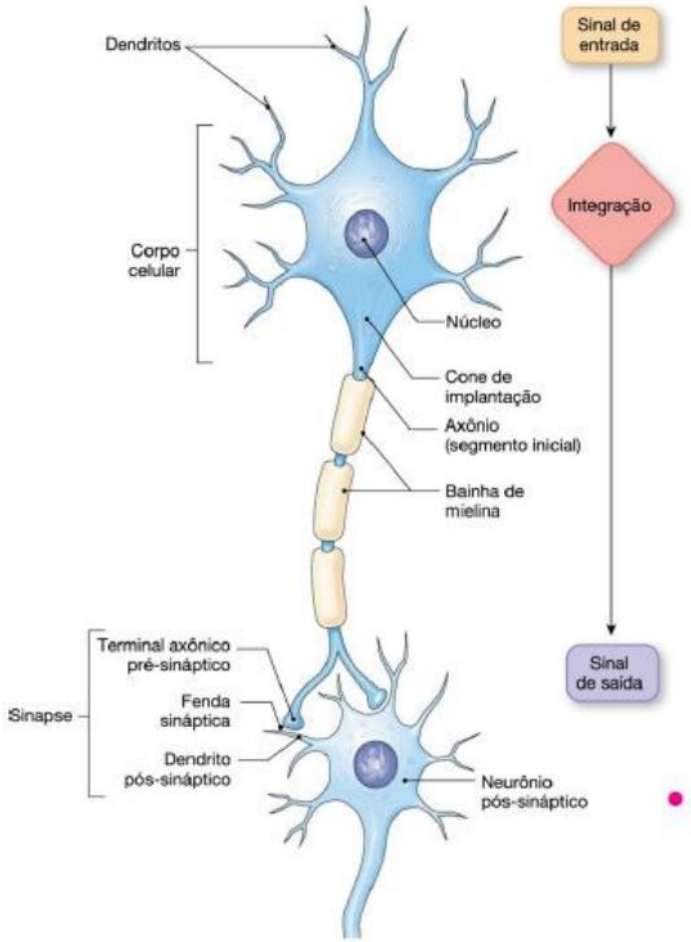

Redes Neurais Artificiais

Alguns exemplos simples de Cálculos realizados a partir de uma Rede Neural Artificial

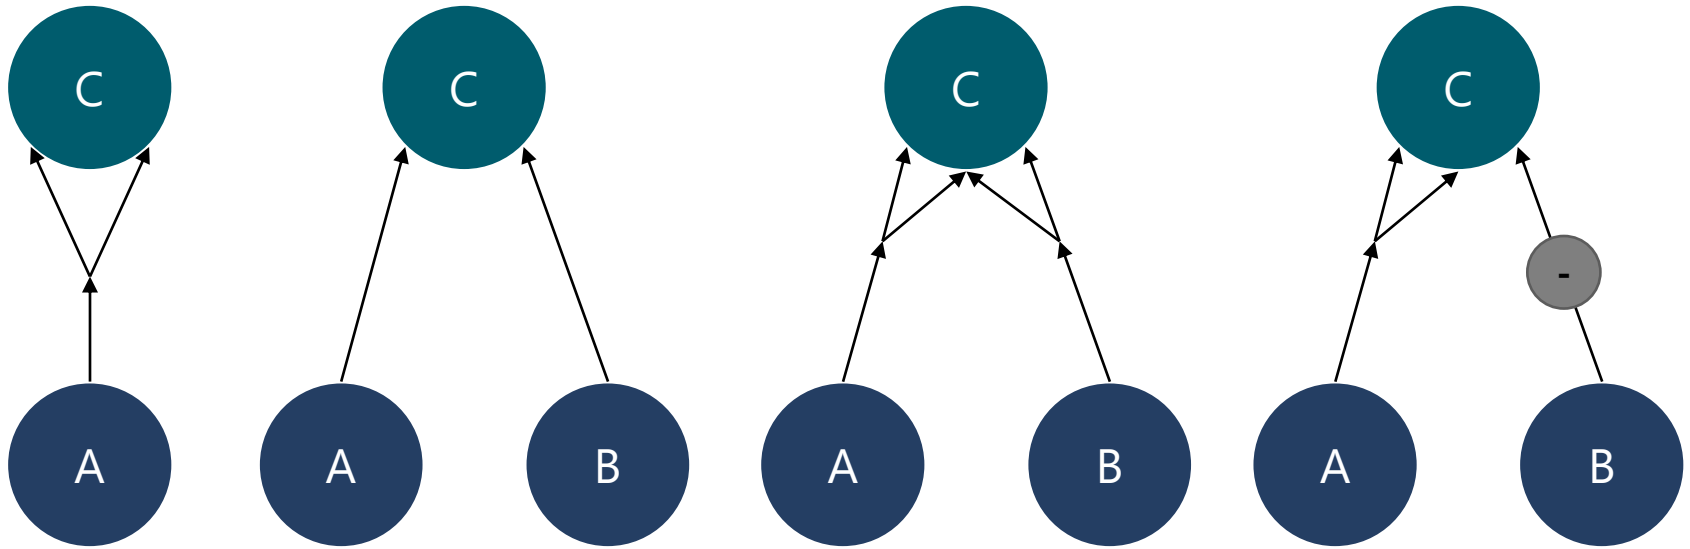

Perceptron
Neurônio Artificial

O **Perceptron** é uma das arquiteturas mais de Redes Neurais Artificiais, capaz de aprender a tomar decisões básicas a partir de exemplos

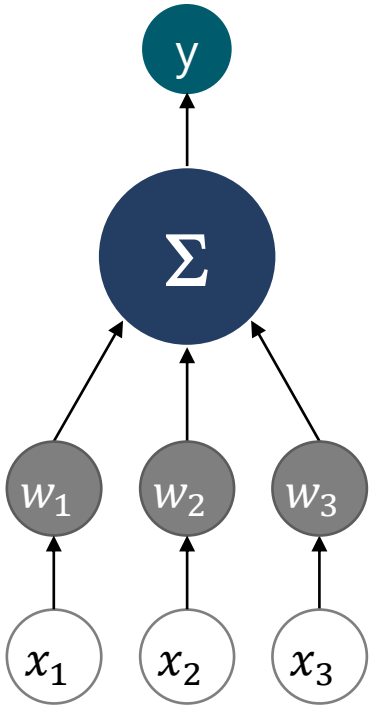

O que é um Neurônio Artificial?

- Recebe Entradas
- Aplica Pesos
- Soma Valores
- Produz Saída

Estrutura do Neurônio

Entradas
- x_1, x_2, x_3

Pesos
- w_1, w_2, w_3

Bias
- b

Função Linear
- $z = w_1x_1 + w_2x_2 + w_3x_3 + b$

Função Degrau / Ativação
- **Determina a Saída**

Saída
- **Ativação**

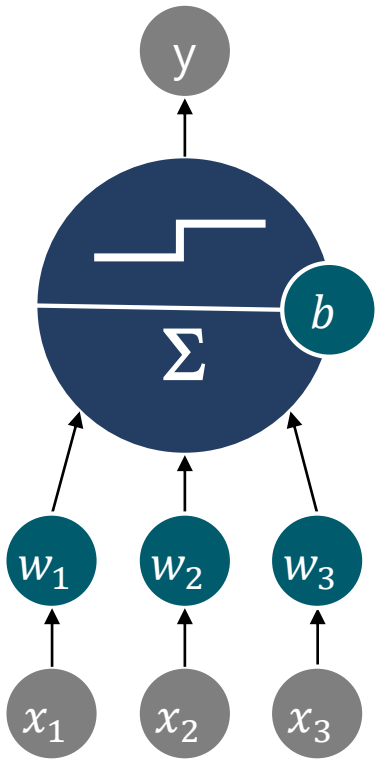

Saída

Função de Ativação

Bias

Função Linear

Pesos

Entradas

Treinamento de um modelo Perceptron

Intuição dos pesos

- Pesos positivos → aumentam influência
- Pesos negativos → reduzem influência

Comparação Biológica

Função de Ativação

O que é uma **Função de Ativação**?

- É o mecanismo do neurônio artificial que decide qual será a saída da rede a partir das informações recebidas

Por que usar Ativação?

- Sem Funções de Ativação, o resultado de qualquer **RNA seria Linear**

Funções de Ativação

Heaviside
- Retorna 0 ou 1 (binário)

0 se z < 0
1 se z > 0

Sigmoid
- Saída entre 0 e 1
- Interpretação Probabilística

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Tanh → Função Tangente Hiperbólica
- Saída entre -1 e 1
- Costuma convergir mais rápido que Sigmoid
- Representa sinais Positivos e Negativos

$$\tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

ReLU → Função de Unidade Linear Retificada
- Treinamento mais rápido
- *Função mais usada atualmente*

ReLU(z)=max(0,z)

Funções de Ativação

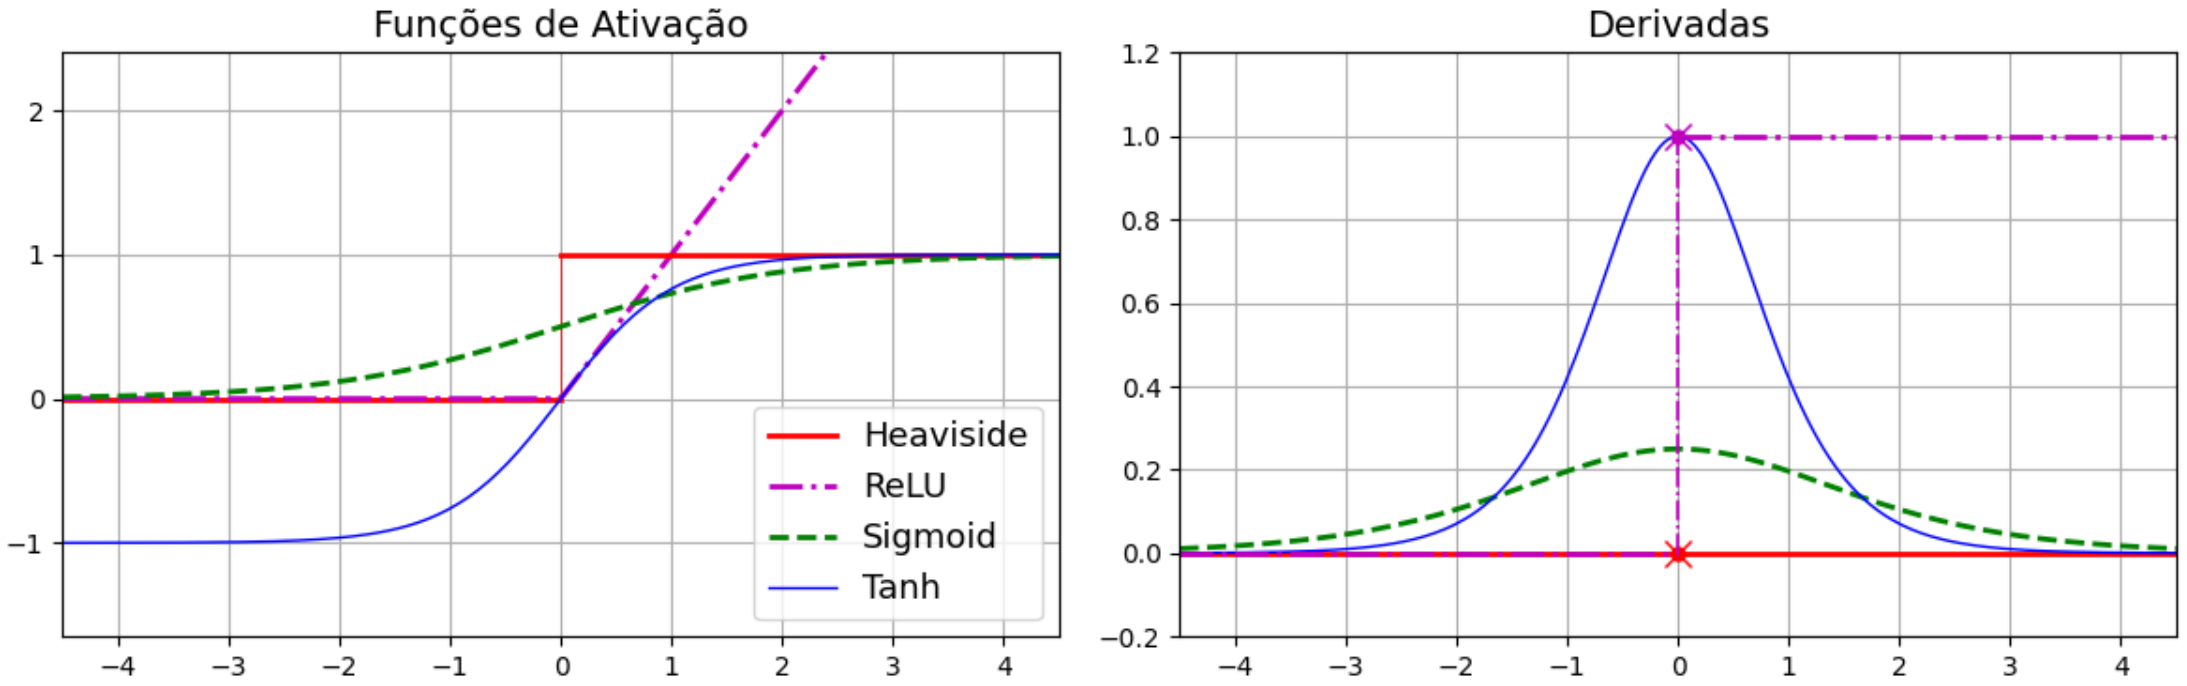

Demonstração

- **Notebook**
  Aulas 12 - Introdução a Redes Neurais.ipynb
  - O Perceptron

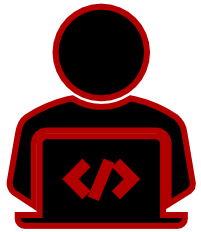

Redes Multicamadas

Limitação do Perceptron

- Não resolve Problemas Não Lineares

Multi-Layer Perceptron (MLP)

- Camada de Entrada
- Camadas Ocultas
- Saída

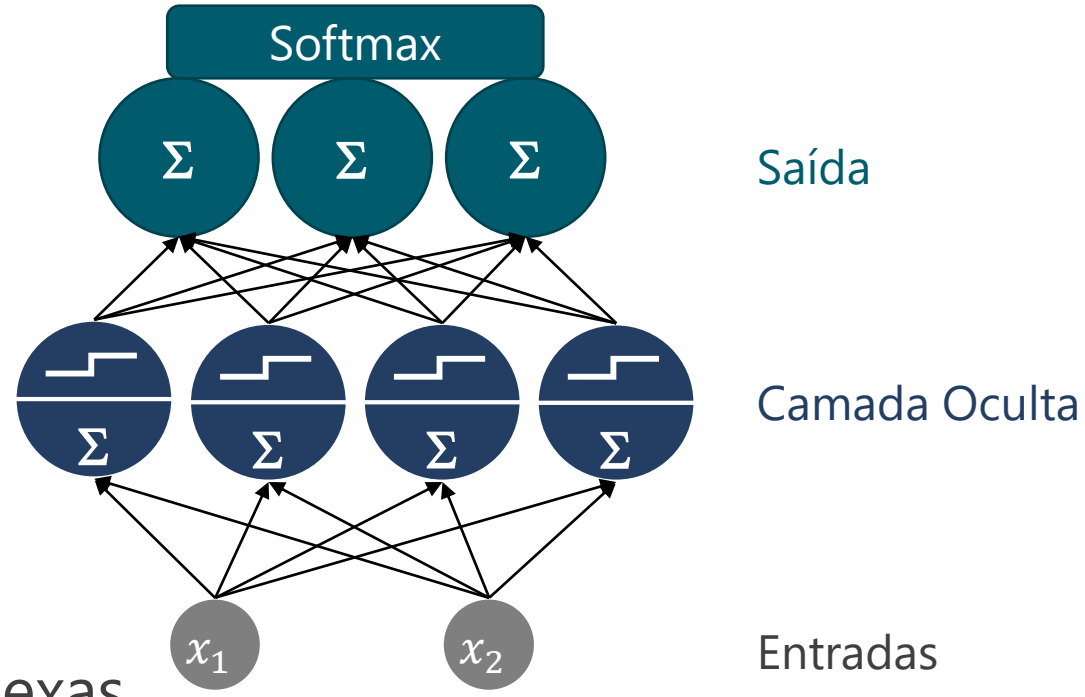

Papel das Camadas Ocultas

- Aprender representações mais complexas

Como a Rede Aprende?

A Rede aprende ajustando os pesos em todos os Neurônios (ou Unidades) da Rede

Ideia Geral → → → →

Erro → Calculado por uma função de Erro

Repetição → Lembra de algo?

Gradiente Descendente, Propagação e Retropropagação

No treinamento de RNAs, temos uma combinação de **Gradiente Descendente** e **Retropropagação**

Propagação

- A informação ***"flui"*** pela rede até a Saída

Retropropagação

- O erro ***"volta"*** pela rede ajustando pesos

Gradiente Descendente

- Aplicado na Retropropagação para minimizar o erro Gradualmente ajustando os Pesos

Treinamento em Maiores Detalhes

Inicializar os Pesos aleatoriamente
A rede começa com pesos pequenos e aleatórios

↓

Executar a propagação para frente (Forward Propagation)
Os dados percorrem a rede até gerar uma previsão

↓

Calcular o Erro
A saída Prevista é comparada com o Valor Esperado

↓

Executar a Retropropagação (Backpropagation)
O erro é propagado de trás para frente para calcular os gradientes

↓

Pesos são atualizados com Gradiente Descendente
Os pesos são ajustados para reduzir o erro

↓

Repetir o Processo por várias épocas (*Epochs*)
A rede aprende progressivamente ao repetir esse ciclo

Demonstração

- **Notebook**
  Aulas 12 - Introdução a Redes Neurais.ipynb
  - Redes Neurais Artificiais → MLPs

https://playground.tensorflow.org/

Vantagens, Limitações e Aplicações

Vantagens

- Aprende Padrões Complexos
- Alta Capacidade de Modelagem
- Flexibilidade

Limitações

- Exige muitos Dados
- Maior Custo Computacional
- Menos Interpretável

Aplicações

- Deep Learning
- IA generativa
- LLMs

Encerramento

- Foco de Hoje → **Redes Neurais Artificiais aprendem padrões complexos ajustando conexões entre Neurônios organizados em Múltiplas Camadas.**

- **Pratique!**
  - Teste Redes Neurais utilizando seus próprios Modelos
  - Teste diferentes Arquiteturas de Redes
  - Observe o impacto da Quantidade de Camadas

- Próxima aula → **Apresentações dos Projetos de Machine Learning**